

Iteration 01 — Label-aware Eigenvector Selection for LRFShap

Reading copy, 5 페이지 분량. plan_v2 + critique_v2 의 발췌 요약.

§ 1 Motivation & Question

LRFShap (lrfshap.pdf, Algorithm 1, p.4) 은 $K(X_N, X_N)$ 의 best rank- r approximation, 즉 **top- r by eigenvalue λ_i** 로 feature $\Phi_{tr} = U_r \Lambda_r^{1/2}$ 를 만든 뒤 모든 prefix 의 ridge solve 를 r -차원 공간에서 수행한다. § 5.5 (pp.7-8) 의 cross-dataset 실험은 이 단순한 truncation 의 한계를 드러낸다 — 같은 rank budget 에서도 SST-2 / MNLI 는 LC(r) 가 낮고 ER 이 1 근처에서 흔들리는 반면, AG News / MR 은 LC(r) 가 높고 ER 이 안정적으로 1 에 붙는다. Cross-dataset 으로부터 보면 FC(r) 는 ER 을 거의 설명하지 못하고 (Fig. 6(b), Pearson(ER, FC) 가 $r = 5-15\%$ 에서 음수), LC(r) 와 LC/FC 만 일관되게 0.7 이상의 상관을 보인다.

이 관찰을 그대로 받으면 가설은 자연스럽다: **rank budget 이 같다면, LC(r) 또는 LC/FC 를 더 끌어올리는 방향이 ER 을 직접 끌어올린다.** 핵심 질문은 세 가지 — (i) top- r by λ 가 아니라 LC 또는 LC/FC 를 maximize 하도록 r 개의 eigenvector 를 재선택 하면 ER 이 올라가는가, (ii) 그 류의 prior work 가 존재하는가, (iii) maximizer 를 어떻게 효율적으로 계산하는가. 이 reading copy 는 (i)–(iii) 에 대한 알고리즘 3 개와 4 트랙 prior work mapping 을 요약한다.

§ 2 Theoretical Backing — eq. (9) 가 직접 주는 supervised score

LRFShap 본문 § 5.5 (lrfshap.pdf p.7, eq. (9), 같은 식이 appendix § A p.12 eq. (8)–(9) 에서 재기술) 은 in-sample predictor gap 을 정확한 spectral identity 로 적어둔다:

$$\|f_{\rho}^{\wedge} \text{FNTK}(X_N) - f_{\rho}^{\wedge} \text{LRNTK}(X_N)\|^2 = \sum_{\{i>r\}} (\lambda_i / (\lambda_i + \rho))^2 \cdot (u_i^T Y_N)^2 \leq (1 - \text{LC}(r)) \cdot \|Y_N\|^2$$

오른쪽 $(1 - \text{LC})$ bound 가 paper 가 명시적으로 사용한 형태지만, **진짜 동등식은 왼쪽** 이고 이쪽은 인덱스 집합 $I \subseteq \{1, \dots, n\}$ 의 함수다 (단, basis 는 $K(X_N)$ 의 eigendecomposition 이 미리 고정해 둔 $U \wedge U^T$ 안에 한정 — fixed basis selection only). 따라서 임의의 I 에 대해

$$E(I) := \sum_{\{i \in I\}} s_i, s_i := (\lambda_i / (\lambda_i + \rho))^2 \cdot (u_i^T Y_N)^2$$

를 정의하면, $|I| = r$ budget 하에서 $E(I)$ 의 minimizer 는

$$I^* = \text{top-}r \text{ by } s_i = (\lambda_i / (\lambda_i + \rho))^2 \cdot (u_i^T Y_N)^2$$

이다. LRFShap 이 쓰는 top- r by λ_i 와의 차이는 ρ 의 자리에서 나온다. $\rho \rightarrow \infty$ 면 $(\lambda / (\lambda + \rho))^2$ 가 λ^2 에 비례해 수축하므로 큰 λ 가 그대로 이긴다 — 그래서 top- r by λ 가 ρ 가 클 때 합리적이다. $\rho \rightarrow 0$ 면 필터가 1 로 saturate 하고 $(u_i^T Y)^2$ 만 남아서 score 가 순수 label alignment 가 된다. **LRFShap 은 $\rho = 1e-3$ 같은 작은 값에서 돌리니 후자에 가깝고, supervised selection 의 이득이 가장 클 가능성이 있다.**

수식 단위로 정리하면 — top- r by λ 는 식 (9) 의 상한 $(1 - \text{LC})$ 만 줄이는 반면, supervised top- r 은 equality 인 LHS 자체를 줄인다. 이게 본 plan 의 이론적 anchor 다.

S = N 한정성. 위 식은 전체 학습셋 위의 predictor gap 이라, TMC 가 거치는 임의 subset $S \subset N$ 에서는

$\|f_S^{\wedge} \text{FNTK}(X_S) - f_S^{\wedge} \text{LRNTK}(X_S)\|^2$ 같은 coalition-내부 gap 이 진짜 신경 써야 할 양이다. 본 plan 은 score s_i 를 매 coalition 마다 재계산하지 않고 $K(X_N)$ 에서 한 번 계산한 뒤 모든 permutation 에 동일하게 사용한다 — "S = N 의 minimizer 가 모든 $|S| < n$ coalition 에 대해서도 average-case 로 유의한 개선을 준다" 는 가정을 짚어진다. 이 가정은 식으로 보장되지 않으니 다음 iter 의 실험에서 verify 해야 한다.

§ 3 Algorithmic Proposals (단순 → 정교)

세 알고리즘 모두 LRFShap Algorithm 1 의 line 3-4 (eigendecomp + Φ construction) 만 교체하고 line 5-14 의 TMC loop 는 그대로 둔다. 즉 **preparation 단계에서만 추가 비용**, TMC iteration 안의 cost $O(M(n^2r^2 + nr^3))$ 는 동일.

Algo	Score 사용	Decomp cost	Theory 정당화 강도	Novelty 위치	실패 가능
A1	s_i (full)	$O(n^3)$	eq. (9) exact min	main: p -aware spectral filter	small-data noise overfit
A2	$\alpha_i = (u_i^T Y)^2 / \lambda_i$	$O(n^3)$	§ 5.5 cross-dataset Pearson	ablation: Canatar α_i 를 selection 으로	small- λ degenerate (falsifier #1)
A3	s_i (partial)	$O(\mu n^2)$ flop	eq. (9) + power-law tail bound	main: partial decomp + supervised refinement	spectrum plateau, randomized SVD wall-clock

A1 (Greedy supervised top-r by s_i). Input: full eigendecomp $K = U \Lambda U^T$, labels Y_N , p , budget r , **null-mode floor ϵ (default $\epsilon = 10 \cdot p$)**. Procedure: (1) $c_i := u_i^T Y_N$ (cost $O(n^2C)$). (2) $s_i = (\lambda_i / (\lambda_i + p))^2 \cdot \|c_i\|_{F^2}$ (multi-class Frobenius extension, § 5.5 binary 정의의 자연스러운 일반화). (3) $\lambda_i < \epsilon$ 인 인덱스 제외 — $p \rightarrow 0$ 한계에서 $(\lambda / (\lambda + p))^2$ 가 1 로 saturate 되어 null direction 이 selection 에 들어와 ridge solve 의 conditioning 을 망가뜨리는 것을 방지. (4) $I^* :=$ top- r of surviving s_i . (5) Φ_{tr}, Φ_{te} 빌드 → Algorithm 1.

A2 (α_i ablation). $r_i = (u_i^T Y)^2 / (\lambda_i \|Y\|^2)$ 는 Canatar–Bordelon–Pehlevan 2021 [B9] 의 task-model alignment $\alpha_i = (u_i^T Y)^2 / \lambda_i$ 와 같은 양. A2 의 실질적 contribution 은 " α_i 를 LRFShap 의 selection criterion 으로 옮긴 것" 이라 novelty 가 제한적이고, 본 plan 은 **A1 ↔ A2 분리 ablation** 으로만 사용한다. 분모의 λ_i 가 small- λ degenerate mode (falsifier #1) 를 1순위로 끌어올리는 약점이 있다.

A3 (Partial decomp + supervised refinement). A1 의 약점은 full $O(n^3)$ eigendecomp 를 전제로 한다는 것. $n = 10000$ (lrfshap § 5.4 의 SST-2/MNLI Pareto 실험 영역) 에서 의미 있는 비용이다. A3 는 **top-2r by λ 까지만 partial Lanczos / randomized SVD 로 뽑은 뒤 (Halko–Martinsson–Tropp 2011 [B13]), 그 안에서 supervised top-r 을 재선택**. Cost: preparation $O(\mu n^2 + \mu^2 r^2 n)$ — $\mu = 2$, $r = 0.1n$ 이면 $\approx 0.24n^3$ 로 flop 기준 약 $4 \times$ 빠름. 다만 GPU 위 wall-clock 은 dense eigh 가 매우 잘 최적화돼 있어 randomized 방식이 항상 빠르다고 단정할 수 없으니, crossover 는 다음 iter 실험에서 직접 측정. Truncation error 분석 — λ 가 power-law decay (lrfshap Remark E.3, p.21: $\lambda_j \leq C \cdot j^{-\alpha}$) 하면 $i > \mu r$ 의 supervised score mass 는 $(\mu r + 1)^{-2\alpha}$ 로 빠르게 떨어져 충분히 작다.

§ 4 Related Work Mapping (4 트랙)

Track A — kernel-side leverage scores (label-agnostic). Alaoui–Mahoney 2015 [B3] 의 ridge leverage $\ell_i(p) = [K(K+pI)^{-1}]_{ii}$, Bach 2013 [B4] 의 effective dimension $d_{\text{eff}}(p) = \sum \lambda_i / (\lambda_i + p)$. **우리 A1–A3 와 차이 — supervised refinement of ridge leverage:** ridge leverage 의 mode-wise 형태는 $\lambda_i / (\lambda_i + p)$ 로, 우리 score 와

$$s_i = (\lambda_i / (\lambda_i + p))^2 \cdot (u_i^T Y)^2 = (\text{mode-}i \text{ ridge leverage})^2 \cdot (u_i^T Y)^2$$

로 깔끔하게 factorize 된다. 즉 **본 plan 의 핵심은 "ridge leverage score 의 supervised refinement"** — leverage 가 column sampling 에 쓰는 label-agnostic 가중을, 우리는 label-aligned term 과 곱해 eigenvector selection 에 쓴다 (critique R1 § 1 의 framing).

Track B — kernel-target alignment. Cristianini et al. 2001 [B5] 의 KTA, Cortes–Mohri–Rostamizadeh 2012 [B6] 의 centered KTA. **차이:** KTA 는 kernel 자체 를 ($Y Y^T$ 와 align 되도록) 재구성. A1–A3 는 kernel 은 고

정하고 그 spectral basis 안에서 coordinate selection. Wang et al. AAAI 2014 / Neurocomputing 2016 [B7, B8] 의 label-aware base kernels 는 ideal kernel eigenfunction 을 unlabeled data 위로 extrapolate 해 새 base kernel 을 만드는 방향 — 우리와 정반대 (kernel 고정 vs kernel 재구성).

Track C — eigenlearning / spectrum-dependent generalization. Canatar–Bordelon–Pehlevan 2021 (Nature Comm) [B9] 가 task-model alignment α_i 와 mode-wise learnability 도입, lrfshap § 5.5 가 이미 인용. Simon–Dickens–Karkada–DeWeese TMLR 2023 [B10] 이 후속 — KRR generalization 의 closed-form 이 정확히 mode-별 $(\lambda_i/(\lambda_i+\rho))^2 \cdot (u_i^T y)^2$ 항의 합. **즉 우리 score s_i 가 eigenlearning framework 의 mode-wise generalization contribution 과 본질적으로 같은 양.** 차이: 이 라인은 generalization 분석 도구이지, low-rank Shapley 안의 budget r 에서 어떤 mode 를 keep 할지를 다루지 않는다. A2 는 α_i 를 selection 으로 옮긴 것이라 novelty 제한적이고, A1 (s_i 가 ρ -aware), A3 (partial decomp 로 cost 까지 잡음) 가 본 plan 의 main contribution.

Track D — data Shapley + low-rank / influence-based attribution. FreeShap [B1] 이 baseline. TRAK [B11] 은 random projection + ensembling 으로 kernel spectrum 을 직접 쓰지 않음. DataInf [B12] 는 LoRA Hessian 의 closed-form inverse — Shapley 가 아니고 influence function 계열. **차이:** A1–A3 는 LRFShap 안 의 low-rank basis 선택 자체를 supervise 하는 직교적 contribution, prior work 에 직접 선례 없음.

§ 5 Verification Plan (다음 iter 의 실험 설계)

본 plan 이 짚어진 검증 항목 네 가지 — 다음 iter 의 executor obligatory 실험.

(V1) ER 향상의 cross-dataset 측정. SST-2 / MNLI (LC 가 낮은 dataset)

- AG News (LC 가 높아 saturated 인 baseline) 세 개로 ER vs r 곡선을 A1 / A3 / top- r -by- λ (LRFShap 원본) 비교. 가설: SST-2 / MNLI 에서 A1, A3 가 baseline 을 일관되게 위로 올리고, AG News 에서는 saturated 라 격차가 작다.

(V2) $S = N \rightarrow S \subseteq N$ transfer 가정 검증. Synthetic spectrum 에서 $|S| = 0.1n, 0.3n, 0.7n, n$ 별로 supervised vs unsupervised selection 의 ER gap 측정. $K(X_N)$ 의 score 가 작은 $|S|$ 까지도 transfer 되는지 확인.

(V3) Falsifier #1 — degenerate small- λ mode 분리 실험. Synthetic spectrum (power-law + 인위적 tail spike) 에서 A1, A2, top- r -by- λ 의 ER 측정. tail spike 가 강해질수록 A2 의 ER 만 baseline 아래로 떨어지면 A1 $\leftrightarrow$ A2 가 분리됨을 confirm. 동시에 A1 의 ϵ floor sensitivity 도 $\epsilon \in \{\rho, 10\rho, 100\rho\}$ grid 로 측정.

(V4) Falsifier #2 — label noise 시나리오. SST-2 의 train label 5–20% random flip + control (flip rate = 0%) 로 A1 vs top- r -by- λ 의 ER 비교. 가설: lrfshap Fig. 2 (p.6) 의 SST-2 1% selection 에서 LRFShap 이 baseline 을 초과 한 것이 implicit denoiser 효과였다면, supervised selection 은 그 효과를 잃는다 (flip rate 가 높을수록 A1 의 ER 이 baseline 아래로 떨어지면 partial confirm).

추가로, A3 의 randomized SVD wall-clock crossover 측정 ($n = 1000, 2000, 5000, 10000$ + GPU dense eig의 비교) 과, Prop 4.2 (lrfshap p.5) 의 원문 norm (operator vs nuclear) 한 줄 인용 — 이 두 가지는 다음 iter 의 reading 단계에서 보강.

남은 risk (critique R2 final sign-off 발체)

- A3 의 partial decomp truncation error 분석에 $(u_i^T y)^2$ 의 spectrum 위 분포 가정이 추가로 필요 (label 이 high-frequency mode 와 align 된 adversarial case 에서 prefactor 가 $\|Y\|^2$ 와 비례해 커질 가능성).
- § 6 falsifier #2 의 flip rate 5–20% 가 SST-2 baseline (~91%) 를 흔들 수 있으니 control = 0% 를 같은 plot 에 포함 권장.

두 항목 모두 plan_v2 본문 수정 없이 다음 iter 의 reading / 실험 설계 시 한 줄씩 보강하면 충분. 본 reading copy 의 결론에 영향 없음.

Iteration 01 — Bibliography

이번 iter 에서 인용된 모든 외부 자료. URL + 1줄 요약.

Primary references (이미 references/ 에 있음)

[B1] Wang et al. 2024a (FreeShap, ICML 2024), baseline 논문. [references/Freeshap.pdf](#). eNTK 기반 retraining-free Shapley value approximation. LRFShap 의 직접 baseline.

[B2] LRFShap (저자 미공개, ICML 2026 workshop submission), 우리 논문. [references/lrfshap.pdf](#). FreeShap 의 ridge inverse 를 $K(X_N)$ 의 best rank- r eigendecomposition 으로 가속. 핵심 LC/FC 분석 § 5.5 (p.7-8).

Track A — kernel-side leverage scores (label-agnostic)

[B3] Alaoui & Mahoney, NeurIPS 2015, Fast Randomized Kernel Methods with Statistical Guarantees. <https://arxiv.org/abs/1411.0306> Ridge leverage score $\ell_i(\rho) = [K(K+\rho I)^{-1}]_{ii}$ 를 Nyström sub-sampling 의 sharp 가중으로 사용.

[B4] Bach, JMLR 2013, Sharp analysis of low-rank kernel matrix approximations. <http://proceedings.mlr.press/v30/Bach13.pdf> Effective dimension $d_{\text{eff}}(\rho) = \text{tr}(K(K+\rho I)^{-1}) = \sum \lambda_i / (\lambda_i + \rho)$ 를 통한 rank- r approximation 의 sharp 분석.

Track B — kernel-target alignment

[B5] Cristianini, Shawe-Taylor, Elisseeff, Kandola, NeurIPS 2001, On Kernel-Target Alignment. <http://papers.neurips.cc/paper/1946> $\text{KTA}(K, yy^T) = \langle K, yy^T \rangle_F / (\|K\|_F \cdot \|yy^T\|_F)$. 본 라인의 시조.

[B6] Cortes, Mohri, Rostamizadeh, JMLR 2012, Algorithms for Learning Kernels Based on Centered Alignment. <https://www.jmlr.org/papers/v13/cortes12a.html> Centered KTA 로 multiple kernel 의 가중 을 학습.

[B7] Wang, Q., Zhang, K., Chen, Z., Wang, D., Jiang, G., Marsic, I., AAAI 2014, Improving Semi-Supervised Target Alignment via Label-Aware Base Kernels. <https://ojs.aaai.org/index.php/AAAI/article/view/8958> Label 정보를 주입해 새로운 base kernel 의 eigenfunction 을 extrapolation. v1 의 "Liu et al." 표기는 오기 (critique R1 § 1 정정).

[B8] Wang, Q. et al., Neurocomputing 2016, Enhancing semi-supervised learning through label-aware base kernels. <https://www.sciencedirect.com/science/article/abs/pii/S0925231215010796> [B7] 의 후속.

Track C — eigenlearning / spectrum-dependent generalization

[B9] Canatar, Bordelon, Pehlevan, Nature Comm 2021, Spectral Bias and Task-Model Alignment Explain Generalization in Kernel Regression and Infinitely Wide Neural Networks. <https://www.nature.com/articles/s41467-021-23103-1> (arXiv: <https://arxiv.org/abs/2006.13198>) task-model alignment $\alpha_i := (u_i^T Y)^2 / \lambda_i$. lrfshap § 5.5 가 이미 인용. 본 plan 의 A2 가 α_i 를 selection criterion 으로 옮긴 것.

[B10] Simon, Dickens, Karkada, DeWeese, TMLR 2023, The Eigenlearning Framework: A Conservation Law Perspective on Kernel Regression and Wide Neural Networks. arXiv: <https://arxiv.org/abs/2110.03922>, OpenReview: <https://openreview.net/forum?id=FDbQGCAVil> KRR

generalization 의 closed-form 이 정확히 mode-별 $(\lambda_i/(\lambda_i+\rho))^2 \cdot (u_i^\top y)^2$ 항의 합 — 우리 score s_i 와 본질적으로 같은 양. v1 의 "Nature Comm 2023" 표기는 오기 (critique R1 § 2 정정).

Track D — data Shapley + low-rank / influence-based attribution

[B11] **Park, Georgiev, Ilyas, Leclerc, Madry, ICML 2023 (TRAK)**, Attributing Model Behavior at Scale. <https://arxiv.org/abs/2303.14186> Random projection + ensembling 으로 attribution. kernel spectrum 직접 사용 안 함.

[B12] **Kwon, Wu, Wang, Mohri, ICLR 2024 (DataInf)**, Efficiently Estimating Data Influence Functions. <https://arxiv.org/abs/2310.00902> LoRA Hessian 의 closed-form inverse. influence function 계열 (Shapley 아님).

Numerical / spectral methods

[B13] **Halko, Martinsson, Tropp, SIAM Review 2011**, Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions. <https://arxiv.org/abs/0909.4061> Randomized SVD 의 표준 reference. A3 의 partial decomp 에 사용.

[B14] **Cortes, Mohri, Talwalkar, AISTATS 2010**, On the Impact of Kernel Approximation on Learning Accuracy. <https://proceedings.mlr.press/v9/cortes10a.html> Kernel approximation 의 predictor gap 이 prediction accuracy 에 미치는 영향. lrfshap Prop 4.2 의 원조 형태.