

Iteration 02 — FC vs LC Orthogonal Framework for A1 vs LRFShap

Reading copy, 5 페이지. plan_v2 + critique_v2 의 핵심 발췌.

§ 1 Motivation & Restated Question

iter 01 의 7 dataset head-to-head 측정 — A1 vs LRFShap, 동일 (rank, sel%) 평가측에서 inv prediction 으로 — 의 win 패턴이 극단적으로 갈렸습니다.

Dataset	n	C	wins/42 cells
MNLI	2000	3	42/42
MRPC	2000	2	35/42
AG News	2000	4	17/42
SST-2	2000	2	8/42
QQP	2000	2	7/42
MR	2000	2	4/42
RTE	2490	2	4/42

iter 01 은 archetype 분류 (multi-class 우세, kernel-task fit 차이 등) 의 현상학적 서술에 머물렀습니다. 본 iter 의 목표는 이 win 패턴을 **FC (kernel norm) axis** 와 **LC (label energy) axis** 의 직교성 관점에서 식 단위로 설명 하는 것. 실험은 없고 precomputed.json 의 수치만으로 분석.

§ 2 FC vs LC Orthogonal Framework

정의

정렬된 eigendecomposition $K = \sum_i \lambda_i u_i u_i^T$ ($\lambda_1 \geq \lambda_2 \geq \dots$), label projection $c_i^2 := \|u_i^T Y\|_{\text{centered}}^2$ (Y 는 centered C-class one-hot), $\rho = \text{ridge}$.

FC(I) := $\sum_{i \in I} \lambda_i / \sum_j \lambda_j$ — kernel Frobenius energy 의 retain ratio **LC(I) := $\sum_{i \in I} c_i^2 / \sum_j c_j^2$** — label energy 의 retain ratio

두 selection 의 objective:

- **top-r (= LRFShap I_LR)**: $I_{LR} = \arg\max_{\{|I|=r\}} \sum_{i \in I} \lambda_i \rightarrow K$ 의 best rank-r Frobenius approximation. c_i^2 안 들어감 (label-blind).
- **A1 score $s_i = f(\lambda_i) \cdot c_i^2$, $f(\lambda) = (\lambda/(\lambda+\rho))^2$** : $\lambda \gg \rho$ 영역에서 $f \approx 1 \rightarrow I_{A1} \approx \arg\max_{\{|I|=r\}} \sum_{i \in I} c_i^2$ (pure LC selection).

A1 $\approx$ LC 의 정확한 조건

단순 " $\lambda \gg \rho$ " 는 충분조건의 절반. 정확한 조건은 $I_{A1} = I_{LC}$ 이려면 $\forall i \in I_{LC}, \forall j \notin I_{LC}$:

$$c_j^2 / c_i^2 < f(\lambda_i) / f(\lambda_j)$$

즉 filter ratio 의 dynamic range 가 c_i^2 ratio 를 dominate 해야 함. precomputed.json 의 $\text{frac}(\lambda_i > 10\rho) \geq 0.999$ 가 모든 dataset 에서 성립하지만, RTE 만 $\lambda_{\min} = 0$ mode 가 일부 존재해 $f(\lambda) = 0$ 으로 정확히 떨어지는 영역이 있고 — 이 경우 c_i^2 가 아무리 커도 A1 이 원리적으로 선택 못 함. RTE 가 framework 의 partial 예외 (edge case).

두 selection 이 놓치는 정보

- **top-r 이 놓친 label energy:** $\text{miss_LC_by_LR} := 1 - \text{LC}(I_{\text{LR}}) = \sum_{\{i \notin I_{\text{LR}}\}} c_i^2 / \sum_i c_i^2$
- **A1 이 놓친 kernel energy:** $\text{miss_FC_by_A1} := 1 - \text{FC}(I_{\text{A1}}) = \sum_{\{i \notin I_{\text{A1}}\}} \lambda_i / \sum_i \lambda_i$

LRfShap eq. (9) (lrfshap.pdf p.7) 의 Shapley estimation error bound 는 $\sum_{\{i \notin I\}} (\lambda_i / (\lambda_i + \rho))^2 \cdot c_i^2$ 형태 — 위 두 양의 product 의 정확한 합. 즉 본 framework 의 두 양은 eq. (9) bound 의 axis-decomposition 임.

Axis 직교성과 selection 결과의 직교성

Axis (FC, LC) 자체는 정의상 독립적 — FC 는 K 만, LC 는 (K, Y) joint 만 봄. Selection 결과 의 직교성은 spectrum-label joint distribution 의 Spearman(λ, c^2) 으로 정량. Spearman = 0 → 두 ranking 독립 → 기대 overlap = r/n . Spearman = 1 → 두 ranking 일치 → overlap = 1.

§ 3 Empirical Evidence

7 dataset 의 핵심 수치 (r=10%)

Dataset	$\lambda_{\text{max}} / \lambda_{\text{med}}$	$\text{frac}(\lambda > 10\rho)$	Spearman(λ, c^2)	overlap	FC_LR	LC_LR	FC_A1	LC_A1	wins/42
MNLI	5093	1.000	0.226	0.325	0.822	0.271	0.271	0.410	42
MRPC	5492	1.000	0.114	0.260	0.819	0.280	0.188	0.532	35
AG News	10092	1.000	0.377	0.510	0.873	0.747	0.292	0.778	17
SST-2	4564	1.000	0.193	0.325	0.814	0.566	0.323	0.704	8
QQP	25716	1.000	0.104	0.290	0.930	0.345	0.124	0.549	7
RTE	6924	0.999	0.098	0.241	0.821	0.206	0.139	0.470	4
MR	11876	1.000	0.150	0.310	0.898	0.516	0.303	0.662	4

핵심 관찰: 모든 dataset 에서 **LC_A1 > LC_LR** 이고 **FC_LR > FC_A1** — A1 은 label energy 를 2 배 가까이 잘 잡고, LR 은 kernel energy 를 4 배 가까이 잘 잡음. 두 selection 의 trade-off 정량 확인.

5 후보 척도 vs empirical_wins 의 rank correlation

척도	가설	r=10% Spearman ρ	r=20% Spearman ρ
A: miss_LC_by_LR	클수록 A1 가치	+0.01	+0.13
B: miss_FC_by_A1	클수록 LR 가치	+0.08	-0.13
C: Spearman(λ, c^2)	클수록 두 axis aligned	+0.60	+0.60
D: eq9_gap_A1/LR	작을수록 A1 bound 좋음	-0.19	+0.02
E: overlap_LR_A1	클수록 두 방법 일치	+0.45	+0.43

C 가 best predictor — r 변경에 robust (r=10%, r=20% 양쪽 +0.60), ranking 의 qualitative order $C > E > D$, A, B 가 모든 robustness check 에서 유지.

Statistical caveat (n=7)

Spearman $\rho = +0.60$ 의 양측 p-value 는 n=7 에서 ≈ 0.15 , Fisher CI $\approx (-0.20, +0.92)$. 단일 dataset leverage 가 큼:

LOO 제외	Spearman(C, wins)
전체	+0.598
MNLI 제외	+0.471
RTE 제외	+0.429
AG News 제외	+0.643

→ paper framing 은 "C 가 후보 5 개 중 가장 강한 정성적 predictor 이고 r-robust" 의 정성 ranking 수준 에서 멈춰야 하고, "0.60" 의 정량을 single number 로 강조하지 말 것.

가장 중요한 보정 — Prediction-side vs Shapley-side 분리

iter 01 setup: A1 으로 Shapley 추정 → top-x% sample 선택 → full kernel (rank-r 아닌 K 전체) prediction → accuracy. LRFShap 도 동일하게 full kernel prediction. 두 단계 분해:

- **(a) Shapley-side:** 어떤 sample 이 골라졌나. A1 의 s_i ranking vs LRFShap 의 rank-r approximation Shapley.
- **(b) Prediction-side:** 그 subset 이 full kernel ridge 에서 얼마나 generalizable 한가.

본 framework 의 miss_LC, miss_FC, eq9_gap, overlap 은 **모두 (a) Shapley-side 양**. 그러나 empirical wins 는 (a) + (b). 두 사이의 mapping 은 monotone 보장 안 됨.

이 분리가 두 관찰을 명료히 해석해 줌:

1. **후보 A (miss_LC_by_LR) 가 wins 와 $\rho \approx 0$** — framework 결함이 아니라 negative result. "Shapley-side 의 절대 miss 양은 prediction-side accuracy 의 직접 결정 요인이 아님."
2. **후보 C (Spearman(λ, c^2)) 가 best predictor** — framework 가 우연히 prediction-side proxy 를 포함. Bordelon-Canatar 의 task-model alignment 이론 [B-BCP21] 에 따르면 prediction-side generalization 의 핵심 결정 요인이 spectrum-label alignment. C 가 (a) + (b) 모두에 작용하는 dataset-level 양.

Framework scope 명시: 본 iter 의 framework 는 Shapley-side selection geometry 의 식 단위 정리. (b) prediction-side 의 full-kernel ridge generalization 은 직접 설명 안 함 — task-model alignment 이론과 bridge 가 필요.

§ 4 Mechanism — 왜 Spearman(λ, c^2) 가 Best?

Spearman(λ, c^2) 가 클 때 두 사건이 동시 발생:

첫째 (Shapley-side): A1 selection 이 "안전하게" 큰 c_i^2 를 골라냄. Pure LC selection 의 estimation variance 는 small- λ noise mode 에서 큰데, λ - c^2 alignment 가 높으면 top- c_i^2 mode 의 λ 도 크기 때문에 A1 score s_i ranking 이 안정적.

둘째 (prediction-side, Bordelon-Canatar eigenlearning curve): generalization error = $\sum_i c_i^2 \cdot (1 - \text{learnability}_i)^2$ 형태로 분해, learnability_i 는 λ_i 의 monotone 함수. high- c_i^2 mode 가 high- λ region 에 몰려 있으면 full kernel ridge 의 generalization 이 효율적이고, A1 의 LC-biased selection 이 그 generalizable mode 의 sample 을 더 잘 representative 하게 골라줌.

iter 01 Archetype 과의 매핑

Archetype	Spearman(λ, c^2) 위치	Mechanism
MNLI (42/42), AG News (17/42)	상대 rank 상위 (0.226, 0.377)	multi-class → label energy 가 여러 mode 에 분산되지만 embedding sub-cluster 가 top eigenvector 와 align
MRPC (35/42)	낮음 (0.114) 인데도 wins 높음	절대값 낮지만 c_i^2 가 특정 minority-detection mode 에 집중되어 A1 의 LC selection 이 그 mode 를 정확히 catch (PR(c^2) 작음 → § 5 참조)

Archetype	Spearman(λ, c^2) 위치	Mechanism
RTE, MR, QQP ($\leq 7/42$)	최하위 (0.10 근처) + Shapley-side 의 prediction-side ineffectiveness	low alignment $\rightarrow$ kernel ridge generalization 자체가 비효율, A1 의 Shapley-side advantage 가 prediction 단계에서 사라짐

RTE vs MRPC Paradox

둘 다 miss_LC_by_LR 큰데 (0.794, 0.720) wins 가 천차만별 (4 vs 35). Shapley-side 절대 miss 로는 설명 불가능.

가설: **높은 label energy 가 prediction-side 에서 learnable signal 인지 unlearnable noise 인지**. RTE 는 c_i^2 가 거의 uniform 하게 1000+ mode 에 흩어진 effective high-rank (noise) 케이스. MRPC 는 c_i^2 가 200-500 mode 에 집중된 low-effective-rank (signal) 케이스. 측정 proxy: c_i^2 의 participation ratio $PR(c^2) = (\sum c_i^2)^2 / \sum c_i^4$. precomputed.json 에는 없어 next iter 에서 측정.

§ 5 Implications and Next Steps

Paper framing 권고

1. A1 의 selection 은 거의 모든 dataset 에서 pure LC selection 의 근사. RTE 만 partial 예외 ($\lambda_{\min} = 0$ mode 의 filter cut). "Universal" 이 아니라 **"near-universal, with RTE as edge case"**.
2. Shapley-side 의 높은 정보 절대량 (miss_LC, miss_FC) 은 empirical wins 를 거의 예측 못 함 ($\rho \approx 0$). 이는 Shapley-side vs prediction-side 분리의 직접 증거.
3. **Spectrum-label alignment Spearman(λ, c^2) 가 best predictor** — Bordelon-Canatar task-model alignment 이론과 직접 연결. paper 본문에서는 정성 ranking 으로 framing.
4. RTE-MRPC paradox 는 c_i^2 분포의 shape ($PR(c^2)$) 양으로 풀 수 있을 것 — next iter 의 첫 항목.

Next Iter Obligatory Items

- **Falsifier 1 — synthetic spectrum-label decoupling.** 동일 K, 인위 Y 생성. aligned ($w_i \propto \sqrt{\lambda_i}$) vs anti-aligned ($w_i \propto 1/\sqrt{\lambda_i}$) 에서 wins matrix 비교. Framework 가 옳다면 aligned ≈ 42 , anti-aligned ≈ 4 .
- **Falsifier 2 — Spearman range 확장.** CoLA 추가 또는 같은 7 dataset 에서 $n \in \{500, 1k, 2k, 4k\}$ 변화로 leverage 분산.
- **보조 — $PR(c^2)$ 와 effective LC dimension.** RTE vs MRPC paradox 정량 해명.
- **보조 — A1 modified version.** λ filter 끄고 pure c_i^2 baseline (= I_LC) 과 A1 의 실증 비교. RTE 의 bottom mode 에서 갈리는지 직접 검증.

한계 (남은 risk)

본 iter PDF 의 source 로는 충분 (critic R2 sign-off). 단 (i) Spearman(λ, c^2) 가설의 synthetic falsifier 미실행, (ii) RTE 의 $|I_{A1} \cap I_{LC}|/r$ 직접 측정 부재 — 둘 다 next iter 실험으로만 해소 가능. paper draft 단계 시 next-iter 결과 기다리는 게 안전.

Iteration 02 — Bibliography

iter 01 의 bibliography 위에 iter 02 에서 새로 핵심으로 자리잡은 두 reference 만 명시 추가. 나머지 4 트랙 (ridge leverage, KTA, eigenlearning 보조, data Shapley) 의 reference 는 iter 01 의 bibliography.md 그대로 유효.

iter 02 에서 핵심으로 자리잡은 reference

[B-BCP21] **Bordelon, Canatar, Pehlevan (2021)** Spectral bias and task-model alignment explain generalization in kernel regression and infinitely wide neural networks. **Nature Communications** 12:2914. <https://www.nature.com/articles/s41467-021-23103-1> iter 02 의 가장 핵심 reference. § 3.5 의 prediction-side vs Shapley-side 분리 와 § 4 mechanism 의 task-model alignment 해석 모두 이 paper 의 framework 위에 서있음. Spearman(λ_i , c_i^2) 가 best predictor 인 이유 — kernel ridge generalization 의 learnability 가 (λ , c^2) joint distribution 의 함수라는 정량 결과 — 가 [B-BCP21] 의 main theorem.

[B-Simon23] **Simon, Dickens, Karkada, DeWeese (2023)** The Eigenlearning Framework: A Conservation Law Perspective on Kernel Ridge Regression. **TMLR** 2023. arXiv:2110.03922. <https://openreview.net/forum?id=FDbQGCAViI> (blog 요약: <https://jamiesimon.io/blog/eigenlearning/>) learnability score 의 zero-sum (Σ over modes = n) 분해 — 본 iter 의 LC retention $LC(I_LR)$, $LC(I_A1)$ 와 dual 관계. 동일 양을 두 시각 (selection-side vs generalization-side) 에서 보는 것이 iter 02 의 핵심.

[B-LRFShap25] **LRFShap** (저자 미공개, ICML 2026 workshop submission), [references/lrfshap.pdf](#). eq. (9) 의 정확한 인용은 p. 7 의 in-sample predictor gap identity. iter 02 의 $miss_LC_by_LR$, $miss_FC_by_A1$, $eq9_gap$ 정의가 모두 이 식 위에 정의됨.

iter 01 의 reference (재인용 없이 reference 만)

iter 01 의 4 트랙 — ridge leverage (Alaoui-Mahoney 2015, Bach 2013), kernel-target alignment (Cristianini 2002, Cortes-Mohri-Rostamizadeh 2012, Wang AAAI 2014 / Neurocomputing 2016), eigenlearning (Canatar 2021, Simon 2023), data Shapley + low-rank (FreeShap 2024, TRAK 2023, DataInf 2024) — 의 reference 들은 [state/iteration_01/bibliography.md](#) 그대로 유효. iter 02 의 식 / framework 는 이 4 트랙 위에 Shapley-side geometry layer 를 한 단계 더 얹은 것.