

Iteration 04 Report (Full Archive)

Auto-generated by `scripts/make_report.py` 4. Includes every round (v1/v2/v3) plus bibliography, next directions, results, and figures.

1. Research Plan (v1)

Iteration 04 (재정의, v2 — critic 반영) — Plan: collapse mechanism 의 정량 분석

이 plan 의 목표는 추가 학습 실험을 시작하는 것이 아니라, 이미 모인 7-dataset × valbal/trainbal × 21+15 의 sidecar 더미와 동일 폴더의 NTK gram cache (`imbalance_ntk/ <ds>/<tag>/bert_seed2026_num<N>_<val_tag>_signFalse.pkl`) 를 사후 *mechanism* 분석 하여, 두 핵심 발견 — (A) valbal 에서 A1 이 FreeShap / LR collapse 를 균일하게 회복, (B) trainbal 에서 A1 이 balanced acc 로는 압도하지만 절반 case 에서 random 에 패배 — 의 원인 을 lens 1-4 로 분리하는 것입니다. 사용자 지시 (`state/directives/ 20260603_iter04.md`) 의 (Q1) train ↔ val 의 imbalance 위치가 왜 collapse 양상을 바꾸는지, (Q2) A1 이 정확히 어떤 quantity 를 회복하는지, (Q3) trainbal 에서 A1 이 random 한테 지는 case 의 predictive metric 이 무엇인지를 — 각 lens 가 1 개씩 잡도록 설계했고, iter_03 의 7-quantity / Cond 1-3 framework (`state/iteration_03/report.md` 의 §3, §4) 와 명시적으로 mapping 합니다.

본 v2 plan 은 첫 plan 에 대한 자체 critique (`state/iteration_04/critique.md`) 의 30 개 수정사항 (필수 20 + 권장 8 + 선택 2) 을 반영한 결과입니다. 핵심 변경 — Nyström extension 식의 $\sqrt{n}$ factor 복원 (§3.2(2)), KL 방향 통일 (§2.2(1)), BBSE confusion matrix 의 joint vs conditional 표기 정정 (§2.2(3)), H1-H4 의 통계 절차를 setting 단위 Pearson + cell 단위 mixed model + multiple-testing 보정의 3-tier 로 확장 (§3.3), lens 1 script spec 신설 (§2.5), 2 번째 라운드 critique 가 받을 minimum output set 명시 (§8). 첫 plan 의 5-단계 backbone (데이터 통합 → lens 1 → lens 2 → lens 3 brief → lens 4 brief → 종합) 은 유지합니다.

전체는 5 단계로 묶입니다. §1 은 데이터 통합 (모든 sidecar → grand long-format CSV) + NTK pickle schema 의 사전 확인, §2 는 lens 1 (label shift / BBSE / weighted risk) + script spec, §3 은 lens 2 (spectral target alignment, KTA, train- $\tilde{Y}$ vs val- $\tilde{Y}$ alignment gap), §4 는 lens 3 (effective dimension $d_{\text{eff}}(\rho)$) 의 brief 보강, §5 는 lens 4 (Shapley value variance) 의 brief 진단입니다. §6 가 종합 + iter_03 framework 와의 mapping, §7 이 next_directions 의 윤곽, §8 이 산출물 체크리스트 와 2-라운드 critique 의 minimum input set. lens 1-2 는 깊게, lens 3-4 는 brief.

서두에 두 가지 제약 을 못 박습니다. 첫째, **dataset-specific 분석 금지** — 모든 주장은 7-dataset 의 cross-dataset correlation 또는 group-level statistic 위에서만 정당화하고, "AG News 는 cls85 에 서..." 식의 single-cell anecdote 는 supporting evidence 로만 허용. 둘째, **추가 실험 launch 금지** — 새 ratio, 새 dataset, 새 NTK 계산 모두 차단. 기존 NTK pickle 의 eigendecomposition 과 기존 sidecar 의 acc 시퀀스만 사용. 분석 스크립트가 GPU 를 쓸 일은 NTK eigen (numpy/SciPy 의 CPU eigh) 뿐이라 GPU contention 도 없습니다.

§1. 데이터 통합 — grand long-format dataframe + NTK schema 사전 확인

분석 전반의 토대가 되는 단일 CSV (`state/iteration_04/grand_df.csv`) 와 setting-level metadata (`state/iteration_04/grand_meta.csv`) 를 만듭니다. sidecar 더미가 두 갈래 setup (valbal 21

settings: train imbalanced + val balanced; trainbal 18 settings: train balanced + val imbalanced) 으로 나뉘어 있고 각 setting 안에 (method $\in$ {FreeShap=inv, LR top-r=lrfschap+eigen, A1 top-r=a1+eigen}) $\times$ (r $\in$ {1, 5, 10, 15, 20, 25, 30}%) $\times$ (sel $\in$ 1..100) 의 acc 시퀀스가 들어 있어, 정합 분석을 위해서는 *long format* — 한 row = (dataset, regime, ratio_tag, method, rank_pct, sel) 의 unique cell — 으로 풀어두는 것이 필수입니다.

사전 sanity check — NTK pickle schema 의 인덱싱 (수정사항 7, 18). lens 2 의 val-side projection 가능 여부 자체가 NTK pickle 에 $K_{\{\text{train, val}\}}$ block 이 있는지에 의존하므로, build script 의 첫 단계 로 임의 pickle 한 개의 schema 를 출력해 인덱싱합니다. 구체적으로 — sst2 의 pos70 / bert_seed2026_num5000_valbal856_signFalse.pkl 한 개를 열어 `bundle.keys()` 와 각 value 의 (type, shape, dtype) 를 출력하고, 결과를 `state/iteration_04/ntk_schema.md` 에 기록. 가장 critical 한 점검은 `bundle["ntk"].shape == (n + n_val, n + n_val)` 의 full gram 여부입니다 (sst2 의 경우 expected shape (5856, 5856)). 만약 train-only (n, n) 면 lens 2 의 val-projection 식 (§3.2(2)) 자체를 제거; *proxy fallback* 사용 금지 — proxy 를 쓰면 Nyström extension 의 수학적 의미가 깨져 H3, H4 의 falsifier 가 무력화됩니다.

FreeShap codebase 의 `compute_ntk` 함수 (상위 repo `../../freeshap/`) 를 직접 확인해 schema 를 plan 단계에서 못 박는 것이 가능하지만, plan 분량 절약을 위해 build script 첫 단계의 sanity check 로 대체. `ntk_schema.md` 의 산출이 plan 의 §2-§3 의 수식이 유효한지의 전제조건 임을 명시.

p (eigen_lambda) 의 cross-sidecar 일관성 (수정사항 29). sidecar 의 `eigen_lambda` field 가 모든 setting 에서 동일 값 (10^{-2}) 인지, 아니면 method/setting 별로 다른지를 build script 에서 출력. 만약 다르면 §3.2(3) 의 mode-wise learnability score s_i 의 p 가 cell 별로 달라져 cross-cell 비교의 일관성이 깨지므로, p -그룹 별 separate 분석이 필요. 다행히 sidecar 의 표준 default 가 $p=10^{-2}$ 라 거의 일관할 expect, 하지만 이 가정의 명시적 검증이 분석 전 에 필요.

스크립트 spec — experiments/build_grand_df.py.

입력: 두 root — `data_selection_test/imbalance/data_selection/` (sidecar 의 부모), `imbalance_ntk/` (NTK pickle 의 부모). 두 root 의 디렉토리 트리를 walk 하면서 sidecar JSON 의 metadata (dataset_name, class_ratios, ratio_tag, method, seed, num_train_dp, val_sample_num, setting_name, approximate, eigen_rank_pct, eigen_lambda, random_seed_used if present) 와 acc 4-tuple (top_results_<inv| eigen>, random_results_<inv|eigen>, top_results_<inv|eigen>_balanced, random_results_<inv|eigen>_balanced) 를 추출.

출력 CSV `grand_df.csv` 의 column schema (한 row = (setting $\times$ method $\times$ rank_pct $\times$ sel)):

column	정의
dataset	sst2 / mr / mrpc / qq / rte / mnli / ag_news
regime	"valbal" / "trainbal" / "single"
train_ratio_tag	sidecar 의 ratio_tag (예: pos70 , cls60_20_20)
val_ratio_tag	setting_name 에서 파싱 (valbalN 또는 valimbN_pos<XX> / valimbN_cls<...>)
imbalance_level	"mild" if 최대 majority ≤ 0.7 , "extreme" otherwise (수정사항 21 의 stratification key)
num_train, num_val	sidecar 의 두 size
method	"FreeShap" / "LR" / "A1"
rank_pct, sel	sidecar 의 eigen_rank_pct , selection count
acc_top_naive, acc_random_naive, acc_top_balanced, acc_random_balanced, acc_at_f0	sidecar acc 의 normalising (정수/10000)
gap_top_random_naive, gap_top_random_balanced	top - random 의 두 metric
rho_used	sidecar 의 eigen_lambda_ (수정사항 29 의 cross-sidecar 확인용)

setting-level metadata grand_meta.csv 의 column:

column	정의
dataset, regime, train_ratio_tag, val_ratio_tag, num_train, num_val	grand_df 와 동일 join key
ntk_path	대응 NTK pickle 의 상대경로
ntk_shape	(n+n_val, n+n_val) 또는 (n, n) — schema 확인 결과
n, C	train dim, class 개수
train_class_counts, val_class_counts	length-C list (NTK pickle 의 sampled idx 와 dataset label join)
P_train_y, P_val_y	length-C 정규화 vector
top_eigs_path	NTK eigendecomposition 캐시 위치 (eig_cache/ <ds>_<tag>_<val_tag>.npz)

eigendecomposition 은 lens 2 의 핵심 입력이라 §1 에서 한 번만 계산하고 캐시. $n \leq 5000$ 의 train kernel 이라 numpy.linalg.eigh 로 충분 (~ 60-90 초/ setting, 50 settings $\approx$ 1 시간). 캐시 schema: npz 에 eigvals (shape [n], 내림차순), eigvecs (shape [n, k], $k=\min(n, 500)$), Y_tilde (shape [n, C], P_train(c) 로 column-wise mean centering), Y_val_tilde (shape [n_val, C],

P_val(c) 로 centering), K_train_val (shape [n, n_val], NTK pickle 이 full gram 일 때만; train-only 면 이 key 부재).

검증 (sanity check 셋): (i) acc_at_f0 가 한 setting 안에서 method 들 사이에 동일, (ii) random_results 의 method 간 일치 — 수정사항 30 — random_seed_used field 가 sidecar 에 없으면 strict (정확 일치) 가 아닌 moderate (cross-method Spearman ≥ 0.9 , 또는 acc 값의 cross-method MAE ≤ 0.01) 기준 적용, (iii) acc_top_naive[sel=100] $\approx$ acc_at_f0. 셋 중 하나라도 깨지면 parsing 버그.

estimated cost: 1 CPU core, 단일 노드 1.5 시간 (NTK eigh 1 시간 + sidecar parsing 30 분). GPU 불필요.

§2. Lens 1 — Label shift / BBSE / weighted risk

§2.1 motivation 과 hypothesis

valbal 과 trainbal 의 유일한 구조적 차이는 P_train(y) 와 P_val(y) 의 mismatch direction 입니다. valbal 에서는 P_train 이 skewed, P_val 이 uniform 이라 train $\rightarrow$ val 의 importance weight $w(y) = P_{val}(y) / P_{train}(y)$ 가 majority class 에서 < 1 , minority 에서 $\gg 1$ (예: sst2 pos70 $\rightarrow w(0) = 0.5/0.3 \approx 1.67$, $w(1) = 0.5/0.7 \approx 0.71$). trainbal 에서는 정반대 — P_train(y) uniform, P_val(y) skewed 라 w 의 방향이 역전. label shift 의 BBSE framework (Lipton-Wang-Smola 2018, ICML, arXiv 1802.03916) 은 이 mismatch 의 통계적 영향을 classifier risk side 에서 정량화하는 표준 도구입니다. Saerens, Latinne, Decaestecker (2002, Neural Computation) 의 EM-based estimator 는 framework 의 origin 으로부터 인용 — oracle P_val(y) 를 우리가 갖고 있으므로 EM iteration 은 직접 사용하지 않고, 실제로 쓰는 closed-form 은 Lipton 2018 eq. (3) 및 후속 (수정사항 23).

가설 H1 — **trainbal 에서 A1 이 random 한테 지는 case 는 P_val(y) skew 가 깊고 small selection budget 의 train sample 이 우연히 majority class 로 쏠려 weighted balanced risk 가 random selection 보다 더 큰 cell 이다.**

operational 정의 (수정사항 20) — trainbal random-loss-rate 를 $P(\text{gap_top_random_balanced}[A1, r=10\%, \text{sel} \in \{1, 2, 5\}] < -0.02)$ (즉 A1 이 random 보다 balanced acc 기준 2pp 이상 진 cell 의 비율) 로 정의. threshold -0.02 는 val_size 200-1000 의 binomial std (약 1-3pp) 보다 큰 효과를 잡기 위한 선택. 이 rate 가 H1 의 outcome metric, 그리고 cell 단위 outcome 으로는 gap_top_random_balanced 의 연속값을 그대로 사용.

정량 falsifier (수정사항 13 의 effect size + p-value 결합): trainbal regime 의 small-budget cell 에서 (predictor = kl_S_val, outcome = gap_top_random_balanced) 의 setting 단위 평균 (수정사항 14) Spearman r 이 $|r| > 0.3$ AND $p < 0.0125$ (Bonferroni 보정 $\alpha/4$) 면 H1 confirm. $|r| < 0.2$ AND $p > 0.1$ 면 reject. 그 사이 grey zone 은 cell 단위 mixed model (수정사항 11) 의 결과를 primary 판정으로 사용.

가설 H2 — **valbal regime 에서 A1 의 FreeShap/LR collapse 회복 강도는 P_train(y) 의 entropy $H(P_{train})$ 또는 majority probability $\max_c P_{train}(c)$ 와 monotone.** 즉 imbalance 가 깊을수록 A1 의 marginal benefit 이 커야 함. falsifier: valbal regime datasetxratio cell (21 setting) 에서 ($x = \max_c P_{train}(c)$, $y = \text{acc_top_balanced}[A1, r=10\%, \text{sel}=5] - \text{acc_top_balanced}[LR, r=10\%, \text{sel}=5]$) 의 Pearson r 이 $|r| > 0.3$ AND $p < 0.0125$ 면 confirm. $n=21$ 의 small-n 에서 $r=0.5$ 의 95% Fisher CI 가 약 [0.08, 0.77] 로 매우 wide 임을 인정 (수정사항 11 (a)), 임계값을 $0.5 \rightarrow 0.3$ 으로 완화. 기존 plan 의 0.5 cutoff 는 false-negative 위험 이라는 critic 지적 반영.

§2.2 정확한 quantity 정의 (수식 출처 명시)

n 개 train sample, n_{val} 개 val sample, C class, $\hat{y} : \mathcal{X} \rightarrow \{1, \dots, C\}$ 가 임의의 classifier. label shift 의 가정은 $P_{\text{train}}(x|y) = P_{\text{val}}(x|y)$ 이고 marginal $P_{\text{train}}(y) \neq P_{\text{val}}(y)$ 만 다르다는 것 (BBSE Sec. 2.1).

(1) KL divergence, 방향 통일 (수정사항 1).

$kl_{\text{val_train}} = KL(P_{\text{val}}(y) \parallel P_{\text{train}}(y)) = \sum_c P_{\text{val}}(c) \cdot \log(P_{\text{val}}(c) / P_{\text{train}}(c))$ [main]

$kl_{\text{train_val}} = KL(P_{\text{train}}(y) \parallel P_{\text{val}}(y)) = \sum_c P_{\text{train}}(c) \cdot \log(P_{\text{train}}(c) / P_{\text{val}}(c))$ [sensitivity]

label shift literature 의 convention — source $\rightarrow$ target ($P_{\text{train}} \rightarrow P_{\text{val}}$) 의 KL 은 coverage error proxy, target $\rightarrow$ source ($P_{\text{val}} \rightarrow P_{\text{train}}$) 의 KL 은 importance-weight variance proxy. 우리 H1, H2 의 mechanism 은 weighted ERM 의 variance 가 핵심이므로 $kl_{\text{val_train}}$ (target $\rightarrow$ source) 을 H1-H4 의 primary predictor 로 통일. $kl_{\text{train_val}}$ 은 같이 산출하되 sensitivity check 로만 사용. cell 단위 selected- subset 의 분포 P_S 에 대해서도 동일 방향으로 $kl_{\text{val_S}} = KL(P_{\text{val}} \parallel P_S)$ 가 primary, $kl_{\text{S_val}}$ 은 secondary. (단 H1 의 직관적 표현 — selected subset 이 val 분포에서 멀어지면 risk 가 커진다 — 는 두 방향 모두에서 monotone 이라 결과가 같은 부호일 expect.)

(2) BBSE importance weight (Lipton 2018 eq. (3)).

$w(c) = P_{\text{val}}(c) / P_{\text{train}}(c) = q(y) / p(y)$ (p = source = train, q = target = val)

방향이 Lipton 2018 의 표준과 정확히 일치. weighted ERM 의 sample weight 가 source distribution 의 expectation 을 target distribution 의 expectation 으로 변환하는 importance ratio 라 이 방향이 표준. column w_vector (list of length C).

(3) Confusion-matrix BBSE estimator (Lipton 2018 eq. (4)-(5), Theorem 3) — joint vs conditional 명확화 (수정사항 2). BBSE 의 confusion matrix 는 joint 분포

$\hat{C}_{\{ij\}} = (1/n_{\text{train}}) \cdot \sum_{k=1}^n \mathbb{I}[\hat{y}_k = i, y_k = j]$ [Lipton 2018 eq. (4)]

이고 (conditional $\hat{P}(\hat{y}=i \mid y=j)$ 가 아님), BBSE 가 직접 산출하는 것은 importance weight w 가 아니라 target marginal

$\hat{q}_{\text{val}}(y) = \hat{C}^{-1} \cdot \hat{\mu}_{\text{val}}(\hat{y}), \hat{\mu}_{\text{val}}(\hat{y})_i = (1/n_{\text{val}}) \sum_l \mathbb{I}[\hat{y}_l = i]$ [eq. (5)]

이며, w 는 후속 elementwise division $\hat{w}(c) = \hat{q}_{\text{val}}(c) / \hat{p}_{\text{train}}(c)$. consistency bound (Lipton 2018 Theorem 3): $\|\hat{w} - w\|_2 = O((1/\sigma_{\min}(C)) \cdot \sqrt{(C/n)})$. 우리 setup 은 oracle $P_{\text{val}}(y)$ 를 갖고 있으므로 estimator 자체는 직접 사용 안 함; 다만 oracle w 와 BBSE w 의 L1 차이 $bbse_err$ 를 sanity check column 으로 산출.

추가로 (수정사항 3) — BBSE 의 conditioning 자체가 wins 패턴과 상관되는지 점검: column $\sigma_{\min} C_{\text{hat}}$ ($\hat{C}$ 의 smallest singular value), $\text{cond}_C C_{\text{hat}} = \sigma_{\max} / \sigma_{\min}$. binary ($C=2$) 에서는 BBSE 가 수학적으로 trivial 한 게 아니라 oracle P_{val} 을 우리가 알기 때문에 실용적으로 redundant 인 것뿐이고, multi-class (MNLI $C=3$, AG News $C=4$) 에서는 conditioning 이 작으면 (모형이 weak 일수록 작음) RLLS (Azizzadenesheli, Liu, Yao, Anandkumar 2019, arXiv 1903.09734) 의 regularized estimator 가 안정. 우리는 RLLS 를 직접 적용하지 않지만, conditioning 이 cell-level wins 와 상관되면 BBSE framework 의 multi-class 적용의 경계조건 을 발견한 것.

(4) Weighted classifier risk + finite-sample variance 인정 (수정사항 4).

$R_w(\hat{y}) = (1/n_{\text{val}}) \sum_{(x,y) \in \text{val}} w(y) \cdot \mathbb{I}[\hat{y}(x) \neq y]$

balanced accuracy 가 R_w 의 special case ($w(c) = 1/(C \cdot P_{\text{val}}(c))$) 이므로, $\text{acc}_{\text{balanced}}$ 와 $\text{acc}_{\text{naive}}$ 의 gap 으로 weighted risk gap 의 proxy 가 가능. 다만 명시 한계: oracle w -weighted risk 는 label shift 만 있을 때의 reachable best predictor 의 risk 와 동일하지 않음. weighted ERM 이 asymptotically ($n_{\text{val}}, n_{\text{train}} \rightarrow \infty$) optimal 인 것과 finite- n 의 best 가 일치하지 않고, $n_{\text{val}} \leq$

1000 의 small budget 에서 Lipton 2018 Theorem 3 의 $O(\sqrt{C/n_{val}})$ order variance 가 risk 추정 에 직접 들어감. 따라서 weighted-balanced risk 는 *importance-weighted estimator* 의 *risk proxy* 일 뿐, lower bound 가 아님을 plan 본문 단계에서 명시.

(5) Train-sample composition 의 KL (Garg 2020 의 excess risk bound 근거; 수정사항 5).

각 cell (method, rank, sel) 에서 top-sel 의 train index 가 sidecar 의 `top_results` 와 분리되어 별도 `indices/*.txt` 에 저장됨 (없으면 sidecar 에서 직접 추출). selected subset S 의 class distribution $P_S(y) = (1/|S|) \sum_{i \in S} \mathbb{1}[y_i = c]$. column

$kl_val_S = KL(P_{val}(y) \parallel P_S(y))$ [primary, target $\rightarrow S$ 방향] $kl_S_val = KL(P_S(y) \parallel P_{val}(y))$ [secondary, $S \rightarrow$ target]

kl_val_S 의 *quality proxy* 근거: Garg, Wu, Smyl, Lipton (NeurIPS 2020, "A Unified View of Label Shift Estimation", arXiv 2003.07554) 의 §3 에서 weighted ERM 의 excess risk 가 $O(\|P_S - P_{val}\|_{TV}^2)$ order 로 bounded. TV 와 KL 의 Pinsker inequality ($TV(P, Q) \leq \sqrt{(KL(P \parallel Q)/2)}$) 로 KL 도 same order. 이게 H1 falsifier 의 임계값 0.3 의 order-of-magnitude 근거. [B-Garg20] 으로 bibliography 추가.

(6) Weighted balanced risk gap.

$\Delta_w = R_w(\hat{y}_{random}) - R_w(\hat{y}_{top})$

양수면 selection 이 random 보다 weighted risk 측면에서 우월. `grand_df` 의

`gap_top_random_balanced` 가 acc-side 의 naive balanced gap (= Δ_w 의 unweighted case = $1/(C \cdot P_{val}(c))$ 가중치), true weighted risk gap 과의 차이가 H1 의 핵심.

§2.3 검증 procedure

분석 단위 — **cell** = (dataset, regime, train_ratio, val_ratio, method, rank_pct, sel). 분석 group — (i) regime 별 (valbal vs trainbal), (ii) sel 별 (small $\leq 5\%$, mid $\in [10, 20]$, large ≥ 50 ; **추가로 sel=1% 도 별도** — 수정사항 22), (iii) method 별, (iv) imbalance_level 별 (mild vs extreme — 수정 사항 21).

H1 의 검증 (수정사항 11, 13, 14):

- *primary (setting 단위 marginal)* — trainbal regime 의 each setting 에 대해 $sel \in \{1, 2, 3, 5\}$ 의 4 cell 평균을 한 점으로 (within-setting 종속성 처리). 이렇게 18 setting $\times$ 1 point per setting $\rightarrow$ ($x = kl_val_S$, $y = gap_top_random_balanced$) 의 Spearman + Pearson + 95% Fisher CI.
- *secondary (cell 단위 mixed model)* — `gap_top_random_balanced` $\sim kl_val_S + \max_c P_{val}(c) + (1 \mid dataset)$ 의 statsmodels MixedLM 의 fixed β (kl_val_S 의 coefficient) + 95% CI. zero 를 cross 안 하면 더 strong.
- *tertiary (dataset 별 within-dataset Spearman)* — 각 dataset 의 setting 내 Spearman 의 median + IQR.
- *stratification* — imbalance_level $\in \{mild, extreme\}$ 별 separate primary Spearman 도 산출. mild-only 에서도 r 가 같은 부호이면 robustness 의 증거.

falsifier — primary Spearman 의 $|r| < 0.2$ AND $p > 0.1$ AND mixed model β 의 CI 가 zero 를 cross 하면 reject. primary $|r| > 0.3$ AND $p < 0.0125$ AND mixed model $\beta > 0$ 이면 confirm. 그 사 이는 partial.

H2 의 검증: valbal 의 21 setting 에서 ($x = \max_c P_{train}(c)$, $y = acc_top_balanced[A1, r=10\%, sel=5] - acc_top_balanced[LR, r=10\%, sel=5]$). primary/secondary/tertiary 3-tier 동일 절차. $n=21$ 의 Fisher CI 가 wide 함을 인정하고 임계값을 $|r| > 0.3$ (기존 0.5 $\rightarrow$ 완화) 으로 잡되 mixed model β 와의 결합 판정. partial Spearman 의 covariate 로 $H(P_{train})$ 도 같이 둬.

(Q1) 의 mechanism-level 답변 — valbal vs trainbal 의 collapse 양상 차이를 *single metric* 으로 잡습니다: $\text{delta_weighted_balanced_risk} = E[\text{acc_balanced} - \text{acc_naive}]$ of FreeShap. valbal 에서는 $\text{acc_balanced} \approx \text{acc_naive}$ (val 이 balanced), trainbal 에서는 $\text{acc_balanced} \ll \text{acc_naive}$ (val 이 imbalanced 라 naive acc 가 majority bias 의 reward). 두 regime 에서 collapse 의 측정 *metric* 자체가 다른 것 이 (Q1) 의 답이고, lens 1 의 BBSE-weighted framework 이 이 차이를 정량화.

§2.4 자료적 한계

label shift framework 의 가장 강한 가정 — $P_{\text{train}}(x|y) = P_{\text{val}}(x|y)$ — 이 우리 controlled imbalance setup 에서 정확히 성립합니다. valbal 의 train 은 GLUE-original 의 stratified subsample, val 은 동일 GLUE-original 의 balanced subsample 이라 $P(x|y)$ 가 같은 *generator* 에서 나옴 — covariate shift 항이 zero. trainbal 도 동일. 우리 setup 의 행운 — BBSE framework 이 oracle gauge 로 사용 가능.

다만 (i) train sample size 가 작음 ($n \leq 5000$), (ii) sel $\leq 5\%$ 의 sub-sample 은 $n_S \leq 250$ 으로 더 작아 importance weight 의 분산이 큼, (iii) C=2 binary 에서는 BBSE estimator 가 실용적으로 redundant (oracle P_{val} 을 갖고 있어서). multi-class (MNLI C=3, AG News C=4) 에서 BBSE confusion matrix 의 conditioning 이 의미 있음 — §2.2(3) 의 `sigma_min_C_hat` column 으로 모니터링.

해석상 가장 큰 risk 는 *label shift* 이상의 *mechanism* 이 trainbal random-loss 의 일부 case 에 작동할 가능성. H1 의 partial Spearman 이 약하다면 lens 2 (KTA) 가 잔 차를 잡을 수 있는지가 §3 의 task. lens 1 단독으로 trainbal random-loss 의 완전한 predictive metric 이 되리라 expect 하지 않습니다.

§2.5 스크립트 spec — `experiments/lens1_label_shift.py` (수정사항 17, 27)

입력: §1 의 `grand_df.csv`, `grand_meta.csv`. selected-subset index 가 별도 파일에 있으면 그 path 도. NTK pickle 의 K 자체는 lens 1 에서는 불필요.

산출:

(A) `state/iteration_04/lens1_table.csv` — setting 당 한 row (39 settings + 일부 cell-level extension). column schema:

column	정의
setting_id	<dataset>_<regime>_<train_ratio_tag>_<val_ratio_tag>의 unique key
dataset, regime, imbalance_level	(수정사항 21 의 stratification key)
C, n, n_val	class 수 + sample size
P_train_y, P_val_y	length-C list
kl_val_train (primary), kl_train_val (sensitivity)	수정사항 1
w_vector	length-C list, $w(c) = P_val(c)/P_train(c)$
H_P_train, H_P_val, max_P_train, max_P_val	entropy + majority prob
sigma_min_C_hat, cond_C_hat	BBSE conditioning (수정사항 3)
bbse_err	oracle w 와 BBSE w 의 L1 차이
risk_weighted_proxy	(acc_naive – acc_balanced) of FreeShap at sel=100, sel=10, sel=5 — proxy of weighted risk gap
kl_val_S_at_sel<S>_method<M>	cell-level KL of selected subset ($sel \in \{1, 2, 3, 5, 10\}$, $method \in \{A1, LR, FreeShap\}$) — wide format 또는 별도 cell-level file

(B) state/iteration_04/lens1_corr.csv — H1, H2 검증 table. row = (hypothesis_id, predictor, outcome, regime, imbalance_level, n_settings, Pearson r, Pearson r 95%CI, Spearman r, Spearman p, mixed_model_beta, mixed_model_beta_95CI, decision $\in \{\text{confirm, partial, reject}\}$). lens2_corr.csv 와 동일 schema 로 통일.

(C) state/iteration_04/lens1_figs/ — H1 scatter (cell 단위 + setting 평균), H2 scatter (setting 단위), regime 별 separate panel.

estimated cost: 1 CPU core, 20 분 (sidecar selected-index 추출 5 분 + KL 계산 5 분

- mixed model statsmodels 10 분).

dependency: statsmodels (MixedLM), scipy (pearsonr, spearmanr, Fisher transformation).

§3. Lens 2 — Spectral / kernel target alignment

§3.1 motivation 과 hypothesis

iter_03 의 §3 에서 정리한 7-quantity (LC, $PR(c^2)$, $Spearman(\lambda, c^2)$, $overlap_LR_A1$, $train_majority$, $LR_predict_majority_frac$, C) 중 *spectral-side* 의 핵심은 $PR(c^2)$ 와 $LC(r)$. $PR(c^2)$ 가 작으면 label 정보가 top eigenmode 에 집중, LR top-r 이 그 mode 를 잡아 task 를 푼다. $LC(r) = (\sum_{i \leq r} c^2_i) / (\sum_i c^2_i)$ 가 large 이면 동일 결론. iter_04 lens 2 의 새 contribution 은 (i) train-side c^2 만 다룬 iter_03 분석에 *val-side projection* c^2_val 을 Nyström extension 으로 추가, (ii) KTA 의 mode-wise decomposition 으로 spread 와 alignment 를 동시에 측정.

가설 H3 — **valbal regime** 에서 **A1** 의 **recovery** 강도는 **train- $\tilde{Y}$ KTA** 와 **val- $\tilde{Y}$ KTA** 의 **alignment gap** 과 **monotone**. falsifier — 21 valbal setting 에서 ($x = kta_gap_r10$, $y =$

recovery_score) 의 primary Pearson + cell-level mixed model 의 결합 판정. $|r| > 0.3$ AND $p < 0.0125$ 면 confirm.

가설 H4 — **trainbal regime** 에서 **LR collapse** 는 **train- $\tilde{Y}$ KTA** 가 높음에도 **val- $\tilde{Y}$ KTA** 가 낮은 **cell** 에서 발생. falsifier — trainbal 18 setting 에서 동일 3-tier 절차.

§3.2 정확한 quantity 정의 (수식 출처 명시)

NTK gram $K_{\text{train}} \in \mathbb{R}^{n \times n}$ 의 eigendecomposition $K_{\text{train}} = U \Lambda U^T$ ($U = [u_1, \dots, u_n]$, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, 내림차순, $\|u_i\|_2 = 1$). 이걸 §1 의 eig_cache 에 있음.

(1) Train label projection (iter_03 의 c_i^2).

$$c_i^2_{\text{train}} = \|u_i^T \tilde{Y}_{\text{train}}\|^2 = \sum_c (u_i^T \tilde{y}_{\{\text{train}, c\}})^2$$

$\tilde{Y}_{\text{train}} \in \mathbb{R}^{n \times C}$ 는 column-wise mean centering ($\tilde{Y}_{\text{train}}[:, c] = 1[y_i = c] - P_{\text{train}}(c)$).

(2) Val label projection via Nyström extension — 식 재유도 (수정사항 6).

기존 plan 의 식

$$c_i^2_{\text{val}} = \sum_c ((1/\lambda_i) \cdot u_i^T K_{\{\text{train}, \text{val}\}} \cdot \tilde{y}_{\{\text{val}, c\}})^2 \cdot (n_{\text{val}}/n) \text{ [WRONG]}$$

은 Nyström extension 의 $\sqrt{n}$ factor 가 누락됐고, sample-mean form 으로 풀리지 않은 matrix-product form 이라 부정확. Williams & Seeger (NeurIPS 2000, "Using the Nyström Method to Speed Up Kernel Machines") 의 eq. (4) 표기 (후속으로 Drineas & Mahoney 2005, JMLR vol. 6 의 eq. (5) 에서 standard form 정리) — train kernel 의 i-번째 eigenfunction ψ_i 의 out-of-sample value 는

$$\hat{\psi}_i(x_{\text{new}}) = (\sqrt{n} / \lambda_i) \cdot u_i^T k(x_{\text{train}}, x_{\text{new}}) \text{ [Williams-Seeger 2000 eq. (4)]}$$

이며, train sample 에서 ψ_i 의 평가값과 u_i 의 관계는 $u_i \approx (1/\sqrt{n}) \cdot (\psi_i(x_1), \dots, \psi_i(x_n))^T$ (normalization). 따라서 val sample $x_{\{\text{val}, j\}}$ 에서의 평가는

$$\hat{\psi}_i(x_{\{\text{val}, j\}}) = (\sqrt{n} / \lambda_i) \cdot u_i^T K_{\{\text{train}, \text{val}\}}[:, j]$$

이고, val side c_i_{val} 의 sample-mean form 은

$$c_i_{\text{val}, c} = (1/n_{\text{val}}) \cdot \sum_{j=1}^{n_{\text{val}}} \hat{\psi}_i(x_{\{\text{val}, j\}}) \cdot \tilde{y}_{\{\text{val}, c\}}(j) = (\sqrt{n} / (\lambda_i \cdot n_{\text{val}})) \cdot u_i^T K_{\{\text{train}, \text{val}\}} \cdot \tilde{y}_{\{\text{val}, c\}} \quad c_i^2_{\text{val}} = \sum_c c_i_{\text{val}, c}^2$$

$\tilde{Y}_{\text{val}} \in \mathbb{R}^{n_{\text{val}} \times C}$ 은 val one-hot 의 column-wise mean centering (P_{val} 로 centering).

NTK pickle 의 ntk 가 $(n+n_{\text{val}}) \times (n+n_{\text{val}})$ 의 full gram 이면 $K_{\{\text{train}, \text{val}\}} = \text{ntk}[:, n:n+n_{\text{val}}]$. §1 의 ntk_schema.md 가 train-only 임을 보고하면 lens 2 의 val-projection 은 제거 (수정 사항 7).

numerical caveat — small λ_i 의 division 에서 noise 큼. $\lambda_i < 10^{-6}$ 이면 Nyström 항을 0 으로 clip, nystrom_clip_count column 으로 보고.

(3) Per-mode learnability score (A1 score 의 원형, BCP21).

$$s_i = (\lambda_i / (\lambda_i + \rho))^2 \cdot c_i^2_{\text{train}}, \rho = 10^{-2} \text{ (sidecar 의 eigen_lambda_)}$$

이 score 가 A1 의 mode 선택 기준. Bordelon, Canatar, Pehlevan (2021, Nature Communications) [B-BCP21] 의 mode-wise generalization closed-form 의 학습 가능 quantity ($L_i = (\lambda_i / (\lambda_i + \kappa))^2 \cdot \alpha_i^2$) 와 함수형이 일치. ρ 의 cross-sidecar 일관성은 §1 의 sanity check 로 확인 (수정사항 29).

(4) Kernel-target alignment, full kernel (Cristianini et al. 2001 eq. (1); 수정 사항 8, 25).

$KTA(K, \tilde{Y}) = \langle K, \tilde{Y} \tilde{Y}^T \rangle_F / (\|K\|_F \cdot \|\tilde{Y} \tilde{Y}^T\|_F)$ [Cristianini, Shawe-Taylor, Elisseeff, Kandola, NIPS 2001 (proceedings vol. 14, 2002), eq. (1)]

column `kta_train_full` = $KTA(K_{train}, \tilde{Y}_{train})$. centered KTA (Cortes, Mohri, Rostamizadeh 2012, JMLR) 의 K-centering $K_c = H K H$, $H = I - (1/n) \mathbf{1} \mathbf{1}^T$ 는 추가 효과가 있음 (constant eigenmode 제거) — $\tilde{Y}$ 가 이미 mean-centered 라 재중복은 아니지만 K-centering 자체는 *redundant* 가 아닌 추가 자유도. 우리 stratified subsample 의 near-zero mean K eigenmode 가정 하에 KTA ranking 에 미치는 영향이 작다고 expect. sanity check 로 K_c 의 KTA 도 함께 산출 → 두 ranking 의 Kendall $\tau \geq 0.95$ 면 uncentered 사용. < 0.95 면 centered KTA 를 primary 로 전환.

KTA_{val} 는 K_{val} (NTK pickle 에 K_{val} 이 있다면, full gram 의 `ntk[n:, n:]`) 또는 K_{train} 위에 val label 을 project 한 형태로 산출. fallback definition — $KTA_{train_with_val_label} = KTA(K_{train}, \tilde{Y}_{train_via_val_y})$ — train sample 의 label 을 val side 분포로 centering 한 것. 두 KTA 의 차이가 *prior shift* 가 *label alignment* 에 미치는 영향 의 정량.

(5) Top-r KTA — self-contained derivation (수정사항 9, 26).

기존 plan 이 "arxiv 2108.08752 chapter 3 eq. (5)" 로 인용했으나 이 arXiv ID 의 정확 한 paper / chapter 가 plan 단계에서 미확인. self-contained derivation 으로 대체: top-r kernel $K_r = \sum_{i \leq r} \lambda_i u_i u_i^T$ 의 KTA 는 full KTA 의 분자·분모 모두 top-r truncate.

$$\langle K_r, \tilde{Y} \tilde{Y}^T \rangle_F = \sum_{i \leq r} \lambda_i \cdot u_i^T \tilde{Y} \tilde{Y}^T u_i = \sum_{i \leq r} \lambda_i \cdot c_i^2 \quad \|K_r\|_F^2 = \sum_{i \leq r} \lambda_i^2 \Rightarrow KTA(K_r, \tilde{Y}) = (\sum_{i \leq r} \lambda_i \cdot c_i^2) / (\sqrt{(\sum_{i \leq r} \lambda_i^2) \cdot \|\tilde{Y} \tilde{Y}^T\|_F})$$

분모의 $\|\tilde{Y} \tilde{Y}^T\|_F$ 는 r 에 무관하게 full label 의 norm. 결과: top-r KTA 는 $[0, \text{full_KTA}]$ range (full KTA 만 $[0, 1]$), dataset-internal r-sweep 에만 사용. cross- dataset 비교는 *ratio* ($KTA(r) / KTA_{full}$) 또는 *gap* (수정사항 9 의 일부).

column `kta_train_r<R>` for $R \in \{1, 5, 10, 15, 20, 25, 30\}\%$.

(6) Top-r KTA gap (train vs val).

$$\text{gap_KTA}(r) = KTA(K_r, \tilde{Y}_{train}) - KTA(K_r, \tilde{Y}_{train_via_val_y})$$

H3, H4 의 main predictor variable. column `kta_gap_r<R>`.

(7) Effective alignment ratio (iter_03 LC_LR 의 generalization).

$$LC_{train}(r) = (\sum_{i \leq r} c_i^2_{train}) / (\sum_i c_i^2_{train}) \quad LC_{val}(r) = (\sum_{i \leq r} c_i^2_{val}) / (\sum_i c_i^2_{val}) \\ LC_{gap}(r) = LC_{train}(r) - LC_{val}(r)$$

iter_03 의 LC_LR 은 $LC_{train}(r)$ 에 해당. LC_{val} 이 새 quantity, LC_{gap} 이 H3 의 *partial verification* (KTA 의 unnormalised version).

(8) Participation ratio (iter_03 와 동일, 수정사항 10).

$$PR_{train} = (\sum_i c_i^2_{train})^2 / \sum_i (c_i^2_{train})^2 \quad PR_{val} = (\sum_i c_i^2_{val})^2 / \sum_i (c_i^2_{val})^2$$

train side 는 iter_03 의 $PR(c^2)$ column 그대로. *small-n caveat* — PR 의 분모 $\sum c_i^4$ 가 small c_i^2 의 chi-square noise 에 sensitive, finite-n underestimation bias 있음. iter_03 의 $n=5000$ 와 iter_04 의 setting-별 $n=2300-5000$ 비교 시 절댓값 비교는 보류, *ranking* (Spearman across datasets) 만 유효.

(9) A1-LR overlap (iter_03 의 overlap_LR_A1).

$$\text{overlap}_r = |I_{LR}(r) \cap I_{A1}(r)| / r, \quad I_{LR}(r) = \text{top-}r \text{ by } \lambda_i, \quad I_{A1}(r) = \text{top-}r \text{ by } s_i$$

§3.3 검증 procedure — 3-tier 통계 절차 (수정사항 11, 12, 13, 19, 21, 22)

분석 unit — setting (한 (dataset, regime, train_ratio, val_ratio) 의 unique combination, valbal 21 + trainbal 18 = 39 settings).

통계 절차 (3-tier, lens 1 과 동일 구조):

1. *Primary (setting 단위 marginal)* — `outcome ~ predictor` 의 Pearson + Spearman
 - 95% Fisher CI. small-n ($n=21$ 또는 18) 의 Fisher CI 가 wide 함을 본문에서 인정 — $n=21$ 에서 $r=0.5$ 의 CI 가 $[0.08, 0.77]$, $n=18$ 에서 $r=0.3$ 의 CI 가 $[-0.20, 0.66]$ 으로 zero 를 cross 가능. 임계값 $0.5 \rightarrow 0.3$ 으로 완화.
2. *Secondary (cell 단위 linear mixed model)* — `outcome ~ predictor + (1 | dataset)` 의 statsmodels MixedLM fixed β + 95% CI. $n_{\text{cell}} = \text{setting} \times \text{method} \times \text{rank_pct} \times \text{sel} \approx 39 \times 3 \times 7 \times \sim 10 = \text{약 } 8000$, dataset 을 random intercept 로 처리해 dataset- level confounding 흡수. β 의 CI 가 zero 를 cross 안 하면 더 strong 한 evidence.
3. *Tertiary (dataset 별 within-dataset Spearman 의 분포)* — 7 dataset 각각의 within- dataset Spearman 의 median + IQR. dataset 간 heterogeneity 확인.

Multiple-testing 보정 (수정사항 12): H1-H4 만 *primary pre-registered*, sub-group analysis (regime, sel range, method, imbalance_level 별) 은 *exploratory*. primary 4-test 에 Bonferroni 보정 $\alpha/4 = 0.0125$ 적용 (또는 BH 의 step-up procedure, 4 test 중 작은 p 부터 정렬해 i -번째 $p < (i/4) \cdot 0.05$ 만족 검사). exploratory 는 raw p-value 와 effect size 만 보고하고 결론적 주장에 사용 안 함.

Falsifier 임계값 재정의 (수정사항 13):

- *confirm* — primary $|r| > 0.3$ AND primary $p < 0.0125$ (Bonferroni) AND mixed model $\beta > 0$ AND β 의 95% CI 가 zero 를 cross 안 함.
- *reject* — primary $|r| < 0.2$ AND primary $p > 0.1$ AND mixed model β 의 95% CI 가 zero 를 cross 함.
- *partial* — 둘 사이의 grey zone. 이 경우 mixed model β 의 결과를 우선 판정으로 서술 + 본문에서 "small-n 의 Fisher CI 가 wide 라 setting 단위 marginal 만으로는 결정 불가, cell 단위 mixed model 의 β 와 그 CI 를 일차 근거로" 명시.

Stratification (수정사항 21): H1-H4 의 primary correlation 을 imbalance_level $\in \{\text{mild, extreme}\}$ 별로도 separate 산출. pooled correlation 의 mechanical inflation (extreme cell 이 KL 큼 + collapse 큼 $\rightarrow r > 0.5$ 의 trivial 발견) 점검.

sel sweep 확장 (수정사항 22): H3 의 cell sweep 에 sel = 1 추가, sel $\in \{1, 3, 5, 10\}$ 의 4 점 평균. sel-별 separate correlation 도 산출해 non-linear 의존성 (sel=1 의 극단 small-budget 에서만 collapse sharp) 확인.

H3 의 검증: valbal 21 setting 에서 ($x = \text{kta_gap_r10}$, $y = \text{recovery_score}$), 3-tier

- stratification + sel sweep. recovery_score 정의 — `acc_top_balanced[A1, r=10%, sel = 5]` - `acc_top_balanced[LR, r=10%, sel=5]`, 추가 robustness 로 sel $\in \{1, 3, 5, 10\}$ 와 $r \in \{5, 10, 15\}$ 의 12 cell average. confirm/reject 는 위 임계값에 따름.

H4 의 검증: trainbal 18 setting 에서 ($x = \text{kta_train_r10}$, $y = -\text{gap_top_random_balanced[LR, r=10\%, sel=5]}$). 결합 H4' — ($x = \text{kta_gap_r10}$, $y = -\text{gap_top_random_balanced[LR, r=10\%, sel=5]}$) 도 산출.

iter_03 Cond 2 (PR(c^2) cause-side) 와의 명시 mapping — iter_04 의 KTA 분석은 이 표현을 PR 큰데 $KTA(r)/KTA_{\text{full}}$ 비율 작으면 collapse 로 재진술하고 (이를 "spectral reformulation" 또는 complementary measure 로 표현, 동치 주장 아님; 수정사항 15). PR 의 scalar 진단을 r-별 curve (KTA mode-wise) 로 generalize 하는 게 lens 2 의 새 contribution.

falsifier (lens 2 종합) — H3, H4 가 둘 다 reject 면 lens 2 가 mechanism 핵심 변수 아님 $\rightarrow$ lens 3 (d_{eff}) 또는 lens 4 (variance) 또는 lens 1 단독 설명력으로 후퇴. 한 개만 reject 면 partial mechanism.

§3.4 스크립트 spec — `experiments/lens2_kta_spectral.py`

입력: §1 의 `grand_df.csv`, `grand_meta.csv`, `eig_cache/*.npz`. NTK pickle 의 `K_{train,val}` block 도 필요 (`eig_cache` 산출 시 함께 저장하거나 이 스크립트에서 pickle 재로딩). `ntk_schema.md` 의 결과로 `K_{train,val}` 부재면 `val-projection column` 들을 NaN 으로 채우고 H3, H4 의 `val-side analysis` 보류.

산출 — `state/iteration_04/lens2_table.csv` — setting 당 한 row, columns: `setting_id`, `dataset`, `regime`, `train_ratio_tag`, `val_ratio_tag`, `imbalance_level`, `C`, `n`, `n_val`, `kta_train_full`, `kta_train_with_val_label`, `kta_train_r{1,5,10,15,20,25,30}`, `kta_train_with_val_label_r{1...30}`, `kta_gap_r{1...30}`, `lc_train_r{1...30}`, `lc_val_r{1...30}`, `lc_gap_r{1...30}`, `pr_c2_train`, `pr_c2_val`, `d_eff_rho`, `d_eff_r{1...30}`, `d_eff_ratio_r{1...30}`, `overlap_LR_A1_r{1...30}`, `recovery_score_A1_vs_LR_balanced` (`sel=1,3,5,10` each), `LR_loss_vs_random_balanced` (`sel=1,3,5,10` each, `trainbal` only), `nystrom_clip_count`, `kta_centered_kendall_tau`.

추가 산출 — `state/iteration_04/lens2_corr.csv` — H3, H4 검증 table, `lens1_corr.csv` 와 동일 schema: (`hypothesis_id`, `predictor`, `outcome`, `regime`, `imbalance_level`, `n_settings`, `Pearson r`, `Pearson r 95%CI`, `Spearman r`, `Spearman p`, `mixed_model_beta`, `mixed_model_beta_95CI`, `decision`).

추가 figure — `state/iteration_04/lens2_figs/` — H3, H4 scatter (primary setting 단위 + dataset color), stratified panel (mild vs extreme).

estimated cost: `eig_cache` 가 있으면 setting 당 ~ 5 초 (50 settings × 5 sec = 5 분, 단일 CPU). mixed model 추가 5 분.

§3.5 직관적 sanity check 와 한계

KTA 의 absolute value 는 dataset 간 비교에 약함 (서로 다른 X 도메인의 $\|K\|_F$ scale 다름). `gap` 또는 `ratio` 만 cross-dataset correlation 에 사용 — top-r KTA 의 [0, full_KTA] range 도 dataset-internal r-sweep 에만 (수정사항 9).

`val-side projection` 의 Nyström extension 이 mathematically 정확하지만 numerical 으로 small λ_i 의 division 에서 noise 큼. $\lambda_i < 10^{-6}$ 이면 Nyström 항을 0 으로 clip (column `nystrom_clip_count` 로 보고).

lens 1 (label shift) 과 lens 2 (KTA) 가 상관 변수일 가능성 — `kl_val_train` 큰 setting 에서 자연스럽게 `kta_gap` 도 크다. 두 lens 의 분리 가능한 *contribution* 측정 을 위해 multivariate 선형 회귀로 H3 의 `recovery_score` 를 (`kl_val_train`, `kta_gap_r10`, `pr_c2_train`) 세 predictor 로 분해. 각 predictor 의 partial r^2 가 lens 별 explained variance.

$PR(c^2)$ 와 $KTA(r)/KTA_{full}$ 의 redundancy 정량화 (수정사항 15) — 두 measure 의 cross- dataset Spearman 을 산출, `p_spearman` > 0.8 이면 sufficiently 중복 (Cond 2 의 PR- based 표현과 KTA-based 표현이 경험적으로 동치), < 0.5 면 두 measure 가 다른 정보.

§4. Lens 3 — Effective dimension $d_{eff}(\rho)$ — brief

Caponnetto-De Vito (2007, Foundations of Computational Mathematics, "Optimal Rates for Regularized Least Squares Algorithm") 의 핵심 quantity — $d_{eff}(\rho) = \text{tr}(K(K + \rho I)^{-1}) = \sum_i \lambda_i / (\lambda_i + \rho)$ — 는 KRR 의 *effective number of degrees of freedom* 이고, source condition 하 KRR generalization error 의 sharp 비율을 정합니다. lens 2 의 sub-lens 인 이유: A1 score 의 첫 factor

$(\lambda_i / (\lambda_i + \rho))^2$ 가 d_{eff} 의 mode-wise contribution $(\lambda_i / (\lambda_i + \rho))$ 의 제곱, 즉 spectral filter. lens 2 의 $KTA(r)$ 가 *label* 측 정렬이라면, d_{eff} 는 *kernel* 측 effective complexity.

정의 (column 으로 lens2_table.csv 에 append):

- $d_{\text{eff_rho}} = \sum_i \lambda_i / (\lambda_i + \rho)$, $\rho = 10^{-2}$.
- $d_{\text{eff_r<R>}} = \sum_{\{i \leq r \cdot n/100\}} \lambda_i / (\lambda_i + \rho)$, top-r mode 의 d_{eff} 기여분.
- $d_{\text{eff_ratio_r<R>}} = d_{\text{eff_r}} / d_{\text{eff_rho}} \in [0, 1]$.

검증 — H5 (mild, exploratory only): valbal regime 에서 $d_{\text{eff_ratio_r10}}$ 가 작은 setting 일수록 A1 recovery_score 가 큼. exploratory 라 multiple-testing 보정 불필요, raw r 와 p 만 보고. lens 2 와 강하게 collinear 할 가능성 큼 (단조감소 spectrum 가정 하에 $d_{\text{eff_ratio}}$ 와 cumulative spectrum 비율은 거의 일치) — partial r^2 로 평가.

해석상 lens 3 의 core contribution 은 수치보다는 *framework*: A1 의 score factor 가 우연이 아니라 KRR generalization 의 source condition 측 quantity 와 직결된다는 점을 명시 (BCP21 / Simon23 / Caponnetto-De Vito 의 lineage). 이 lens 는 sidecar 분석 자체보다 paper 의 §Theory 의 motivation 으로 들어갈 자료.

산출은 §3 의 lens2_table.csv 에 8 개 column 추가만. 별도 스크립트 없이 lens2 script 의 마지막 함수로. estimated cost: < 1 분.

§5. Lens 4 — Shapley value variance — brief

TMC Shapley 의 marginal contribution 추정은 random permutation $\sigma \in S_n$ 의 sample mean 으로 계산. tmc_iter = 500 의 finite-sample variance 가 selection ranking 의 안정성을 결정. A1 score 가 LR score 대비 분산이 작은 mode 를 선호한다면 A1 의 ranking 이 더 안정 — 또는 그 반대.

정의:

- 각 method 의 final per-sample Shapley value $\hat{\phi}_i \in \mathbb{R}^n$ 의 *seed-to-seed variance* $\text{Var}_{\text{seed}}(\hat{\phi}_i)$ — single seed (2026) 만이라 직접 측정 불가. proxy 로 TMC 내 permutation chunk 단위 partial mean 의 jackknife variance $\text{Var}_{\text{jack}}(\hat{\phi}_i)$ 가 가능. shapley pickle (data_selection_test/imbalance/shapley/.../*.pkl) 의 TMC trajectory 가 chunk 단위로 남아 있는지 점검 필요.
- trajectory 부재면 lens 4 는 *bound* 형 진술만 — TMC paper (Ghorbani-Zou 2019) 의 Hoeffding bound: $|\hat{\phi}_i - \phi_i| \leq \epsilon$ with prob $\geq 1 - \delta$ for $\epsilon = O(\sqrt{(\log n)/T})$. $T = 500$, $n = 5000 \rightarrow \epsilon \approx 0.04$. small budget (sel = 5%) 의 top-100 ranking 변경에 영향 가능. A1 vs LR 의 sensitivity 비교는 paper §Limitations 한 단락.

분석 procedure — lens 1-3 의 검증이 모두 *reject* 일 때만 lens 4 정밀 분석으로 진입. 산출 — state/iteration_04/lens4_bound_note.md (수식 + 두 paragraph, 별도 스크립트 없음).

§6. 종합 — iter_03 framework 와의 mapping 및 (Q1)-(Q3) 답안 윤곽

iter_03 의 3-조건 framework 와 iter_04 의 4-lens 의 mapping 을 표로 정리 (수정사항 15, 16 의 mapping table 약화 반영):

iter_03 quantity / Cond	iter_04 lens	강화 방향
LC_LR(r) (Cond 1 primary)	lens 2 의 LC_train(r)	val side LC_val(r) 와 gap 으로 확장. iter_03 §6 부록의 r-robustness 검증 그대로
PR(c^2) (Cond 2 cause-side)	lens 2 의 pr_c2_train + KTA_train(r)/KTA_full ratio	complementary spectral measure (동치 아님). PR $\leftrightarrow$ KTA(r)/KTA_full 의 cross-dataset Spearman 으로 redundancy 정량 검증 (수정사항 15)
train_majority (Cond 2 verification)	lens 1 의 max_c P_train(c), kl_val_train	label shift framework 으로 위치 지정
LR_predict_majority_frac (Cond 2 effect-side)	lens 1 의 BBSE-weighted balanced risk	confusion-matrix / weighted risk 의 결과 observable
Spearman(λ , c^2) (Cond 1 secondary)	lens 2 의 overlap_LR_A1, score-correlation	iter_03 와 동일
overlap_LR_A1	lens 2 의 overlap_LR_A1	iter_03 와 동일
C (Cond 3 primary)	iter_04 lens 1-4 가 cover 하지 않음 (수정사항 16)	C $\leftrightarrow$ KL 의 매핑은 부정확 (binary balanced 와 binary imbalanced 모두 가능, multi-class balanced 와 imbalanced 도 모두 가능 — 두 mechanism 은 independent). next_directions item 1 (C-sweep 본 실험) 으로 이관

Cond 2 cause-side $\leftrightarrow$ lens 2 KTA 의 관계: 두 측정 (PR, KTA(r)/KTA_full) 이 원리적 동치 라는 주장은 약하지만, 경험적으로 강하게 상관할 expect (특히 spectrum 의 power-law decay 영역에서). 동치성은 lens 2 의 검증 procedure (PR-KTA(r)/KTA_full 의 cross-dataset Spearman 측정) 의 결과 로 결정 될 정량 hypothesis 이지, plan 단계의 가정 아님. PR 큰데 KTA(r)/KTA_full 작은 setting 에서 prior shift ($kl_val_train > 0$) 가 추가되면 LR selection 이 majority class 의 common-feature mode 로 채워져 collapse — 이게 lens 2 의 narrative.

(Q1) — train $\leftrightarrow$ val 의 imbalance 위치가 collapse 양상을 바꾸는 이유: valbal 은 balanced acc 가 acc_naive 와 일치 (val 이 balanced) $\rightarrow$ FreeShap collapse 의 직접 metric 이 train side mechanism (PR 큰데 KTA 작은) 의 직접 효과. trainbal 은 balanced acc 가 naive acc 와 크게 다름 (val 이 imbalanced) $\rightarrow$ FreeShap naive acc 는 majority bias 의 reward 를 받아 절댓값 큼, balanced acc 만 보면 collapse. metric 의 reference 차이 가 가장 큰 분기 원인이고, 그 외에는 lens 2 의 train-val KTA gap 이 분기 강도를 조절. lens 1 의 BBSE-weighted framework 이 이 metric 차이의 수식적 정량화.

(Q2) — A1 이 회복하는 quantity: lens 2 의 $s_i = (\lambda_i/(\lambda_i + p))^2 \cdot c_i^2_train$ 이 BCP21 learnability 와 함수형 일치하는 mode-wise generalization 기여분. A1 의 top-r subspace 는 label 변별력이 큰 mode 의 집합이라, 그 위에서의 ridge 가 minority class 의 prediction power 를 보존 $\rightarrow$ balanced acc 회복. mode-wise 표현으로는 LC_train(r) 에서 LR 이 빠뜨린 mode (small λ 에 흩어진 label 정보) 의 회복.

(Q3) — trainbal random-loss-rate (operational 정의: 수정사항 20 의 `gap_top_random_balanced[A1, r=10%, sel  $\in$  {1, 2, 5}]` < -0.02 cell 의 비율) 의 predictive metric: lens 1 의 `kl_val_S` — 즉 selected subset 의 class distribution 이 val distribution 에서 떨어진 cell. lens 2 의

LR_loss_vs_random 과의 결합으로 $KTA_{train}(r)$ 큰데 kta_gap_r 도 큰 cell 이 가장 위험. 검증은 §2.3 의 H1, §3.3 의 H4.

종합 paragraph 는 (Q1)-(Q3) 답안 + lens 1-4 의 partial r^2 분해 + iter_03 framework 의 spectral 강화 + 한계 (binary 의 BBSE 실용적 redundant, Nyström 의 small- λ noise, single-seed, controlled imbalance 의 covariate shift zero 가정, $n=21/18$ 의 small- n Fisher CI wide) 를 prose 로 한 페이지 길이.

§7. next_directions 의 윤곽

본 iter 의 critique 후 작성될 `state/iteration_04/next_directions.md` 의 candidate items:

1. **multi-class C-sweep 의 본 실험 launch** — iter_03 §6 의 (ii) 우선 task. $C \in \{6, 10, 14, 20\}$ dataset (TREC, Yahoo Answers, DBpedia, 20Newsgroups) 의 NTK 계산 + Shapley 실험. iter_04 lens 1-4 가 cover 하지 않은 $C \leftrightarrow$ Cond 3 mechanism (수정사항 16) 의 직접 검증. iter_04 의 H1-H4 가 multi-class 에서 strong evidence 를 주는지도 부수 검증.
2. **valbal $\times$ trainbal 의 symmetric pair sweep** — 같은 dataset 에서 (train pos70, val balanced) 와 (train balanced, val pos70) 의 정확한 mirror pair. iter_04 의 sidecar 는 일부만 mirror, 전체 21 ratio 에 대한 mirror pair 가 lens 1 label shift 가설의 *causal* falsifier.
3. **A1 score factor decomposition 실험** — $s_i = (\lambda_i/(\lambda_i+\rho))^2 \cdot c_i^2$ 를 두 factor ablation. $score_spec = c_i^2$ only, $score_filt = (\lambda_i/(\lambda_i+\rho))^2$ only, $score_full = s_i$. 각 score 의 wins 비교. lens 3 의 d_eff 실증.
4. **paper draft 의 §Theory 한 페이지** — BCP21 learnability $\leftrightarrow$ A1 score 의 함수형 일치 증명. critique_priorart.md 의 C3 (필수).

현재 plan 시점의 가장 유력 우선순위는 H1, H3 confirm 시 (1) + (4), reject 시 (2) + (3). critique 결과로 우선순위 재정렬.

§8. 제약 재확인, 산출물 체크리스트, 2-라운드 critique 의 minimum input set

제약 (재확인):

- dataset-specific 분석 금지. main claim 은 cross-dataset correlation 위에서.
- 추가 실험 launch 금지. NTK 재계산 금지 (eig_cache 까지만). shapley pickle 의 trajectory 추출 OK.
- iter_03 framework (Cond 1/2/3, 7-quantity) 와의 explicit mapping 의무. lens 2 $\leftrightarrow$ Cond 2 의 spectral 정량화 관계 §6 에 명시 (단 *complementary*, 동치 아님).

산출물 체크리스트:

- ☐ `state/iteration_04/ntk_schema.md` (§1 사전 schema 확인, 가장 우선)
- ☐ `state/iteration_04/grand_df.csv` (§1, lens 1-4 공통 입력)
- ☐ `state/iteration_04/grand_meta.csv` (§1, kernel/spectral metadata)
- ☐ `state/iteration_04/eig_cache/*.npz` (§1, NTK eigendecomposition 캐시)
- ☐ `state/iteration_04/lens1_table.csv` (§2.5 spec, lens 1 quantity table)
- ☐

- state/iteration_04/lens1_corr.csv (§2.5 spec, H1/H2 correlation summary)
- ☐ state/iteration_04/lens1_figs/*.png (H1, H2 scatter)
- ☐ state/iteration_04/lens2_table.csv (§3.4 spec, KTA + lens 3 d_eff column 포함)
- ☐ state/iteration_04/lens2_corr.csv (§3.4 spec, H3/H4 correlation summary)
- ☐ state/iteration_04/lens2_figs/*.png (H3, H4 scatter)
- ☐ state/iteration_04/lens4_bound_note.md (brief, 한 페이지)
- ☐ experiments/build_grand_df.py
- ☐ experiments/lens1_label_shift.py
- ☐ experiments/lens2_kta_spectral.py
- ☐ state/iteration_04/critique.md (2 번째 라운드 critique, executor 종료 후)
- ☐ state/iteration_04/next_directions.md
- ☐ reports/iter_04.pdf (full archive)
- ☐ reports/iter_04_summary.pdf (lens 1-2 깊게 다룬 reading copy)

2-라운드 critique 의 minimum input set (수정사항 28): executor 완료 시 critic 이 받아야 할 4 + α 파일은

1. state/iteration_04/grand_df.csv — cell-level acc 와 모든 outcome metric.
2. state/iteration_04/lens1_corr.csv — H1, H2 의 confirm/partial/reject decision + 3-tier 통계 (primary Pearson, mixed β , dataset-별 분포).
3. state/iteration_04/lens2_corr.csv — H3, H4 의 동일 schema.
4. state/iteration_04/lens1_figs/H{1,2}_scatter.png, state/iteration_04/lens2_figs/H{3,4}_scatter.png — 4 개 hypothesis scatter.

추가로 ntk_schema.md (lens 2 val-projection 가능 여부 보고), lens2_table.csv (KTA-PR redundancy 정량) 도 critic 이 참조하면 더 강한 critique 가능. critic 의 primary outcome 은 H1-H4 의 decision (confirm/partial/reject) 과 그 decision 의 3-tier 통계적 robustness — Bonferroni 보정 후에도 $p < 0.0125$ 인지, mixed model β 의 95% CI 가 zero 를 cross 안 하는지, dataset 별 within-Spearman 의 분포가 한 부호로 일관한지의 3 가지.

Estimated total cost — 단일 노드 CPU 만 사용, 6 시간 내외 (§1 build 30 분 + NTK eigh 1 시간 + lens 1 분석 30 분 + lens 2 분석 30 분 + lens 3-4 5 분 + 리포트 빌드 30 분 + debugging buffer 2 시간 + statsmodels MixedLM 30 분). GPU 불필요.

참고

- BBSE: Lipton, Wang, Smola (2018) ICML, arXiv 1802.03916. eq. (3) — $w(y) = q(y)/p(y)$; eq. (4) — confusion matrix $\hat{C}_{\{ij\}} = (1/n) \sum \mathbb{I}[\hat{y}=i, y=j]$ (joint); eq. (5) — $\hat{q} = \hat{C}^{-1} \mu_{\hat{q}}$; Theorem 3 — consistency bound. <https://arxiv.org/abs/1802.03916>

- RLLS: Azizzadenesheli, Liu, Yao, Anandkumar (2019), arXiv 1903.09734 — small- $\sigma_{\min}$ 영역의 regularized BBSE.
- Garg, Wu, Smyl, Lipton (2020) NeurIPS, arXiv 2003.07554. weighted ERM excess risk bound 의 TV/KL form (Pinsker). [B-Garg20]
- Saerens, Latinne, Decaestecker (2002) Neural Computation. prior shift correction 의 EM-based estimator — framework origin only, 직접 사용 안 함 (수정사항 23).
- KTA: Cristianini, Shawe-Taylor, Elisseeff, Kandola (2001) NIPS, proceedings vol. 14 (2002 인쇄). eq. (1) — $A(K_1, K_2) = \langle K_1, K_2 \rangle_F / \sqrt{\langle K_1, K_1 \rangle_F \cdot \langle K_2, K_2 \rangle_F}$. <https://papers.nips.cc/paper/1946-on-kernel-target-alignment> (수정사항 25 의 venue 통일).
- Centered KTA: Cortes, Mohri, Rostamizadeh (2012) JMLR. K-centering $K_c = H K H$, $H = I - \frac{1}{n} \mathbf{1}\mathbf{1}^T$ 의 추가 효과.
- Nyström out-of-sample extension: Williams & Seeger (2000) NeurIPS, eq. (4) — $\psi_i(x_{\text{new}}) = (\sqrt{n} / \lambda_i) \cdot u_i^T k(x_{\text{train}}, x_{\text{new}})$. 후속 표기 Drineas & Mahoney (2005) JMLR vol. 6 eq. (5). (수정사항 6 의 식 출처)
- d_{eff} : Caponnetto, De Vito (2007) Foundations of Computational Mathematics — $d_{\text{eff}}(\rho) = \text{tr}(K(K+\rho I)^{-1})$.
- A1 score 의 learnability anchor: Bordelon, Canatar, Pehlevan (2021) Nature Comm [B-BCP21]; Simon, Dickens, Karkada, DeWeese (2023) TMLR [B-Simon23].
- top-r KTA mode-wise decomposition: self-contained derivation (수정사항 9, 26), 본문 §3.2(5) 참조. (arxiv 2108.08752 인용 제거 — chapter/eq. 확인 불가능.)
- iter_03 framework: `state/iteration_03/report.md` §3, §4.
- prior-art 점검: `state/iteration_04/critique_priorart.md`.
- FreeShap = inv: Wang, Lin, Qiao, Foo, Low (2024) NeurIPS [B1].
- LR = lrfshap top-r: 저자=사용자 (2026) ICML workshop [B2].

2. Critic Analysis (v1)

Iteration 04 plan critique — quantity 정의, falsifier 임계값, script spec 의 사후 점검

본 문서는 state/iteration_04/plan.md 의 내부 비평입니다. 5-단계 backbone (데이터 통합 → lens 1 label shift → lens 2 spectral/KTA → lens 3 d_eff brief → lens 4 Shapley variance brief → 종합) 의 골조는 사용자와 이미 합의된 것이라 유지하고, 각 단계 안의 quantity 정의의 수학적 정확성, 검증 procedure 의 타당성, H1-H4 falsifier 임계값의 적절성, iter_03 framework mapping 의 정확성, 분석 스크립트 spec 의 충분성/누락을 정량 단위로 짚습니다. 마지막 §10 에 planner 가 받아 plan 을 수정할 수 있는 actionable 수정사항 목록을 둡니다. 분량은 본문 약 4000 단어.

§1. Lens 1 — label shift quantity 정의의 수학적 정확성

plan §2.2 의 quantity 7 개 (KL, $w(c)$, confusion-matrix BBSE, weighted risk, kl_S_val , weighted risk gap, plus implicit Δ_w) 를 차례로 점검합니다.

(a) KL divergence 의 방향. plan §2.2(1) 는 $KL(P_{train}(y) \parallel P_{val}(y)) = \sum_c P_{train}(c) \cdot \log(P_{train}(c) / P_{val}(c))$ 를 정의하고 reverse kl_val_train 도 같이 둔다고 했습니다. 부호 자체는 맞고 두 방향 모두 두는 것도 좋은 판단입니다. 다만 어느 방향이 $H1$, $H2$ 의 *predictor* 로 사용되는지 가 plan 에 없습니다. label shift literature 의 convention 은 source → target ($P_{train} \rightarrow P_{val}$) 방향의 KL 을 *coverage error proxy* 로 쓰고, target → source ($P_{val} \rightarrow P_{train}$) 의 KL 을 *importance-weight variance proxy* 로 씁니다. 우리 문제에서는 H1 (trainbal 의 small-budget cell 에서 A1 이 random 한테 짐) 의 mechanism 이 "selected subset 의 class distribution P_S 가 P_{val} 과 멀어진 다" 라서 $kl_S_val = KL(P_S \parallel P_{val})$ (= selected → target) 이 자연스러운데, baseline 의 train 측 분포는 *target* 인 *val* 방향으로 가는 게 일관됩니다. 즉 main predictor 는 $kl_val_train = KL(P_{val} \parallel P_{train})$ (target → source) 로 통일하고, kl_train_val 은 같이 산출만 하되 sensitivity check 용으로 두는 게 좋습니다. plan 에 이 방향 통일 의 명시가 없으니 수정 필요 (§10 의 수정사항 1).

(b) BBSE importance weight 의 방향 — 맞음. plan §2.2(2) 의 $w(c) = P_{val}(c) / P_{train}(c)$ 는 Lipton-Wang-Smola 2018 (arXiv 1802.03916) 의 eq. (3) — $w(y) = q(y) / p(y)$, p = source = train, q = target = val — 와 정확히 일치합니다. weighted ERM 의 sample weight 가 source distribution 의 expectation 을 target distribution 의 expectation 으로 변환하는 importance ratio 라는 점에서 이 방향이 표준이고, plan 의 표기는 정확합니다.

(c) BBSE estimator — $\hat{c}^{\{-1\}}$ 만으로는 binary 에서 부족. plan §2.2(3) 는 confusion-matrix BBSE estimator $\hat{C} \in \mathbb{R}^{C \times C}$, $\hat{C}_{\{ij\}} = \hat{P}_{train}(\hat{y}=i, y=j)$, $w_{BBSE} = \hat{C}^{\{-1\}} \hat{P}_{val}(\hat{y})$ 를 "참고만" 으로 두고, oracle $w(c)$ 와의 L1 차이 $bbse_err$ 만 산출한다고 했습니다. 두 가지 문제가 있습니다.

첫째, BBSE 는 *joint* 분포 $\hat{P}_{train}(\hat{y}=i, y=j) = \hat{P}_{train}(\hat{y}=i|y=j) \cdot \hat{P}_{train}(y=j)$ 의 추정인데 plan 표기 $\hat{C}_{\{ij\}} = \hat{P}_{train}(\hat{y}=i, y=j)$ 는 *joint* 인지 *conditional* 인지 모호합니다. 정확히는 BBSE eq. (3) 의 $\hat{C}_{\{ij\}} = (1/n_{train}) \cdot \sum_k \mathbb{1}[\hat{y}_k = i, y_k = j]$ 이 joint 이고, 이 joint 의 $\hat{C}^{\{-1\}}$ $\mu_{val}(\hat{y})$ 가 $q(y)$ 를 직접 추정 (weight w 가 아니라 marginal q 를). w 는 $\hat{q}(y) / \hat{p}(y)$ 의 elementwise division 으로 산출. plan 표기는 estimator 의 직접 산출 이 w 인 것처럼 읽혀 혼동 여지가 있

습니다. 수정사항 2 — $\hat{C}$ 의 정의 (joint, not conditional) 와 BBSE 가 직접 산출하는 것이 $\hat{q}_{val}(y)$ 이고 w 는 그 후 elementwise division 임을 명시.

둘째, plan §2.4 에서 "C=2 의 binary 에서는 BBSE estimator 자체가 trivial" 이라 무력화시켰는데, 이건 실용적으로는 맞지만 수학적으로는 부정확합니다. binary 에서 BBSE 가 trivial 한 이유는 oracle $P_{val}(y)$ 를 우리가 알기 때문이지, BBSE 자체가 비정의이거나 부정확해서가 아닙니다. multi-class (MNLI C=3, AG News C=4) 에서 BBSE 의 confusion matrix conditioning number $\sigma_{min}(\hat{C})$ 가 작으면 (모형이 weak 일수록 작아짐) RLLS (Azizzadenesheli, Liu, Yao, Anandkumar 2019, arXiv 1903.09734) 의 regularized estimator 가 BBSE 보다 안정. plan 의 sanity check (bbse_err L1) 는 oracle vs BBSE 의 정확도 만 측정하고 *conditioning* 은 측정하지 않습니다. 수정사항 3 — bbse_err 와 함께 $\sigma_{min}C_{hat}$ ($\hat{C}$ 의 smallest singular value) 와 $condC_{hat}$ 를 산출, multi-class setting 에서 conditioning 이 wins 패턴과 상관되는지 sanity check.

(d) Oracle weighted balanced risk 의 "label shift 만 있을 때 reachable best" 가정. plan §2.2(4) 가 weighted risk $R_w(\hat{y}) = (1/n_{val}) \sum_{(x,y) \in val} w(y) \cdot \mathbb{I}[\hat{y}(x) \neq y]$ 를 정의하면서, 이 risk 가 acc_balanced 의 special case ($w(c) = 1 / (C \cdot P_{val}(c))$) 라고 (정확히) 짚었습니다. 그러나 plan 본문이 암묵적으로 가정 한 것 — "oracle w-weighted risk 가 label shift 만 있을 때 reachable best predictor 의 risk 와 일치" — 은 틀립니다. Sugiyama, Krauledat, Müller 2007 의 covariate shift importance-weighted ERM 의 *unbiased* 성격이 label shift 의 BBSE 세팅에서도 동일 하게 성립한다는 점은 맞지만, *reachable best* 는 ERM 의 ridge 규제 선택 (우리는 $\rho = 10^{-2}$ 고정) 과 sample-size 의 finite-sample variance 에 의존합니다. weighted ERM 이 *asymptotically* ($n_{val}, n_{train} \rightarrow \infty$) optimal 이라는 것과 finite sample 에서의 best 가 동일하지 않다는 점은 BBSE paper 의 Theorem 3 (weight estimation error bound $\|\hat{w} - w\|_2 = O(1/\sigma_{min}(C) \cdot \sqrt{(C/n)})$) 에 의해 $n_{val} \approx 250$ 의 small-budget regime 에서 명시적으로 큰 variance 를 갖습니다. plan §2.3 에서는 이 점이 "weighted risk gap" 의 측정 한계로만 짧게 언급되어 있는데 (acc 만 갖고 risk reconstruct 어려움), 사실은 더 큰 limitation 입니다 — oracle weight $w(c)$ 가 *known* 임에도 weighted-balanced risk 가 best reachable 의 proxy 일 뿐이라는 점이 본문에서 명시되어야 합니다. 수정사항 4 — §2.2(4) 끝에 "BBSE weighted risk 가 reachable best 의 lower bound 가 아니라 *importance-weighted estimator* 의 risk proxy 일 뿐이고, finite sample ($n_{val} \leq 1000$) 에서는 $O(\sqrt{(C/n_{val})})$ order of variance 를 가짐" 한 줄 추가.

(e) kl_s_val 의 quality proxy 근거. plan §2.2(5) 의 $kl_s_val = KL(P_S(y) \parallel P_{val}(y))$ 가 "selected subset 의 quality proxy" 라는 가정은 직관적으로는 맞 지만 *literature* 근거 가 plan 에 없습니다. 가장 가까운 근거는 Garg, Wu, Smyl, Lipton (NeurIPS 2020, "A Unified View of Label Shift Estimation", arXiv 2003.07554) 의 §3 에서, weighted ERM 의 excess risk 가 $\|P_S - P_{val}\|_{TV^2}$ 의 order 로 bounded 라는 점입니다 (TV 와 KL 의 Pinsker inequality 로 KL 도 같은 order). plan 의 H1 falsifier 임계값 (Spearman ≥ 0.3 , $|r| < 0.2$ 이면 reject) 의 근거 가 이 bound 의 *order of magnitude* 와 연결되어야 설득력 있습니다. 수정사항 5 — §2.2(5) 에 "Garg 2020 의 weighted ERM excess risk bound 의 dominant term 이 $TV(P_S, P_{val})$ 임 (Pinsker 로 KL 도 same order)" 한 줄 + bibliography 에 [B-Garg20] 추가.

§2. Lens 2 — spectral / KTA quantity 정의의 수학적 정확성

plan §3.2 의 quantity 9 개 ($c^2_{train}, c^2_{val}, s_i, kta_{train_full}, kta_{val}, kta_{train_r}, kta_{gap_r}, LC_, PR_, overlap$) 를 점검합니다.

(a) Nyström extension 으로 val projection — 식이 정확하지 않습니다. plan §3.2(2) 의 식 $c^2_{val} = \sum_c ((1/\lambda_i) \cdot u_i^T K_{\{train, val\}} \cdot \tilde{y}_{\{val, c\}})^2 \cdot (n_{val}/n)$ 이 다음 두 점에서 부정확 합니다.

첫째, Nyström extension 의 standard 식 (Williams & Seeger 2000, NeurIPS, "Using the Nyström Method to Speed Up Kernel Machines"; 후속으로 Drineas & Mahoney 2005 JMLR vol. 6 의 eq. (5)) 은 train kernel 의 i-번째 eigenfunction ψ_i 의 out-of- sample value 가

$$\hat{\psi}_i(x_{\text{new}}) = (\sqrt{n} / \lambda_i) \cdot u_i^T K(x_{\text{train}}, x_{\text{new}})$$

입니다 (여기서 u_i 는 train kernel 의 normalized eigenvector — $\|u_i\|_2 = 1$, λ_i 는 그 eigenvalue, K 는 일반 kernel function). plan 의 식에는 $\sqrt{n}$ factor 가 빠져 있습니다. 그래서 $(1/\lambda_i) \cdot u_i^T K_{\{\text{train}, \text{val}\}}$ 만 곱하면 magnitude 가 train side 의 $u_i^T \tilde{Y}_{\text{train}}$ 과 비교 가능한 scale 이 아닙니다. n_{val}/n 의 추가 factor 는 *partial* 보정이지만 ($n_{\text{val}} \neq n$ 일 때 sum 의 stochastic mean scale 조정), Nyström 의 $\sqrt{n}$ factor 와는 다른 보정입니다.

둘째, plan 식은 $\psi_i(x_{\text{val}})$ 를 각 val sample 별로 평가한 vector 의 내적 형태가 아니라 $u_i^T K_{\{\text{train}, \text{val}\}} \cdot \tilde{y}_{\{\text{val}, c\}}$ 의 matrix product 로 적었습니다. 정확히 풀면 ($u_i^T K_{\{\text{train}, \text{val}\}}$) 가 길이 n_{val} 의 row vector 이고 (이게 $\sqrt{n} \cdot \lambda_i$ 배 scaling 차이로 $\psi_i(x_{\text{val}})$ 의 sample 평가값과 일치), 이걸 $\tilde{y}_{\{\text{val}, c\}}$ 와 내적 하면 length-1 scalar — 이것이 *train side* $c_i \equiv u_i^T \tilde{y}_{\text{train}}$ 의 val-version 의 *proxy*. 따라서 정확한 식은

$$c_{i, \text{val}, c} := (1/\lambda_i) \cdot u_i^T K_{\{\text{train}, \text{val}\}} \cdot \tilde{y}_{\{\text{val}, c\}} \cdot (1/\sqrt{n_{\text{val}}}) \quad c_i^2_{\text{val}} := \sum_c c_{i, \text{val}, c}^2$$

이고, scaling factor $1/\sqrt{n_{\text{val}}}$ (혹은 $\sqrt{n} / (\sqrt{n_{\text{val}}} \cdot \lambda_i)$ 의 dimension match) 가 정확히 어떻게 들어가는지는 plan 이 의도한 *empirical estimator vs population projection* 의 정합성에 의존합니다. 수정 사항 6 — plan §3.2(2) 의 식을 Williams & Seeger 2000 의 eq. (4) 표기 ($\hat{\psi}_i(x_{\text{new}}) = (\sqrt{n} / \lambda_i) \cdot u_i^T k(x_{\text{train}}, x_{\text{new}})$, k 는 length- n vector) 로 명시 재유도 하고, 그 후 $c_{i, \text{val}, c} = (1/n_{\text{val}}) \sum_j \hat{\psi}_i(x_{\text{val}}, j) \cdot \tilde{y}_{\{\text{val}, c\}}(j)$ 의 sample mean form 으로 풀어 쓰기. NTK pickle 의 schema 와 무관하게 식 자체가 정확해야 lens 2 가 falsifiable.

(b) NTK pickle 의 $K_{\{\text{train}, \text{val}\}}$ block 의 존재 여부 — schema 가 plan 에 미명시. plan

§3.2(2) 끝과 §3.4 의 입력 명세가 "NTK pickle 의 `bundle["ntk"].shape` 를 출력해 확인" 의 fallback 만 두고, 실제 *schema* 가 무엇인지 사전 확인을 미뤘 습니다. `imbalance_ntk/.../*.pkl` 의 파일명에 `val<N>` 또는 `valbal<N>` 또는 `valimb<N>_...` 이 들어가 있고 두 개 (train + val) sample 의 size 가 함께 encoded 된 점 — sst2 의 `num5000_valbal856` 이면 `5000+856` 의 full kernel 가능 성이 큼 — 으로 보아 full $(n+n_{\text{val}}) \times (n+n_{\text{val}})$ gram 일 가능성이 높지만, plan 단계에서 확정 필요. 수정사항 7 — §1 build script 의 첫 sanity check 로 `ntk.shape` 검증 + `assert ntk.shape == (n+n_val, n+n_val)` 명시, 만약 train-only 면 lens 2 의 val-projection 은 제거 *not fallback* (proxy 가 부정확해 H3, H4 의 falsifier 가 무력해짐). FreeShap codebase 의 `compute_ntk` 함수 (references/ Freeshap.pdf Appendix C 또는 source) 를 직접 확인해 schema 를 미리 못 막는 것이 plan 단계에서 가능합니다.

(c) KTA 정의 — Cristianini 2001 의 식과 일치. plan §3.2(4) 의 $KTA_{\text{train}} = (K_{\text{train}}, \tilde{Y}_{\text{train}} \tilde{Y}_{\text{train}}^T)_F / (\|K_{\text{train}}\|_F \cdot \|\tilde{Y}_{\text{train}} \tilde{Y}_{\text{train}}^T\|_F)$ 는 Cristianini, Shawe-Taylor, Elisseeff, Kandola (NIPS 2001, "On Kernel-Target Alignment") 의 eq. (1) (그들은 단순히 $A(K_1, K_2) = (K_1, K_2)_F / \sqrt{((K_1, K_1)_F (K_2, K_2)_F)}$ 와 정확히 일치합니다. 분모의 normalization 도 맞고 mean-centering 에 대한 plan 의 추가 설명 (Cortes-Mohri 2012 의 centered KTA 가 redundant — $\tilde{Y}$ 가 이미 column mean centering 되어 있으므로) 도 정확합니다. 다만 *centered KTA* 의 표준 정의는 Y 의 centering 이 아니라 *kernel* 의 centering — $K_c = H K H$, $H = I - (1/n)11^T$ — 이므로, plan 의 진술 (" $\tilde{Y}$ 가 이미 mean-centered 라 redundant") 은 절반만 맞습니다. K 의 centering 은 추가 효과가 있습니다 (constant eigenmode 의 제거). 다행히 우리 setup 의 train data 는 stratified subsample 이라 mean shift 가 작고, *uncentered KTA* 와 centered KTA 의 ranking 이 거의 동일할 가능성이 크지만, 이 점이 plan 에 명시되어야 합니다. 수정사항 8 — plan §3.2(4) 끝에 "K-centering 은 Cortes-Mohri 2012 의 eq. (5), 우리 stratified subsample 의 near-zero mean K eigenmode 가정 하에 KTA ranking 에 미

치는 영향이 작다고 expect. sanity check 로 $K_c = H K H$ 의 KTA 도 함께 산출, 두 ranking 의 Kendall $\tau \geq 0.95$ 면 uncentered 사용" 한 줄 추가.

(d) top-r KTA 의 mode-wise decomposition — 분모 normalization 의 의심. plan §3.2(5) 가 $KTA_{train}(r) = (\sum_{i \leq r} \lambda_i \cdot ci^2_{train}) / (\sqrt{\sum_{i \leq r} \lambda_i^2} \cdot \|\tilde{Y}\tilde{Y}^T\|_F)$ 라고 적고 출처를 "arxiv 2108.08752 의 chapter 3 의 식 (5)" 라고 했는데, 이 식 자체의 두 가지 의심점이 있습니다.

첫째, KTA 의 full kernel 정의 $\langle K, \tilde{Y}\tilde{Y}^T \rangle_F / (\|K\|_F \cdot \|\tilde{Y}\tilde{Y}^T\|_F)$ 와 eigen expansion $K = \sum_i \lambda_i u_i u_i^T$ 를 대입하면 $\langle K, \tilde{Y}\tilde{Y}^T \rangle_F = \sum_i \lambda_i \cdot u_i^T \tilde{Y}\tilde{Y}^T u_i = \sum_i \lambda_i \cdot ci^2$ 이고 $\|K\|_F^2 = \sum_i \lambda_i^2$. 따라서 full KTA = $(\sum_i \lambda_i ci^2) / (\sqrt{\sum_i \lambda_i^2} \cdot \|\tilde{Y}\tilde{Y}^T\|_F)$. plan §3.2(5) 의 top-r KTA 는 이 식의 분자만 top-r 로 truncate 하고 분모의 $\sqrt{\sum_{i \leq r} \lambda_i^2}$ 도 top-r 로 truncate 했는데, 분자와 분모의 truncate 가 일관 하다면 이 식은 top-r kernel $K_r = \sum_{i \leq r} \lambda_i u_i u_i^T$ 의 KTA 가 됩니다. 이게 plan 의 의도면 정확하고, 출처 표기를 "arxiv 2108.08752" 보다는 직접적인 K_r 의 KTA 정의 — full KTA 의 top-r 절단판 — 으로 자기 충족적으로 정의해도 됩니다. 수정사항 9 — plan §3.2(5) 의 출처 "arxiv 2108.08752 의 chapter 3" 가 정확히 어떤 chapter 인지 확인 (이 arXiv ID 가 어떤 paper 인지 plan 에 명시되어 있지 않음 — Bach 2008 의 kernel methods chapter 일 가능성?). 정확히 출처가 모호하면 self-contained derivation 으로 대체: "top-r KTA 는 $K_r = \sum_{i \leq r} \lambda_i u_i u_i^T$ 의 KTA 이며 분자·분모 모두 top-r 절단 (식 풀이는 부록)".

둘째, mode-wise decomposition 에서 분모의 $\|\tilde{Y}\tilde{Y}^T\|_F$ 가 r 에 무관하게 full label 의 norm 으로 고정된 점은 r 별 비교에서 상대 scale 만 보존하고 KTA 가 $[0, 1]$ range 에 있다는 성질은 깨집니다 (full KTA 만 $[0, 1]$, top-r KTA 는 $[0, full_KTA]$ range). 이는 H3 의 Pearson r 측정에서 monotone 관계만 잡으면 되므로 큰 문제 아님 이지만, plan §3.5 의 "absolute KTA 는 dataset 간 비교에 약함, gap 만 사용" 진술과 일관시켜 "top-r KTA 도 dataset-internal r-sweep 에만 사용" 을 명시하는 게 좋습니다. 수정사항 9 의 일부로 함께.

(e) PR(c^2) 의 plan 정의 — iter_03 와 일치 확인. plan §3.2(8) 의 $PR_{train} = (\sum_i ci^2_{train})^2 / \sum_i (ci^2_{train})^2$ 는 iter_03 report §1 의 eq. (2) ($PR(c^2) := (\sum_i ci^2)^2 / \sum_i ci^4$) 와 정확히 일치 (분모 $\sum (ci^2)^2 = \sum ci^4$ 동일). 정의는 OK. 다만 iter_03 에서 산출한 PR(c^2) 값 (MRPC 274.94, QQP 134.57 등) 이 $n=5000 \times 3$ -seed 평균이고, iter_04 의 grand_meta.csv 에서는 n 이 데이터셋·setting 별로 다르므로 (mrpc 의 valbal 은 $n=2300$, mr 의 valbal 은 $n=4500$) iter_03 의 값과 직접 비교 가능한지 plan 에 명시되어야 합니다. PR 자체는 normalization-free 라 n 에 무관하다고 기대 하지만, finite-n 의 noise floor $(C-1)\sigma^2/n$ 가 PR 의 denominator 에 들어가 작은 n 에서 PR 이 overestimated 됩니다 (작은 ci^4 가 noise 로 부풀려져 분모가 커지고 PR 이 작아진다는 의미가 아니라, 정반대 — small ci^2 의 chi-square noise 때문에 ci^4 의 분포 tail 이 두꺼워져 PR 이 underestimated). 이 finite-n bias 의 방향을 plan 에서 한 줄 인정하고, iter_03 의 $n=5000$ 값과 비교 시 순서만 안정한지 검증 절차 필요. 수정사항 10 — §3.2(8) 끝에 "PR 은 small-n underestimation bias 있음, iter_03 ($n=5000$) 와의 비교는 ranking 만 유효, 절댓값 비교는 보류" 한 줄 추가.

§3. H1-H4 falsifier 임계값의 적절성 — multiple testing 과 power

plan 의 H1 (Spearman ≥ 0.3), H2 (Pearson ≥ 0.5), H3 (Pearson ≥ 0.5), H4 (Pearson ≥ 0.3) 의 임계값과 cell/setting 수를 통계적 power 측에서 점검합니다.

(a) cell 수 와 multiple testing. plan §3.3 의 H3 는 21 valbal setting 의 cross-dataset correlation 이고 H4 는 18 trainbal setting. setting 단위 의 n 이 21 또는 18 으로 작아 Pearson r 의 95% CI 가 매우 wide: $n=21$ 에서 $r=0.5$ 의 CI 는 약 $[0.08, 0.77]$, $n=18$ 에서 $r=0.3$ 의 CI 는 $[-0.20, 0.66]$ 으로 zero 를 cross 합니다 (Fisher transformation 기반). 따라서 plan 의 임계값 $r \geq 0.3$ 면 confirm 또

는 $r \geq 0.5$ 면 confirm 은 충분히 strict 가 아닙니다 — 실제 mechanism 이 있어도 small-n 의 sample variance 만으로 r 이 0.3 부근으로 떨어질 가능성이 큼.

대안 — H3, H4 를 cell 단위 hierarchical 로 재정의하는 게 더 안전합니다. setting 단위 의 cross-dataset correlation 외에, cell 단위 (setting $\times$ method $\times$ rank_pct $\times$ sel) 의 paired comparison (e.g., 같은 setting 의 A1 cell vs LR cell 의 차이를 outcome 으로) 으로 가면 n 이 ~ 880 (valbal) 또는 ~ 750 (trainbal) 로 늘어나고, dataset 을 random effect 로 처리하면 hierarchical 적절. cross-dataset correlation 의 raw r 만 보면 confounding (dataset-level fixed effect) 이 흡수 되지 않습니다.

수정사항 11 — H1-H4 의 검증을 (i) setting 단위 marginal Pearson/Spearman + 95% CI (Fisher), (ii) cell 단위 linear mixed model — `outcome ~ predictor + (1 | dataset)` 의 fixed coefficient β 와 그 95% CI — 두 형태로 둘 다 보고. linear mixed model 의 β 가 zero 를 cross 하지 않으면 더 신뢰. lme4 의 R 또는 statsmodels 의 MixedLM 으로 구현 (analysis script 에 dependency 추가).

(b) multiple-testing 보정. plan 은 H1-H4 의 4 개 hypothesis 를 동시에 test 하고 추가로 sub-group 분석 ($sel \leq 5\%$, $sel \in [10, 20]$, $sel \geq 50$, regime 별, method 별) 을 함. 나이브하게 모든 sub-group 의 p-value 를 reported 하면 multiple testing 문제 — 4 main + 12 sub ≈ 16 test 의 Bonferroni 보정은 $0.05/16 \approx 0.003$ 의 strict 임계값. Plan 에 이 보정의 언급이 전혀 없음. 수정사항 12 — hypothesis 검증의 보정 정책 명시 — main 4 (H1-H4) 만 pre-registered primary, 나머지 sub-group 은 exploratory 로 표시. primary 의 Bonferroni 임계값 $\alpha/4 = 0.0125$ 또는 BH (Benjamini-Hochberg) 적용.

(c) Pearson ≥ 0.5 의 false-negative risk. plan 의 H2, H3 의 임계값 0.5 가 overly strict 이라는 비평이 정당합니다. $n=21$ 의 setting 단위에서 true $r = 0.4$ 의 mechanism 이 있어도 sample r 의 std 가 약 $(1 - 0.4^2) / \sqrt{21 - 2} \approx 0.193$ 로 크고, observed r 이 0.3 부근으로 떨어질 확률이 25% 이상. 0.5 cutoff 면 mechanism 이 약하지만 real 인 경우 reject 가 false. 더 적절한 정책은 (i) 임계값을 effect size 만 으로 보지 말고 p-value (multiple-testing 보정 후) 와 함께 판정, (ii) "reject" 의 정의를 $r < 0.2$ AND $p > 0.1$ 같이 명확한 null evidence 로 강화. plan §2.1, §3.1 의 falsifier 정의를 이 두 조건 결합으로 재서술. 수정 사항 13 — falsifier 임계값을 effect size + p-value 의 결합으로 재정의.

(d) H1 의 Spearman ≥ 0.3 — partial Spearman 의 자유도 손실 고려. plan §2.3 의 H1 검증이 trainbal small-budget ($sel \in \{1, 2, 3, 5\}$, method=A1, rank_pct=10%) 의 cell 4 개 $\times$ 18 setting = 최대 72 cell 입니다. covariate train_majority + val_majority 의 partial Spearman 은 자유도가 $n - 3 = 69$ 정도로 충분하나, 이 72 cell 안에서 setting 당 4 cell 의 within-setting correlation (같은 setting 의 $sel = 1, 2, 3, 5$ 의 cell 은 독립이 아님) 이 무시되면 effective sample size 가 ~ 18 (setting 수) 까지 떨어집니다. 수정사항 14 — H1 의 partial Spearman 도 setting 단위 평균 으로 정의 (each setting 내에서 $sel \in \{1, 2, 3, 5\}$ 평균을 한 점으로) 또는 mixed model 로 within-setting 종속성 처리.

§4. iter_03 framework mapping 의 정확성

plan §6 의 mapping table 7 개 row 를 점검합니다.

(a) Cond 1 $\leftrightarrow$ LC_train(r). "iter_03 의 LC_LR(r) $\equiv$ iter_04 의 LC_train(r) = $(\sum_i \{i \leq r\} ci^2_{train}) / (\sum_i ci^2_{train})$ " 의 동치 주장은 정확합니다 (iter_03 §1 의 LC LR 정의가 정확히 이 형태). $r=10\%$ 외 다른 r 에서의 validity 도 iter_03 §6 부록 ("LC_LR(r) r-robustness, $n=5000$, $r=5\sim 30\%$ 에 ranking 유지") 으로 이미 검증됨. OK.

(b) Cond 2 cause-side $\leftrightarrow$ KTA train. plan §6 의 "Cond 2 의 spectral 정량화는 train kernel 의 top-r 이 train-label spread (PR_{train} large) 와 weak alignment ($KTA_{train}(r)/KTA_{full}$ small) 의

결합인 *setting* 에서 *collapse*" 는 *heuristic equivalence* 입니다 — KTA 와 PR 두 quantity 가 "label 정보의 top-r 흡수" 의 *dual measure* 라는 직관은 정당하지만, 두 측정이 수학적으로 동치 라는 증명은 없습니다. 사실 두 측정은 dimension 이 다릅니다: $PR(c^2)$ 는 c^2 의 분포 spread 의 inverse 차원의 measure ($\sum c_i^2 / \max c_i^2$ 의 일종), $KTA(r)/KTA_full$ 은 r-mode 의 label-explanatory ratio. 경험적으로 두 measure 가 강하게 correlate 할 수 있지만 (특히 spectrum 이 power-law decay 일 때), 원리적 동치 의 주장은 약 합니다. 수정사항 15 — plan §6 의 mapping table 의 $PR(c^2)$ row 표현을 "*spectral reformulation*" 또는 "*complementary spectral measure*" 로 완화, 동치 주장은 삭제. 본문에서도 " $PR(c^2)$ 와 $KTA(r)/KTA_full$ 의 Spearman correlation 을 cross- dataset 측정해 두 measure 의 redundancy 정량화" 라는 검증 procedure 를 추가하면 더 좋음.

(c) C ↔ Cond 3 ↔ lens 1 의 $KL(P_{train} \parallel P_{val})$. plan §6 의 마지막 row 가 "Cond 3 (multi-class $\sqrt{(C-1)}$ SNR) ↔ lens 1 의 $KL + \sqrt{(C-1)}$ SNR" 으로 mapping 했 는데, 이 매핑이 부정확 합니다. iter_03 의 Cond 3 mechanism 은 label 의 *number of classes* C 와 noise reduction 의 관계인데, lens 1 의 label shift framework 은 $P_{train}(y) \neq P_{val}(y)$ 의 measure 입니다. 두 mechanism 은 *independent*: binary balanced (C=2, KL=0) 와 binary imbalanced (C=2, KL>0) 가 모두 가능하고 multi-class balanced (C=3, KL=0) 와 multi-class imbalanced (C=3, KL>0) 도 모두 가능. plan §6 의 표현은 두 mechanism 을 혼동 시킵니다. 수정사항 16 — mapping table 의 C row 를 삭제 하거나 "Cond 3 (multi-class noise reduction) 은 lens 1-4 의 어떤 *lens* 도 직접 cover 하지 않으며, iter_04 의 분석 범위 밖. C-sweep 실험은 next_directions 의 item 1 로 이관" 으로 명시.

§5. 분석 스크립트 spec 의 충분성

plan §1, §3.4 의 두 script (build_grand_df.py, lens2_kta_spectral.py) 와 implicit 한 lens1_label_shift.py 의 spec 을 점검합니다.

(a) 3 개 script 가 모든 quantity 를 cover 하는가. plan 의 §8 산출물 체크 리스트에서 lens 1 의 lens1_table.csv, lens1_corr.csv 가 명시되어 있는데, 생산 스크립트 인 lens1_label_shift.py 의 명세가 §2 본문에 암묵적 으로만 존재하고 별도 §sub-section 으로 정리되지 않았습니다. lens 2 의 §3.4 만큼 명세 정리가 필요. 수정사항 17 — plan §2 에 §2.5 "스크립트 spec — experiments/lens1_label_shift.py" sub-section 추가 (입력: grand_df.csv, grand_meta.csv; 출력: lens1_table.csv, lens1_corr.csv; column schema; estimated cost).

(b) NTK kernel pickle 의 위치와 format. plan §1 의 grand_meta.csv 의 ntk_path column 은 상대경로 만 명시하고, pickle 의 내부 schema (ntk, per_class_counts, sampled_val_idx, kernel_eigvals 등의 key 가 정확히 무엇 인지) 는 추정 으로 적혀 있습니다. plan §1 끝의 "개시 schema: npz 에 eigvals, eigvecs, Y_tilde, Y_val_tilde" 가 우리가 만들 cache 의 schema 이고, 원본 pickle 의 schema 는 모름. 수정사항 18 — plan §1 의 build script 첫 단계 로 "임의 pickle 한 개를 열어 bundle.keys() 출력 + 각 value 의 type, shape, dtype 기록, 결과를 state/iteration_04/ntk_schema.md 에 인덱싱. 그 schema 가 plan 의 모든 quantity 산출에 충분한지 (특히 $K_{\{train, val\}}$ block) 확인" 단계를 명시. 이게 lens 2 의 H3, H4 falsifiability 의 전제조건 이라 가장 우선되어야 하는 sanity check.

(c) cell 단위 cross-dataset correlation 의 통계 절차. plan 은 (§3.3) cell 단위 correlation 을 setting 수 21 또는 18 의 cross-dataset Pearson 으로 측정한 다고만 했고, 어떤 dataset 을 pool 하는지 (모든 7-dataset?), dataset random effect 처리 정책 (fixed effect 로 빼는가, mixed model 의 random intercept 인가) 의 명세가 없습니다. 수정사항 19 — plan §3.3 끝에 "통계 절차: (i) primary — outcome ~ predictor 의 cross-dataset Pearson + 95% Fisher CI, (ii) secondary — outcome ~ predictor + (1 | dataset) 의 lme4-style mixed model 의 fixed β + 95% CI, (iii) tertiary — 각

dataset 별 within-dataset Spearman 의 분포 (median, IQR) 로 dataset-heterogeneity 확인" 의 3-tier 명시.

§6. 누락된 분석

(a) trainbal random-loss 의 operational 정의. plan 의 핵심 motivation 인 "trainbal 의 절반 case 에서 A1 이 random 한테 진다" 가 quantitative threshold 의 명시 없이 plan 전반에 사용됩니다. 정확한 정의 — $\text{gap_top_random_balanced}[A1, r=10\%, \text{sel}=5] < 0$ (random 보다 A1 이 acc 낮음) 인 cell 의 비율 — 가 plan 에 명 시되지 않았고, "절반" 이라는 표현이 사용자 directive 의 대략적 관찰 이라 plan 에서 정량적 *outcome* 으로 변환 필요. 수정사항 20 — plan §6 의 (Q3) 답안 시작 부분에 "trainbal random-loss 의 operational 정의: $\text{gap_top_random_balanced}[A1, r=10\%, \text{sel} \in \{1, 2, 5\}] < -0.02$ (-2pp 이상 random 에 짐) 인 cell 의 비율을 random-loss-rate 로 정의, 이 rate 가 H1 의 outcome metric" 한 줄 추가. threshold -0.02 는 acc 측정 noise (val_size 200-1000 의 binomial std 약 1-3pp) 보다 큰 영 역을 잡기 위한 선택.

(b) imbalance level 별 separately correlation. plan 의 cross-dataset correlation 은 모든 imbalance level (mild = 70/30 or cls55/15/15/15, extreme = 90/10 or cls85/05/05/05) 을 *pooled* 로 처리합니다. 그러나 lens 1 의 KL 측정 이 mild 와 extreme 에서 *order-of-magnitude* 차이 ($\text{KL}(0.7, 0.5) \approx 0.09$, $\text{KL}(0.9, 0.5) \approx 0.51$) 가 나서, pooled correlation 이 *almost mechanical* (extreme cell 이 KL 큰 + collapse 큰 $\rightarrow r > 0.5$ 의 trivial 발견) 일 위험. 수정사항 21 — H1-H4 의 검증 에서 imbalance level 별로 separate correlation 도 산출 — $\text{level} \in \{\text{mild}, \text{extreme}\}$ 의 stratified analysis. mild-only 에서도 H3, H4 의 correlation 이 significant 면 mechanism 의 robustness 더 강한 evidence.

(c) sel% 별 non-linear effect (sel = 1% 만 collapse). iter_03 와 iter_04 의 사이드카 관찰에서 $\text{sel} = 1\%$ 의 극단 *small budget* 만 LR collapse 가 가장 sharp 한 영역으로 알려져 있습니다 (plan §3.3 의 H3 검증 cell $\text{sel} \in \{3, 5, 10\}$ 이 이 영역을 cover 안 함). 수정사항 22 — H3 의 cell sweep 에 $\text{sel} = 1$ 도 포함 (즉 $\text{sel} \in \{1, 3, 5, 10\}$ 의 4 점 평균), 그리고 sel-별 *separate* correlation 도 산출해 non-linear 의존성 확인.

§7. 외부 자료 활용의 명시도

plan 의 §7 (참고) 와 본문 인용 의 정확도를 점검합니다.

(a) Saerens 2002 의 인용. plan §2.1, §2.2 에서 "Saerens-Latinne-Decaestecker 2002 의 EM-style estimator" 라고 brief 인용했는데, 정확히 어떤 식 이 우리 lens 1 의 어디서 사용되는지 명시 부족. Saerens 2002 의 *core contribution* 은 EM algorithm 으로 $P_{\text{val}}(y)$ 를 추정하는 *iterative procedure* (그들 paper 의 eq. (5)-(8)). plan 의 lens 1 은 oracle $P_{\text{val}}(y)$ 를 갖고 있어 EM 이 필요 없는 setup — 즉 Saerens 2002 의 *iterative estimator* 는 직접 사용 안 함, 단지 *label shift framework* 의 *origin* 으로만 인용. 수정사항 23 — plan §2.1 의 Saerens 2002 인용을 "prior shift correction 의 EM-based estimator (직접 사용 안 함, framework origin)" 로 한정. BBSE 의 *closed-form* estimator (Lipton 2018 eq. (3)) 가 우리 setup 에 서 실제로 쓰이는 식.

(b) Lipton 2018 의 어떤 식. plan §2.2(2) 가 $w(c) = q(y)/p(y)$ 를 "BBSE Eq. (3)" 으로 인용했는데 정확한 BBSE eq. 가 무엇인지 본문에서 직접 명시되지 않았 습니다 (arXiv 1802.03916 의 eq. (3) 가 importance weight 정의, eq. (4)-(6) 가 estimator). 수정사항 24 — plan §2.2 의 각 인용에 eq. 번호 명시. 구체적으로 (i) $w(c)$ 의 정의 $\rightarrow$ Lipton 2018 eq. (3), (ii) BBSE estimator $\rightarrow$ eq. (4)-(5) (또는 Theorem 3 의 식), (iii) consistency bound $\rightarrow$ Theorem 3.

(c) KTA 의 Cristianini 2001 식 (1). plan §3.2(4) 의 KTA 정의가 어느 식 에서 왔는지 plan §7 의 reference 에는 "NIPS 2002" 로 잘못 표기되어 있습니다 (실제는 NIPS 2001 — 12월 발표, paper 인쇄는 다음해 proceedings volume 14). 수정 사항 25 — plan §7 의 KTA reference 를 "NIPS 2001 (proceedings volume 14, 2002)" 또는 "Cristianini et al. 2001, NIPS" 로 통일. paper 의 어떤 eq. — KTA 의 정의 eq. (1) — 인지 본문 §3.2(4) 에 명시.

(d) per-eigenvector KTA decomposition 의 출처 — arxiv 2108.08752. plan §3.2(5) 가 "arxiv 2108.08752 의 chapter 3 의 식 (5)" 라고 인용했는데, 이 arXiv ID 가 어떤 paper / book chapter 인지 plan 의 어디에도 명시되지 않습니다. 제가 검색 해본 결과 — arXiv 2108.08752 는 Canatar, Bordelon, Pehlevan 2021 "Spectral bias and task-model alignment explain generalization in kernel regression and infinitely wide neural networks" 의 longer version 일 가능성이 있지만, plan 의 chapter 3 식 (5) 가 정확히 어디인지 plan 단계에서 확인되어야 합니다. 수정사항 26 — plan §3.2(5) 의 출처를 직접 확인 (혹은 *self-contained derivation* 으로 대체, §2(d) 의 수정사항 9 와 동일).

§8. Cycle progression — 2 번째 라운드 critique 를 위한 output schema

plan 은 §8 의 산출물 체크리스트에 `lens1_table.csv`, `lens2_table.csv` 등의 파일 명만 적었고, 2 번째 라운드 *critique* (executor 결과 분석) 가 어떤 column 을 expect 할지 *output schema* 를 명시하지 않았습니다. 특히 `lens2_table` 의 column schema 는 §3.4 에 약 30 개 column 으로 풀어 적혀 있어 OK이지만, `lens1_table` 의 schema 는 plan 본문에 전혀 없음. 그리고 2 번째 라운드 *critique* 가 받아 분석 할 *correlation table* (`lens1_corr.csv`, `lens2_corr.csv`) 의 schema 도 `lens2` 만 spec 됨 (`regime`, `hypothesis_id`, `predictor`, `outcome`, `Pearson r`, `Spearman r`, `p-value`, `n_settings`), `lens1` 은 미명시.

수정사항 27 — plan §2.5 (수정사항 17 로 추가될 sub-section) 에 `lens1_table.csv` 의 column schema 명시. column 은 적어도 `setting_id` (`dataset + regime + train_ratio + val_ratio`), `C`, `n`, `n_val`, `P_train_y`, `P_val_y`, `kl_train_val`, `kl_val_train`, `w_vector`, `sigma_min_C_hat`, `cond_C_hat`, `bbse_err`, `kl_S_val` (cell-level, 별도 파일?), `risk_weighted_proxy`. `lens1_corr.csv` 도 `lens2_corr.csv` 와 같은 schema 로 통일.

수정사항 28 — 2 번째 라운드 *critique* 의 *input* 으로 들어갈 최소 *output set* 을 plan §8 끝에 명시: "executor 완료 시 critic 이 받아야 할 4 파일 — `grand_df.csv`, `lens1_corr.csv`, `lens2_corr.csv`, plus 4 개 figure (H1, H2, H3, H4 의 scatter)". 이 spec 이 없으면 2 번째 라운드 critic 이 어떤 *primary outcome* 을 보고 hypothesis 판정해야 하는지 모름.

§9. 기타 minor 점검

(a) $\rho = 10^{-2}$ 의 출처. plan §3.2(3) 가 $\rho = 10^{-2}$ 를 `eigen_lambda` (sidecar 의) 로 가정했는데, 이 값 이 모든 *setting* 에서 동일한지, *method* 별 (LR vs A1) 로 다른지 확인 필요. 만약 sidecar 별로 다르면 mode-wise learnability score $s_i = (\lambda_i / (\lambda_i + \rho))^2 \cdot c_i^2$ 의 ρ 가 cell 별로 다를 수 있어 cross-cell 비교 의 일관성 훼손. 수정사항 29 — §1 build script 에서 `eigen_lambda` 의 cross-sidecar 일관 성 확인, 만약 다르면 그룹별 separate 분석.

(b) random_results 의 sanity check 의 정확성. plan §1 의 (ii) sanity check ("random_results 가 method 간 거의 일치") 가 *seed mismatch* 차이만 허용 인데, 실제 random selection 의 *index* 가 method 별로 다를 수도 있습니다 (LRFShap 의 random vs A1 의 random 이 서로 다른 RNG seed 일 가

능성). 수정사항 30 — sidecar 의 `random_seed_used` field 가 있는지 확인, 없으면 `random_results` 의 method-간 일치를 *strict* 가 아니라 *moderate* (Spearman ≥ 0.9 같은 약한 기준) 로 완화.

(c) `acc_at_f0` 의 method-간 일치. plan §1 의 (i) sanity check ("`acc_at_f0` method 간 동일") 는 정확하지만, 실제 *sidecar* 에서 method 별로 `acc_at_f0` 가 저장될지 (모든 train 사용 시는 method 무관해야 함) 코드 단계에서 검증 필요.

§10. Actionable 수정사항 — planner 가 받아 plan 을 수정할 항목

이하 30 개 항목은 §1-§9 의 비평을 *plan* 수정 가능 단위 로 압축한 것입니다. 우선 순위 표기: **[필수]** = 다음 plan revision 에 반영 의무, **[권장]** = 가능하면 반영, **[선택]** = 시간 여유 시.

#	수정사항	우선
1	plan §2.2(1): KL 방향 통일 — main predictor $kl_val_train = KL(P_val \parallel P_train)$, kl_train_val 은 sensitivity check 용. 두 방향 산출은 유지하되 H1-H4 의 primary predictor 가 어느 방향인지 명시.	필수
2	plan §2.2(3): BBSE $\hat{C}_{\{ij\}} = (1/n) \sum \mathbb{I}[\hat{y}=i, y=j]$ 가 joint (not conditional) 임을 명시, BBSE estimator 의 직접 산출이 $\hat{q}_{val}(y)$ 이고 w 는 후속 elementwise division 임을 명시. Lipton 2018 eq. (3)-(5) 인용.	필수
3	plan §2.2(3): $bbse_err$ 외에 $\sigma_min_C_hat$, $cond_C_hat$ 도 column 추가. multi-class setting 에서 conditioning 의 wins 패턴 상관 sanity check.	권장
4	plan §2.2(4): weighted-balanced risk 가 reachable best 의 proxy 일 뿐, finite sample $O(\sqrt{(C/n_val)})$ order 의 variance 가짐을 한 줄 명시.	필수
5	plan §2.2(5): kl_S_val 의 quality proxy 근거로 Garg 2020 (arXiv 2003.07554) 의 weighted ERM excess risk bound (TV/KL of P_S , P_val) 인용. bibliography 에 [B-Garg20] 추가.	필수
6	plan §3.2(2): Nyström extension 식을 Williams & Seeger 2000 eq. (4) 표기 ($\psi_i(x_new) = (\sqrt{n} / \lambda_i) \cdot u_i^T k(x_train, x_new)$) 로 재유도. plan 의 현재 식은 $\sqrt{n}$ factor 누락.	필수
7	plan §1, §3.2(2): NTK pickle schema 의 사전 확인 — <code>bundle.keys()</code> , <code>bundle["ntk"].shape</code> 를 build script 의 첫 단계로 명시, 결과를 <code>state/iteration_04/ntk_schema.md</code> 에 인덱싱. $K_{\{train, val\}}$ block 부재 시 lens 2 val-projection 제거 (fallback proxy 사용 금지 — H3, H4 falsifier 무력화 위험).	필수
8	plan §3.2(4): K-centering 의 추가 효과 (constant eigenmode 제거) 명시. uncentered vs centered K 의 KTA ranking 의 Kendall $\tau \geq 0.95$ sanity check.	권장
9	plan §3.2(5): top-r KTA 식의 출처 명시 (arxiv 2108.08752 가 어떤 paper / chapter 인지) 또는 <i>self-contained derivation</i> ($K_r = \sum_{\{i \leq r\}} \lambda_i u_i u_i^T$ 의 KTA 의 직접 풀이) 으로 대체. top-r KTA 가 $[0, full_KTA]$ range 이고 dataset-internal r-sweep 에만 사용함을 명시.	필수
10	plan §3.2(8): PR 의 small-n underestimation bias 명시, iter_03 의 $n=5000$ 값과 iter_04 의 setting-별 n 값 비교는 <i>ranking</i> 만 유효.	권장
11	plan §3.3, §2.3: H1-H4 검증을 (i) setting 단위 marginal Pearson + 95% Fisher CI, (ii) cell 단위 linear mixed model (<code>`outcome ~ predictor + (1</code>	dataset)`) 의 fixed β + 95% CI 두 형태로 둘 다 보고. lme4 또는 statsmodels MixedLM dependency 추가.
12	plan §3.3, §2.3: multiple-testing 보정 정책 명시 — H1-H4 만 primary (Bonferroni $\alpha/4 = 0.0125$ 또는 BH 적용), sub-group (regime, sel range, method 별) 은 exploratory.	필수
13	plan §2.1, §3.1: falsifier 임계값을 effect size + p-value 결합으로 재정의 — "reject" = `	r

#	수정사항	우선
14	plan §2.3: H1 의 partial Spearman 을 <i>setting</i> 단위 평균 (each <i>setting</i> 의 $sel \in \{1, 2, 3, 5\}$ 평균을 한 점으로) 또는 mixed model 로 within-setting 종속성 처리.	필수
15	plan §6 mapping table: PR(c^2) row 의 "spectral 정량화 동치" 주장을 "spectral reformulation / complementary spectral measure" 로 완화. PR(c^2) 와 KTA(r)/KTA_full 의 cross-dataset Spearman 으로 redundancy 측정.	필수
16	plan §6 mapping table: C row (Cond 3 $\leftrightarrow$ lens 1) 삭제 또는 "iter_04 lens 1-4 가 cover 하지 않으며, next_directions item 1 (C-sweep 실험) 으로 이관" 으로 재서술. C $\leftrightarrow$ KL 의 혼동 제거.	필수
17	plan §2 에 §2.5 "스크립트 spec — experiments/ lens1_label_shift.py" sub-section 추가. lens 2 의 §3.4 만큼 입력/출력/column schema/estimated cost 명시.	필수
18	plan §1: build script 첫 sanity check 로 임의 pickle 한 개의 <code>bundle.keys()</code> + 각 value 의 type, shape, dtype 출력, 결과 state/iteration_04/ntk_schema.md 인덱싱. (수정사항 7 과 결합).	필수
19	plan §3.3: 통계 절차 3-tier 명시 — (i) Pearson + Fisher CI, (ii) lme4-style mixed model fixed β + CI, (iii) 각 dataset 별 within-dataset Spearman 분포.	필수
20	plan §6 (Q3) 답안 시작: trainbal random-loss 의 operational 정의 — <code>gap_top_random_balanced[A1, r=10%, sel $\in \{1, 2, 5\}$] < -0.02</code> 인 cell 의 비율을 random-loss-rate 로.	필수
21	plan §3.3, §2.3: H1-H4 검증에 imbalance level 별 <i>stratified</i> (mild=70/30 or cls55/15, extreme=90/10 or cls85/05) correlation 도 산출. pooled correlation 의 mechanical inflation 점검.	필수
22	plan §3.3: H3 cell sweep 에 <code>sel = 1</code> 추가 (<code>sel $\in \{1, 3, 5, 10\}$</code> 의 4 점), sel-별 separate correlation 도 산출해 non-linear 의존성 점검.	권장
23	plan §2.1: Saerens 2002 인용을 "prior shift correction 의 EM-based estimator (framework origin only, 직접 사용 안 함)" 으로 한정. BBSE 의 closed-form 이 실제 사용 식임을 명시.	권장
24	plan §2.2: 각 인용에 eq. 번호 명시 — w(c) 정의 $\rightarrow$ Lipton 2018 eq. (3), BBSE estimator $\rightarrow$ eq. (4)-(5), consistency bound $\rightarrow$ Theorem 3.	필수
25	plan §7 KTA reference: "NIPS 2002" $\rightarrow$ "Cristianini, Shawe-Taylor, Elisseeff, Kandola (2001) NIPS, proceedings vol. 14". paper 의 KTA 정의 eq. (1) 본문 §3.2(4) 에 명시.	권장
26	plan §3.2(5) 의 arxiv 2108.08752 인용 확인 — 정확한 paper title / chapter / 식 번호 검증 또는 self-contained derivation 으로 대체 (수정사항 9 와 결합).	필수
27	plan §2.5 (수정사항 17 로 추가될 sub-section): lens1_table.csv column schema 명시 — <code>setting_id, C, n, n_val, P_train_y, P_val_y, kl_train_val, kl_val_train, w_vector, sigma_min_C_hat,</code>	필수

#	수정사항	우선
	cond_C_hat, bbse_err, kl_S_val, risk_weighted_proxy. lens1_corr.csv 도 lens2_corr.csv schema 와 통일.	
28	plan §8 끝: 2 번째 라운드 critique 의 input 으로 들어갈 minimum output set 명시 — grand_df.csv, lens1_corr.csv, lens2_corr.csv, plus 4 개 H1-H4 scatter figure. critic 의 primary outcome 명확화.	필수
29	plan §1, §3.2(3): eigen_lambda_ (p) 의 cross-sidecar 일관성 확인, 다른 그룹별 separate 분석.	권장
30	plan §1 sanity check (ii): random_results 의 method-간 일치 기준을 strict (정확 일치) → moderate (Spearman ≥ 0.9) 로 완화, sidecar 의 random_seed_used field 확인.	선택

위 30 개 항목 중 **[필수] 20 개** 는 planner 가 plan 의 다음 revision 에서 모두 반영해야 lens 1-2 의 falsifier 가 statistically valid 하고 reproducible 합니다. 특히 수정사항 6, 7 (Nyström 식 + NTK schema 사전 확인) 은 lens 2 의 수학적 정확성과 실현 가능성 의 전제이고, 수정사항 11, 12, 13 (mixed model + multiple-testing + falsifier 임계값) 은 setting 수 21/18 의 small-n 에서 H1-H4 가 통계적으로 *meaningful* 한 결론을 내기 위한 최소 필요조건입니다. 수정사항 27, 28 (output schema 와 critic 의 minimum input set) 은 2 번째 라운드 critique 의 실행 가능성 의 전제. 권장/선택 10 개는 plan 의 robustness 와 narrative 명확성을 강화하는 보조 항목입니다.

§11. 외부 자료 참고 — 본 비평이 사용한 식의 출처

- BBSE (Lipton, Wang, Smola 2018), arXiv 1802.03916, ICML 2018 Proceedings. <http://proceedings.mlr.press/v80/lipton18a/lipton18a.pdf>. importance weight $w(y) = q(y)/p(y)$, confusion matrix $\hat{C}_{\{ij\}} = \hat{P}(\hat{y}=i, y=j)$, estimator $\hat{q} = \hat{C}^{-1} \mu_{\hat{q}}$, consistency Theorem 3.
- RLLS / regularized label shift (Azizzadenesheli, Liu, Yao, Anandkumar 2019), arXiv 1903.09734. BBSE 의 small- $\sigma_{\min}(C)$ 영역에서 regularized estimator 의 안정성 개선 — multi-class setting 에서의 alternative.
- Unified view of label shift (Garg, Wu, Smyl, Lipton 2020), NeurIPS 2020, arXiv 2003.07554. weighted ERM excess risk bound 의 TV (Pinsker 로 KL) 형태.
- KTA (Cristianini, Shawe-Taylor, Elisseeff, Kandola 2001), NIPS 2001 vol. 14. <https://papers.nips.cc/paper/1946-on-kernel-target-alignment>. KTA 정의 $A(K_1, K_2) = \langle K_1, K_2 \rangle_F / \sqrt{(\langle K_1, K_1 \rangle_F \cdot \langle K_2, K_2 \rangle_F)}$, eq. (1).
- Centered KTA (Cortes, Mohri, Rostamizadeh 2012), JMLR. K-centering $K_c = H K H$, $H = I - 11^T/n$ 의 추가 효과 (uncentered Y 보다 더 일반).
- Nyström out-of-sample extension (Williams & Seeger 2000) NeurIPS, eq. (4) $\hat{\psi}_i(x_{\text{new}}) = (\sqrt{n} / \lambda_i) \cdot u_i^T k(x_{\text{train}}, x_{\text{new}})$. 후속 표기는 Drineas & Mahoney 2005 JMLR vol. 6 의 eq. (5).
- iter_03 framework: state/iteration_03/report.md §1, §3, §6.
- iter_04 directive: state/directives/20260603_iter04.md.
- prior-art critique (이전 작업, 본 critique 와 분리): state/iteration_04/ critique_priorart.md.

§9. Executor 1st-round 결과 분석 — H1-H5 판정의 사후 점검

본 section 은 plan v2 (state/iteration_04/plan.md , critic-반영본) 를 따라 executor 가 산출한 1st-round 결과 (grand_df.csv 79,700 cell, grand_meta.csv 52 setting, lens1_table.csv , lens1_corr.csv , lens1_cell_kl.csv , lens2_table.csv , lens2_corr.csv , ntk_schema.md , 4 개 H1-H4 scatter PNG) 를 §1-§8 의 사전 비평 관점에서 다시 검증합니다. 1st-round 의 형식적 요약은 다음과 같이 정리됩니다.

가설	가설 내용 (1줄)	n	r (Pearson)	p (Bonferroni $\alpha=0.0125$)	결정
H1	trainbal random-loss-rate $\leftrightarrow$ kl_val_S	14	-0.001	0.997	reject
H2	A1 recovery (valbal) $\leftrightarrow$ max_P_train	21	+0.71	3.2e-4	confirm
H3	A1 recovery (valbal) $\leftrightarrow$ kta_gap_r10	21	-0.71	3.5e-4	confirm
H4	LR loss (trainbal) $\leftrightarrow$ kta_train_r10	14	+0.99	7.6e-11	confirm
H5	recovery $\leftrightarrow$ d_eff_ratio_r10	21	+0.14	0.54	reject (예상된 lens 3 collinearity)

이 표가 "executor 가 합격" 으로 끝나면 안 되는 이유 — 즉 H4 의 $r=0.99$ 가 어떻게 *physical* 인과 신호가 아니라 *cross-dataset confounding* 의 산물일 가능성이 큰지를 §9.1 에서 정확히 짚고, §9.2-§9.5 에서 H1-H5 각각의 사후 점검, §9.6 에서 plan §6 의 mapping 이 결과에 의해 어떻게 보강/약화 되었는지, §9.7 에서 mnli cls90 INV missing cell 의 영향, §9.8 에서 다음 round 의 우선 task 를 정리합니다.

§9.1 H4 의 $r=0.99$ 는 dataset-level confounding 의 결과 — circular 는 아니나 mechanism evidence 가 아님

executor 가 산출한 H4 (kta_train_r10 $\leftrightarrow$ LR_loss_vs_random_balanced_sel5 , $n=14$ trainbal setting, Pearson $r=+0.987$, $p=7.6e-11$) 가 너무 깨끗합니다. 보통 NLP / kernel 분석에서 cross-dataset Pearson 이 0.99 까지 올라가는 경우는 두 변수 중 하나가 *trivially* 다른 하나의 함수일 때이거나, 두 변수가 모두 *dataset identity* 만으로 결정되는 surrogate 일 때입니다. 사용자가 비평 1 번에서 제기한 "hidden dependency" 가 정확히 이 두 가능성입니다. 1st-round 결과를 정밀히 들여다 보면 다음의 사실이 드러납니다.

먼저 kta_train_r10 의 정의 (experiments/lens2_kta_spectral.py 라인 152-153, plan §3.2(5) 의 self-contained derivation) 는 $(\sum_{i \leq r} \lambda_i \cdot c_{i^2_train}) / (\sqrt{(\sum_{i \leq r} \lambda_i^2)} \cdot \|\tilde{Y}_{train} \tilde{Y}_{trainT}\|_F)$ 이고, LR_loss_vs_random_balanced_sel5 는 grand_df.csv 의 gap_top_random_balanced[LR, r=10%, sel=5] 의 부호 반전 입니다 (lens2 script 라인 219-222). 두 quantity 는 직접 산술 의존 이 없습니다 — KTA 는 train kernel 의 spectrum $\times$ train label 의 spread 이고, LR_loss 는 LR top-r selection 으로 뽑힌 5 sample 의 down-stream balanced acc 와 random selection 의 balanced acc 의 차이. 두 quantity 가 같은 train kernel 의 spectrum 정보를 공유 하는 것

은 사실 (LR 의 top-r 선택 자체가 c_i^2 의 ranking 에 기반) 이지만, KTA(r) 의 수치와 LR top-5 의 downstream training-then-eval pipeline 의 결과 사이에는 분명히 nonlinear 단계가 여러 개 있습니다 (top-r index 선택 → 5 sample subset → BERT classifier eval 의 logit → predicted label → balanced acc). 따라서 *circular definition* 은 아닙니다.

그러나 결과의 *cross-dataset* 분포 를 보면 다른 의심이 강해집니다. `lens2_table.csv` 의 첫 두 trainbal row (ag_news cls25_25_25_25 trainbal, val_ratio = cls55 vs cls85) 의 `kta_train_r10` 값이 둘 다 0.03905545820668073 으로 **identical** 입니다. 이걸 KTA 가 train kernel 의 spectrum 만으로 결정되고 *train ratio* 가 동일 (cls25 4-uniform balanced) 한 두 setting 에서 K_{train} 도 같고 $\tilde{Y}_{train}$ 도 같기 때문에 당연한 결과입니다. trainbal 정의 자체가 "*train* 은 *balanced* 로 고정, *val* 만 *imbalance* 변경" 이므로, `kta_train_r10` 는 dataset 내에서 *trainbal* 의 모든 *val_ratio* 변형 에 걸쳐 *constant* 입니다. 즉 trainbal 14 setting 중 7-dataset × 2-val_imbalance = 14 cell 에서 `kta_train_r10` 은 효과적으로 **7 개의 unique 값** 만 갖고 (각 dataset 당 1 값), 그 7 개 unique 값은 dataset 별 train kernel 의 spectrum 차이만 반영합니다. $\text{correlation } r(\text{kta_train_r10}, \text{LR_loss}) = 0.99$ 는 본질적으로 $r(\text{dataset_id_one_hot} \approx \text{kta_train_r10}, \text{LR_loss_per_dataset}) \approx 0.99$ — 즉 dataset 정체성이 두 변수 모두를 강하게 결정하는 *confounded correlation* 입니다.

이 점이 plan §3.3 의 *Stratification* (수정사항 21) 의 의도와 정확히 부합하는 *mechanical inflation* 의 사례입니다. plan 은 imbalance level 별 stratification 만 요구했지만, *dataset-level stratification* 은 빠져 있었습니다. 사실 trainbal 에서 train ratio 가 고정이라 KTA train 측은 dataset 의 NTK structure 의 직접적 measure 일 뿐이고, mechanism-level "label spread × spectral concentration" 의 변동성은 거의 없습니다 — 변동의 source 는 7 datasets 의 model-kernel 차이입니다. 이를 확인 하려면 (i) Spearman r (rank-based) 가 Pearson r 보다 얼마나 낮은지, (ii) dataset-level fixed effect 를 제거한 within-dataset residual 의 correlation 이 얼마인지, 두 점검이 필요합니다.

executor 의 `lens2_corr.csv` 행 H4 의 Spearman $r=+0.853$ (Pearson 0.987 보다 낮음) 이 첫 번째 단서입니다 — Spearman 이 낮아진 건 trainbal 의 14 setting 중 같은 dataset 의 두 cell 이 KTA 가 완전히 같고 (tie) LR_loss 는 다르기 때문에 rank 상관에서 loss 가 큼니다. 두 번째로, dataset-level confounding 을 정량화하려면 mixed model $\text{LR_loss} \sim \text{kta_train_r10} + (1 \mid \text{dataset})$ 의 fixed β 의 CI 를 봐야 하는데, executor 의 `lens2_corr.csv` 에서 H4 의 `mixed_beta` column 이 비어 있습니다 (NaN). plan §3.3 의 secondary tier 가 구현되지 않음 — `experiments/lens2_kta_spectral.py` 라인 264-288 의 `_add` 함수가 `mb=np.nan` 을 default 로 받고 mixed model 호출이 없습니다. 이걸 plan 의 수정사항 11 (필수) 의 명시적 *incomplete implementation* 이고, H4 의 confirm 판정의 통계적 validity 의 최대 hole 입니다.

요약하면 H4 의 $r=0.99$ 는 (i) circular definition 아님, (ii) 두 변수 사이에 진짜 mechanism 신호가 있을 가능성도 있음, 그러나 (iii) trainbal 의 setup constraint 로 `kta_train_r10` 가 dataset 별 7 unique 값으로 *degenerate* 되어 있어, 이 high Pearson 은 mechanism evidence 가 아니라 *dataset-level* 분산 흡수 입니다. 진정한 mechanism evidence 를 얻으려면 (a) within-dataset residual correlation, (b) mixed model 의 fixed β + CI, (c) trainbal 외 valbal 에도 같은 predictor (`kta_train_r10`) 를 적용해 *regime-cross* 일관성 확인 — 셋 다 plan §3.3 의 secondary/tertiary tier 인데 executor 가 *primary* 만 실행했습니다. 수정사항 31 — 2nd-round 분석으로 mixed model + within-dataset 잔차 correlation 을 별도 script 로 산출.

§9.2 H1 reject 의 해석 — kl_val_S 단독이 무의미한가? interaction effect 의 가능성

H1 의 reject ($n=14$, Pearson $r=-0.001$, Spearman $r=-0.144$) 가 사용자 비평 2 의 지적과 정확히 일치합니다. 우리 plan §2.1 의 H1 가설은 "trainbal small-budget 의 random-loss-rate $\leftrightarrow$ kl_val_S " 단변량 monotone 관계였고, $p=0.997$ 의 $r=0.001$ 은 완전한 *null*. 그러나 lens 1 의 kl_val_S 가 무의미한 quantity 가 아니라, *interaction effect* 또는 *non-monotone dependence* 일 가능성을 cell-level 데이터에서 점검해야 합니다.

`lens1_cell_kl.csv` 의 `ag_news trainbal cls55` row 들을 보면 — $sel \in \{1,2,3,5,10\}$ 의 모든 cell 에서 kl_val_S 가 11.25 로 *constant* 입니다. 그 이유는 selected subset P_S 가 작은 sel 에서 거의 100% majority class ($P_S = [1.0, 0, 0, 0]$) 로 collapse 했기 때문이고, KL 의 무한대 방향 항이 약 19.34, mixed class 의 평균이 약 11.25 의 plateau 에 머무는 것 — 즉 small sel 에서 kl_val_S 의 *cross-cell* 변동성 자체가 작음. H1 의 Pearson 이 0 인 핵심 원인은 KL 값의 *between-setting* 분산이 LR_loss 의 *between-setting* 분산보다 훨씬 작은 것이지, KL 이 mechanism 측 신호가 아닌 것이 아닙니다.

interaction 의 직관 — kl_val_S 가 큰 setting 에서도 (1) kta_gap_r10 이 작으면 collapse 가 작고, (2) kta_gap_r10 이 크면 collapse 가 커지는 형태일 수 있음. 즉 H1 의 true 형태는

$gap_top_random_balanced \sim kl_val_S \times kta_gap_r10$ (multiplicative interaction) 또는 $kl_val_S \mid \text{conditioned on KTA tier}$. 이 sub-analysis 가 executor 의 1st-round 에서 빠져 있고, plan §2.3 의 *primary tier* (setting 단위 Pearson) 만 실행되었습니다.

수정사항 32 — 2nd-round 분석에 (i) `gap_top_random_balanced` 를 outcome 으로, predictors $\{kl_val_S, kta_train_r10, max_P_val, max_P_train\}$ 의 multivariate linear regression (statsmodels OLS) 과 partial r^2 (variance partitioning), (ii) $gap \sim kl_val_S * kta_train_r10 + (1 \mid dataset)$ 의 interaction model, (iii) small- $sel \in \{1, 2, 3\}$ 와 mid- $sel \in \{5, 10\}$ 의 별도 correlation. 만약 interaction 의 $\beta_{interaction}$ 이 significant (95% CI 가 zero 를 cross 안 함) 이면 H1 의 reject 는 단변량 형태의 reject 였을 뿐 lens 1 의 KL 이 mechanism 의 *moderator* 로 작용 한다는 evidence 가 됨.

또 `lens1_table` 의 `trainbal` row 들의 `risk_w_proxy_sel5` 가 음수값 (-0.005 부터 -0.076 까지) 으로 직접 *random-loss* 의 *magnitude proxy* 이고, kl_val_train (target $\rightarrow$ source 방향, plan §2.2(1) 의 primary) 과의 Spearman 을 따로 측정해보면 sub-signal 이 살아날 가능성 — executor 의 `lens1_corr.csv` 가 kl_val_S 만 outcome으로 잡고 kl_val_train 은 빠져 있습니다. 수정사항 33 — 2nd-round 에 setting-level $risk_w_proxy_sel5 \leftrightarrow kl_val_train$ (Lipton-Wang-Smolá 2018, arXiv 1802.03916 의 KL convention) 의 Pearson + mixed model 도 추가. 이 게 lens 1 의 본래 *prediction* 이고 H1 의 cell-level 변형보다 dimension 이 일치.

§9.3 H2 와 H3 의 $r=\pm 0.71$ 가 동일 신호의 두 측면일 가능성 — predictor redundancy 의 정량화

H2 ($max_P_train \leftrightarrow A1-LR$ balanced acc gap, $n=21$ valbal, Pearson $r=+0.709$, Spearman $r=+0.719$, $p=3.2e-4$) 와 H3 ($kta_gap_r10 \leftrightarrow recovery_sel5$, $n=21$ valbal, Pearson $r=-0.705$, Spearman $r=-0.650$, $p=3.5e-4$) 가 둘 다 confirm 인데 사용자 비평 3 이 지적하듯 두 predictor 가 *correlated* 라면 같은 신호의 다른 측면입니다. 정량화 — max_P_train 과 kta_gap_r10 의 cross-setting Spearman 을 직접 측정. 이는 `lens1_table.csv` 의 max_P_train column 과

lens2_table.csv 의 kta_gap_r10 column 의 valbal 21 setting join 으로 즉시 계산 가능 (mixed model 불필요).

cross-row 직관 검증 — lens2_table 의 valbal row 중 ag_news cls25 (balanced) trainbal 가 아니라 valbal 에 해당하는 cls25 row 의 kta_gap_r10 ≈ 0 (train + val 둘 다 balanced 라 alignment 차이 없음, max_P_train = 0.25). 반면 ag_news cls85 valbal 의 max_P_train = 0.85, kta_gap_r10 가 negative 큰 값. 즉 두 변수 가 비슷한 방향 의 함수 관계를 갖고 monotone 일 expected. 이 가설을 정량적으로 검증한 것이 executor 의 1st-round 에는 빠져 있습니다.

max_P_train 와 kta_gap_r10 의 Spearman ρ predictor 가 $|\rho| > 0.8$ 이면 두 가설 이 같은 latent 변수 의 두 측정. < 0.5 이면 상보적 (complementary). plan §3.5 의 multivariate regression 의 partial r^2 가 정확히 이 분해를 수행 — recovery_sel5 $\sim$ max_P_train + kta_gap_r10 의 두 predictor 의 partial r^2 합이 각각 따로 측정한 r^2 의 합 보다 작으면 redundancy 큼.

paper draft 의 narrative 차원에서 이 점이 결정적입니다. lens 1 의 max_P_train (label shift 의 단순 majority probability) 이 lens 2 의 kta_gap_r10 (kernel target alignment 의 train-val gap) 과 redundant 하면 lens 1 의 정량 contribution 이 거의 없음 — 즉 paper 의 main story arc 는 "lens 2 가 lens 1 을 흡수 하고 mechanism 의 single best predictor 이다" 로 강화됩니다. 그렇지 않고 complementary 면 "lens 1 = global label distribution 의 effect, lens 2 = kernel-side spectral effect, 두 lens 의 합 이 mechanism 의 full picture" 로 framing.

수정사항 34 — 2nd-round 분석에 (i) corr(max_P_train, kta_gap_r10) valbal 21 setting 의 Spearman 정량화, (ii) recovery_sel5 $\sim$ max_P_train + kta_gap_r10 의 OLS partial r^2 분해, (iii) 동일 분석을 max_P_val (trainbal 의 H1 replacement) 와 kta_train_r10 (trainbal 의 H4) 에 대해 trainbal 14 setting 에서도.

§9.4 H4 의 $r=0.99$ 의 cross-regime 일반화 — kta_train_r10 가 valbal recovery 도 예측하는가?

H4 가 trainbal 14 setting 에서 $r=0.99$ 라면, 같은 predictor kta_train_r10 를 valbal 21 setting 에 적용했을 때도 비슷한 강도의 prediction 이 나와야 mechanism 의 regime-independent evidence 가 됩니다. valbal 의 outcome 으로는 LR_loss_vs_random_balanced_sel5 대신 recovery_sel5 (A1 의 LR 대비 회복) 를 쓰는 게 자연 — H3 와 같은 outcome.

executor 의 lens2_corr.csv 에는 이 regime-cross test (H4' = valbal 의 kta_train_r10 $\leftrightarrow$ recovery_sel5) 가 없습니다. 사실 H3 와 H4 가 별도 라고 framing 한 것 자체가 이 cross-test 를 우회한 것 — H3 는 valbal 의 gap predictor, H4 는 trainbal 의 train-only predictor 로 갈라져 있습니다. common predictor (kta_train_r10) 의 regime-cross analysis 가 빠져 있어, H4 의 $r=0.99$ 가 trainbal 의 특수한 confounding 인지 mechanism 의 general property 인지 결정 불가.

valbal 의 21 setting 에서는 train ratio 가 변동 합니다 (ag_news cls25/cls55/cls85, sst2 pos50/pos70/pos90 등), 그래서 kta_train_r10 가 dataset-degenerate 되지 않고 21 unique 값을 갖습니다 — 따라서 valbal 의 r(kta_train_r10, recovery_sel5) 가 H4 의 $r=0.99$ 만큼 높으면 mechanism 의 강한 evidence, 0.3 부근으로 떨어지면 trainbal 의 $r=0.99$ 는 dataset confounding 의 산물.

수정사항 35 — 2nd-round 분석의 최우선 task: H4-regime-cross — valbal 21 setting 의 recovery_sel5 $\sim$ kta_train_r10 Pearson + Spearman + Fisher CI + mixed model. 만약 valbal $r > 0.6$ 이면 mechanism evidence 강화, < 0.4 면 H4 의 trainbal 결과는 confounding warning.

§9.5 H5 의 reject 는 예상된 — d_eff_ratio 가 모든 setting 에서 거의 일정

H5 (d_eff_ratio_r10 ↔ recovery_sel5, n=21 valbal, Pearson $r=+0.142$, $p=0.54$) 의 reject 는 사용자 비평이 지적인 lens 3 의 본래 한계 와 일치합니다. lens2_table 의 첫 4 row 의 d_eff_ratio_r10 가 모두 0.10000 으로 동일 합니다 (5-decimal 이상 일치). 이걸 NTK spectrum 의 power-law decay 가 매우 안정적이고 (BCP21 Sec. 3, Bordelon-Canatar-Pehlevan 2021), top-r mode 가 d_eff 의 r/n proportion 을 거의 monotone 하게 흡수하기 때문 — $r=10\%$ 이면 $d_eff_r10 / d_eff_rho \approx r/n \times \text{constant}$ 가 거의 1:1 으로 비례. 따라서 d_eff_ratio_r10 의 cross-setting 분산 이 거의 0 이고, 이 변수로 는 어떤 outcome 도 예측 불가.

이 점은 plan §4 의 "lens 3 는 수치보다 framework" 진술과 일치하고, paper draft 의 §Theory 에서 d_eff 가 직접적 predictor 가 아니라 KTA(r) 의 normalization denominator (i.e., $d_eff(p)$ 가 KRR 의 effective number of parameters 라 KTA(r) 의 r 의 operational meaning 을 정해주는 역할) 로 들어가야 함을 시사. lens 3 의 재정의 — d_eff_ratio 대신 top-r KTA / d_eff_ratio_r (effective alignment density) 를 시도. 단 이 quantity 가 H3/H4 의 raw KTA gap 과 redundant 할 가능성 이 높아 추가 contribution 은 marginal.

수정사항 36 — paper draft 에서 lens 3 는 framework section 으로 격하 (별도 lens 가 아니라 KTA 의 normalizer 로). H5 의 reject 는 결과 section 의 short paragraph 로 처리.

§9.6 plan §6 mapping table 의 결과-사후 보강

plan §6 (iter_04 plan v2 의 framework mapping) 의 7 개 row 중 결과로 보강/약화 된 것:

- (i) **Cond 1 ↔ LC_train(r)** — 보강. lens2_table 의 lc_train_r10 가 trainbal/valbal 모두 dataset 마다 monotone 증가 (ag_news 0.876→1.0, sst2 와 mrpc 도 비슷) 로 iter_03 의 LC_LR(r) 의 functional form 과 일치.
- (ii) **Cond 2 cause-side ↔ KTA train + PR(c²)** — 부분 보강 + 약화. KTA train 의 H4 $r=0.99$ 가 (warning §9.1) trainbal-only confounding 일 가능성. $PR(c^2) \leftrightarrow$ KTA ratio 의 correlation (plan §3.5 의 redundancy 정량화) 가 executor 결과에 없어 direct verification 불가. lens2_table 의 pr_c2_train column 이 11.5 (ag_news 4-uniform) 부터 30 부근까지 분포 — iter_03 의 PR ranking 과 ordering 정합성 점검 가능 (executor 가 안 함). 수정사항 37 — 2nd-round 에 pr_c2_train 와 kta_train_r10 의 valbal/trainbal cross-setting Spearman 측정, redundancy 정량화.
- (iii) **Cond 3 ↔ C (multi-class)** — plan v2 에서 mapping 삭제 의 권고 (수정사항 16) 가 정확. executor 결과는 C=2 (binary) 와 C=3,4 (multi-class) 의 분리 분석을 하지 않아 직접 검증 불가. paper draft 의 §Limitations 한 단락.
- (iv) **valbal A1 recovery ↔ kta_gap_r10 (H3)** — 보강 ($r=-0.71$ confirm). mechanism narrative — A1 의 score (lens 3 의 $s_i = (\lambda_i/(\lambda_i+p))^2 \cdot c_i^2$) 가 high- λ mode 의 label-aligned 부분만 선택하므로, train kernel 의 KTA 가 낮는데 val 측에서 다른 alignment 가 필요한 setting 에서 A1 이 LR 대비 더 큰 회복을 보인다는 결과 와 일치.
- (v) **trainbal LR collapse ↔ kta_train_r10 (H4)** — 형식적 보강, 내용적 warning (§9.1 의 confounding). 2nd-round 의 regime-cross + mixed model 결과 후 최종 판정.

§9.7 mnli cls90 INV missing cell 의 영향 분석

mnli cls90_05_05 의 trainbal INV (FreeShap) 가 누락 (사용자 비평 4) 이라 lens2_corr 의 trainbal H4 n_settings 가 14 (15 이 정상). missing cell 의 candidate impact 방향을 lens1_table 의 mnli trainbal row 로부터 추정 — mnli valimb1000_cls90_05_05 의 row (lens1_table line 11) 에서 risk_w_proxy_sel5, sel10, sel100 가 모두 NaN/empty 인데 train ratio cls33_33_33 + val ratio cls90_05_05 의 극단적 imbalance 이라 trainbal random-loss 가 가장 큰 cell 일 가능성 큼.

이 setting 의 추정 LR_loss_vs_random_balanced_sel5 는 (extrapolation 으로) ag_news cls25 trainbal cls85 의 0.553 또는 sst2 trainbal pos90 의 0.4 보다도 클 expected. H4 의 fit $r=0.99$, slope ≈ 11 (lens2 figure scatter 추정) 에서 mnli cls90 의 kta_train_r10 (lens2_table 에서 mnli cls33 trainbal cls60 row 의 값 사용) 와 LR_loss 의 expected 가 fit line 의 extreme 점에 위치하면 $r=0.99$ 가 더 강화될 가능성. 반대로 outlier 면 r 이 0.85-0.9 부근으로 떨어질 가능성.

수정사항 38 — mnli cls90 INV cell 의 rerun 우선순위: 높음. 누락 cell 이 H4 의 가장 extreme x-값 (kta_train_r10 가 mnli 의 spectrum 으로 결정됨) 에 해당하므로 inclusion 이 fit 의 robustness 검증의 핵심. executor 에게 rerun task 를 별도 round 로 할당.

§9.8 통계 절차의 구현 누락 — plan §3.3 의 secondary/tertiary tier

plan §3.3 의 statistical procedure 3-tier 중 primary (setting 단위 Pearson + Fisher CI) 만 executor 가 구현했고, secondary (cell 단위 mixed model) 와 tertiary (dataset 별 within-dataset Spearman 분포) 가 모두 누락 되었습니다. lens2_corr.csv 의 mixed_beta, mixed_ci_lo, mixed_ci_hi column 이 모든 row 에서 NaN.

이 누락의 영향이 H4 의 $r=0.99$ 판정의 신뢰도에 직격탄입니다 (§9.1 의 dataset confounding 점검의 primary 도구가 mixed model β). 또 H3 의 $r=-0.71$ 의 valbal 21 setting 도 Fisher CI $[-0.87, -0.39]$ (lens2_corr 의 pearson_ci_lo/hi) 로 wide 하고, mixed model 의 β 가 변동성 (random intercept 흡수 후) 을 좁힐 수 있는데 숫자가 없습니다.

수정사항 39 — 2nd-round 의 필수 항목: experiments/lens2_mixed_model.py 신설, statsmodels MixedLM (outcome ~ predictor + (1 | dataset)) 으로 H1-H4 의 secondary tier 산출. 이 결과를 lens1_corr.csv, lens2_corr.csv 의 mixed_* column 에 back-fill. 비용 ~ 10 분 (cell 수 8000, single core).

수정사항 40 — tertiary tier (dataset 별 within-dataset Spearman 의 median + IQR) 도 같은 script 에서 산출. 이는 dataset heterogeneity 의 직접 evidence — 7 dataset 중 몇 개 에서 H3/H4 가 각각 hold 하는지 fraction 으로 보고.

§9.9 외부 자료 비교 — KTA 의 cross-task generalization theory

WebSearch 로 확인한 최신 KTA 관련 자료:

- Cortes, Mohri, Rostamizadeh 2012 JMLR "Algorithms for Learning Kernels Based on Centered Alignment" (이미 plan §3.2(4) 인용). centered KTA 의 generalization bound — $R(f) - \hat{R}(f) \leq O(\sqrt{(\text{complexity} / n) / \text{KTA}})$ 의 inverse-KTA 의존. 우리 H4 의 KTA train 큰데 LR 가 random 한테 짐 의 mechanism 은 이 bound 의 kernel- target mismatch 가 작아도 selection-induced sample-imbalance 가 ERM 의 effective task 를 KTA 와 misalign 한 시나리오. 즉 우리

KTA train 측정은 *full-train* alignment 이고, *top-5 selected* subset 의 alignment 는 훨씬 낮을 expect — Garg 2020 의 weighted excess risk bound 의 $\|P_S - P_{val}\|_{TV}^2$ 와 일관.

- *arXiv 2505.03617* (Liu et al. 2025) "Understand the Effect of Importance Weighting in Deep Learning on Dataset Shift" — importance weighting 의 효과가 *training iteration* 초기 에 강하고 말기 에 fade 함. 우리 lens 1 의 weighted-balanced risk proxy 의 finite-sample variance 논의 (plan §2.2(4)) 와 직결 — BERT 의 ~3-5 epoch 짧은 fine-tuning 에서 importance weight 의 효과가 strong 한 regime 일 expect. 이 paper 가 우리 분석의 *training dynamics dimension* 의 next-iter 확장의 직접 reference. bibliography 추가.

WebSearch 의 *quantum KTA* (Sahin 2024) 와 *NTK alignment training* (arXiv 2105.14301) 은 우리 problem 과 직접 관련은 약함. 무시.

§9.10 §9 의 종합 — Round 2 의 우선순위 task

위 §9.1-§9.9 의 수정사항 31-40 을 우선순위로 정렬:

#	task	위치	우선	비용
39	mixed model (secondary tier) 산출 — H1-H4 의 (<code>`outcome ~ pred + (1</code>	dataset)`) β + CI	experiments/ lens_mixed_model.py 신 설	필수
35	H4 regime-cross — valbal 21 setting 의 <code>recovery_sel5 ~</code> <code>kta_train_r10</code>	mixed_model.py 에 추가	필수	5 분
34	predictor redundancy — <code>corr(max_P_train,</code> <code>kta_gap_r10),</code> <code>corr(pr_c2_train,</code> <code>kta_train_r10)</code> , OLS partial r^2 분 해	mixed_model.py 에 추가	필수	5 분
32	H1 interaction model — <code>gap ~</code> <code>kl_val_S * kta_train_r10,</code> multi-predictor OLS	mixed_model.py 에 추가	필수	5 분
33	lens 1 의 setting-level risk_w_proxy $\leftrightarrow$ kl_val_train (Lipton primary 방향) Pearson	mixed_model.py 에 추가	권장	2 분
38	mnli cls90 INV cell rerun (executor task) + H1-H4 의 rerun	별도 round	필수	1 day (학습 time)
40	tertiary tier — dataset 별 within- dataset Spearman median + IQR	mixed_model.py 에 추가	권장	3 분
31	within-dataset residual correlation (Pearson 의 dataset fixed effect 제거 후)	mixed_model.py 에 추가	권장	5 분
36	lens 3 의 paper-draft 격하 — <code>d_eff</code> 를 KTA normalizer 로 재서술	next_directions.md	권장	(draft)
37	<code>pr_c2_train $\leftrightarrow$ kta_train_r10</code> redundancy 정량화	mixed_model.py 에 추가	권장	2 분

종합 — 1 시간 짜리 `lens_mixed_model.py` 가 round 2 의 80% 를 cover 하고, 1 day 짜리 mnli cls90 INV rerun 이 나머지 robustness check. 두 task 모두 GPU 충돌 없음 (mixed model 은 CPU, mnli INV 는 standard BERT fine-tune).

§9.11 sub-question (Q1)-(Q3) 의 결과-사후 답안 윤곽

(Q1) train $\leftrightarrow$ val imbalance 위치가 collapse 양상을 바꾸는 mechanism — 1st-round 결과로 부분 답 가능. valbal 의 경우 H3 (KTA gap $r=-0.71$) 가 main mechanism — *train kernel* 의 *top-r* 가 *train label* 에 잘 align 되어 있지만 *val label* 분포가 *balanced* 로 *shift* 하면 *train-side KTA* 가 *val* 측에 옮겨 질 때 *gap* 발생, 이 *gap* 이 큰 cell 에서 LR collapse 가 크고 A1 가 더 회복. trainbal 의 경우 H4 가 (warning §9.1 후에 valbal-side cross-test §9.4 통과 시) main mechanism — *train kernel* 의 *top-r*

가 *train label* 에 너무 잘 *align* 된 *setting* (*KTA train large*) 에서 *LR top-r* 가 *majority* 만 잡아 ($P_S \approx \text{majority class only}$, *lens1_cell_kl* 의 19.34 plateau 가 직접 증거) *random-loss* 발생.

(Q2) A1 이 정확히 어떤 quantity 를 회복하는가 — H3 의 negative correlation 의 의미. A1 score $s_i = (\lambda_i / (\lambda_i + \rho))^2 \cdot c_i^2$ 가 LR 의 *naive top-c²* 선택과 달리 spectral filter $(\lambda_i / (\lambda_i + \rho))^2$ 로 *high-λ mode* 만 강조. *high-λ mode* 는 *kernel* 의 *dominant direction* 이고, 이 *direction* 의 *label projection* 이 *train + val* 모두 유의미할 expected (Caponnetto-De Vito 2007 의 source condition 의 *spectral decay* 가정과 일관). 즉 A1 은 *train kernel* 의 *spectral dominance* 와 *label-aligned mode* 의 교집합을 잡고, LR 은 *label-aligned mode* 의 모든 것 (*low-λ* 도 포함) 을 잡는다는 차이. *KTA gap* 이 큰 *setting* 에서 *train-only KTA* 가 misleadingly high 이고 (*top-r* 가 *train* 의 *majority class* 만 잡음), A1 의 spectral filter 가 그 정보를 *demote* 해 더 *generalizable* 한 *mode* 를 잡음.

(Q3) *trainbal* 의 *random-loss* 절반 case 의 operational 기준 — plan §2.1 의 정의

$P(\text{gap_top_random_balanced}[A1, r=10\%, \text{sel} \in \{1, 2, 5\}] < -0.02) \cdot 1\text{st-round}$ 결과의 이 rate 가 정확히 몇 % 인지 — *executor* 가 *lens1_corr* 에 보고하지 않았음. *grand_df* 에서 직접 계산 가능 ($\text{cell} \approx 14 \text{ setting} \times 3 \text{ sel} \times 1 \text{ method} = 42$, 그 중 -0.02 이하 fraction). 수정사항 41 — 2nd-round 에 이 rate 의 dataset-별, setting-별 분포 산출 (simple count). 사용자 directive 의 "절반" 표현의 정량 검증.

§9.12 §9 의 결론 — round 1 의 형식적 success, 통계적·해석적 불완전성

1st-round 의 H1-H5 판정 (H2/H3/H4 confirm, H1/H5 reject) 의 형식적 결과는 plan v2 의 falsifier 기준 (Bonferroni $\alpha=0.0125$) 을 만족합니다. 그러나 통계적 신뢰도와 *mechanism* 해석의 두 차원에서 1st-round 는 불완전합니다. 구체적으로:

- **통계적 hole:** secondary tier (mixed model β) 와 tertiary tier (within-dataset Spearman) 의 전체 누락 — H4 의 $r=0.99$ 가 dataset-level confounding 인지 mechanism 인지 분리 불가. plan §3.3 의 3-tier 절차의 1/3 만 실행.
- **해석적 hole:** H2 와 H3 의 predictor redundancy 정량화 부재 — *max_P_train* 과 *kta_gap_r10* 의 cross-setting Spearman 측정 없이는 *lens 1* 의 정량 contribution 이 *lens 2* 와 별도 인지 흡수 인지 결정 불가. H4 의 regime-cross test 부재 — *valbal* 에서도 $r > 0.6$ 인지 모르고는 *trainbal* 의 $r=0.99$ 의 generality 미확정.
- **데이터 hole:** *mnli cls90 INV missing* — H4 의 extreme x-value 가 빠진 fit. rerun 후 H4 의 fit robustness 재검증 필요.

Round 2 는 위 hole 셋을 cover 하는 1 시간 *mixed_model.py* + 1 day *mnli rerun* 으로 충분 (수정사항 39, 35, 34, 38). 이후 paper draft 의 main story arc 가 *lens 2* 의 *KTA* 가 *dominant mechanism*, *lens 1* 의 *label shift* 는 *moderator* 로 정착 (*lens 2* 가 *lens 1* 흡수면) 또는 *lens 1* 과 *lens 2* 의 *complementary partition* (redundancy 약함 일 때) 의 두 시나리오 중 한 쪽으로 결정. *next_directions.md* 에 두 시나리오 별 paper narrative 의 outline 정리.

§9.13 §9 의 외부 참고

- Liu et al. 2025 "Understand the Effect of Importance Weighting in Deep Learning on Dataset Shift", arXiv 2505.03617. importance weighting 효과의 training-stage 의존성 — paper draft 의 limitation 단락의 직접 reference.

- Cortes, Mohri, Rostamizadeh 2012 JMLR "Algorithms for Learning Kernels Based on Centered Alignment". centered KTA 의 generalization bound $R(f) - \hat{R}(f) \leq O(\sqrt{(\text{complexity}/n) / \text{KTA}})$ — H4 의 KTA-train 의 *full* alignment 측정 vs *selected subset* 의 alignment 차이의 theoretical framing.
- 1st-round 결과 파일: `state/iteration_04/grand_df.csv` (79,700 cell), `lens1_corr.csv` (3 rows), `lens2_corr.csv` (8 rows), `lens2_table.csv` (52 settings), `ntk_schema.md`.
- plan v2 §3.3 의 statistical 3-tier procedure 의 미구현 evidence: `experiments/lens2_kta_spectral.py` line 287 의 `mb=np.nan` default.

3. Proposed Next Directions

Iteration 04 — Next directions (round 2 + paper draft outline + iter_05 task)

본 문서는 `state/iteration_04/critique.md` §9 (executor 1st-round 분석) 의 결론을 받아, 두 시야 — (i) **iter_04 round 2** 의 분석 task (수정사항 31-41), (ii) **paper draft** 의 **main story arc** 의 두 candidate scenario, (iii) **iter_05** 의 우선 task (KTA quantity 의 theory bound, vision domain 확장, training dynamics) — 의 우선순위를 정리합니다. 분량 약 1500 단어.

§1. Round 2 분석 task — `lens_mixed_model.py` 의 신설

iter_04 plan v2 §3.3 의 statistical 3-tier procedure (primary = setting 단위 Pearson + Fisher CI, secondary = cell 단위 mixed model β + CI, tertiary = dataset 별 within- dataset Spearman 분포) 중 primary 만 1st-round 에서 구현되었습니다. round 2 의 첫 task 는 secondary + tertiary 를 *retroactively* 산출하는 단일 script 의 신설입니다.

experiments/lens_mixed_model.py 의 spec:

입력: `state/iteration_04/grand_df.csv` (79,700 cell), `lens1_table.csv`, `lens2_table.csv`, `lens1_cell_kl.csv`.

산출: `state/iteration_04/round2_corr.csv` — 모든 H1-H4 의 (primary, secondary, tertiary) 의 통합 row. column schema: `hypothesis_id`, `predictor`, `outcome`, `regime`, `imbalance_level`, `n_settings`, `primary_pearson_r`, `primary_fisher_ci_lo`, `primary_fisher_ci_hi`, `primary_spearman_r`, `primary_p`, `mixed_beta`, `mixed_ci_lo`, `mixed_ci_hi`, `mixed_p`, `within_dataset_spearman_median`, `within_dataset_spearman_iqr_lo`, `within_dataset_spearman_iqr_hi`, `decision_3tier`.

각 H1-H4 의 추가 task:

- **H1**: trainbal regime 의 cell-level mixed model `gap_top_random_balanced ~ kl_val_S + (1 | dataset)` (수정사항 11, 14, 39). H1 interaction extension — `gap ~ kl_val_S * kta_train_r10 + (1 | dataset)` 의 β interaction (수정사항 32).
- **H2**: valbal 21 setting 의 cell-level mixed model `(A1-LR balanced acc gap) ~ max_P_train + (1 | dataset)`. partial r^2 분해 — `(A1-LR gap) ~ max_P_train + kta_gap_r10`, 두 predictor 의 각 partial r^2 + variance decomposition (수정사항 34).
- **H3**: valbal 21 setting 의 cell-level mixed model `recovery_sel5 ~ kta_gap_r10 + (1 | dataset)`. predictor redundancy check — `recovery_sel5 ~ kta_gap_r10 + max_P_train` 의 partial r^2 .
- **H4**: trainbal 14 setting 의 cell-level mixed model `LR_loss_vs_random_balanced_sel5 ~ kta_train_r10 + (1 | dataset)`. fixed β 의 CI 가 zero 를 cross 안 하면 dataset-confounding 후에도 mechanism evidence 유지. cross-regime test (수정사항 35) — valbal 21 setting 의 `recovery_sel5 ~ kta_train_r10` 의 Pearson + Spearman + Fisher CI + mixed model. valbal $r > 0.6$ 이면 H4 generality 확보.

추가 task (수정사항 33, 37, 41):

- **lens 1 primary direction:** setting-level `risk_w_proxy_sel5 ~ kl_val_train` (Lipton 2018 의 target → source 방향) 의 Pearson, 14 trainbal setting.
- **PR vs KTA redundancy:** `pr_c2_train ~ kta_train_r10` 의 valbal 21 + trainbal 14 의 Spearman. $\rho > 0.8$ 이면 Cond 2 의 PR-based 와 KTA-based 표현이 경험적 동치.
- **(Q3) operational random-loss-rate 계산:** trainbal 14 setting 의 $P(\text{gap_top_random_balanced}[A1, r=10\%, \text{sel} \in \{1, 2, 5\}] < -0.02)$ 의 dataset-별
 - setting-별 값. 사용자 directive 의 절반 표현이 quantitative 으로 얼마인지 확정.

산출 figure: `state/iteration_04/round2_figs/`

- `H4_regime_cross.png` — valbal 21 + trainbal 14 의 `kta_train_r10` ↔ outcome scatter 2-panel.
- `partial_r2_decomposition.png` — H2, H3, H4 의 multivariate partial r^2 stacked bar chart.
- `within_dataset_heterogeneity.png` — 7 dataset 별 within-dataset Spearman 의 forest plot (median + IQR).

estimated cost: 1 CPU core, 15-20 분. statsmodels MixedLM dependency.

§2. mnli cls90 INV cell rerun (executor 별도 round)

mnli cls90_05_05 의 trainbal INV (FreeShap) 가 누락 (사용자 비평 4) 으로 H4 의 $n=15$ 가 아닌 14. 누락 cell 이 H4 의 *extreme x-value* (mnli 의 NTK spectrum 으로 결정되는 `kta_train_r10`, `lens2_table` 추정 mnli trainbal cls60 row 의 값 기준 cls90 도 동일 하므로 새 x-value 가 아님) 에 해당하지 않아도, *extreme y-value* (LR_loss 가 cls90 의 극단 imbalance 로 가장 클 expected) 의 fit 점이라 H4 fit 의 robustness 검증의 핵심.

Rerun spec: 기존 `n05_INV.sh` 또는 동등 script 의 `mnli cls33_33_33 + valimb1000_ cls90_05_05` setting 만. `method=FreeShap (TMC)`, `seed=2026`, `n_train=5000`, `n_val=1000`. NTK pickle 은 이미 존재 (`imbalance_ntk/mnli/cls33_33_33/bert_seed2026_num5000_valimb1000_cls90_05_05_signFalse.pkl`). 학습은 BERT base + GLUE-MNLI fine-tune 의 표준 pipeline (~ 1 day on single A100 / V100).

완료 후 round 3 — `lens_mixed_model.py` 재실행, H4 의 $n=15$ fit 의 Pearson r 비교. $r=0.99$ 가 유지 되면 mechanism evidence 강화, $r<0.9$ 로 떨어지면 mnli cls90 가 outlier 로 H4 의 strict-mechanism interpretation 약화.

§3. Paper draft 의 main story arc — 두 candidate scenario

round 2 의 redundancy 정량화 결과에 따라 paper 의 main narrative 가 갈립니다.

scenario A: "lens 2 가 dominant, lens 1 은 moderator"

조건: `corr(max_P_train, kta_gap_r10)` 의 Spearman > 0.7 AND `recovery_sel5 ~ kta_gap_r10 + max_P_train` 의 multivariate OLS 에서 `max_P_train` 의 partial $r^2 < 0.05$ (`kta_gap_r10` 의 partial $r^2 > 0.4$ 의 절반 미만).

narrative: "label distribution shift (lens 1) 의 effect 는 본질적으로 *kernel-target alignment* (lens 2) 의 *kernel-side* 표현 으로 흡수된다. trainbal 에서 LR top-r 의 collapse mechanism 은 *train kernel* 의 *top-r mode* 가 *majority class* 에 *dominantly align* 되어 selected subset `P_S` 가 majority-only 로 degenerate 하는 것 — 이는 raw label distribution `P_train` 의 majority probability `max_c`

$P_{\text{train}}(c)$ 와 monotone 이지만, 원리적 mechanism 은 NTK 의 spectral structure $\times$ label alignment 의 결합 인 KTA(r). A1 score 의 spectral filter $(\lambda_i / (\lambda_i + \rho))^2$ 가 LR top- c 대비 *high- λ mode* 만 강조해 collapse 회복 — 이 회복은 KTA(r) gap 의 함수로 monotone."

paper 구조: §1 Intro / §2 Related (BBSE, KTA, FreeShap, A1) / §3 Setup (controlled imbalance benchmark) / §4 Empirical observation (valbal recovery + trainbal random- loss) / §5 Spectral framework (KTA decomposition + A1 score derivation) / §6 Quantitative validation (H2, H3, H4 의 confirm + lens 1 흡수의 redundancy evidence) / §7 Theory (BCP21 generalization closed-form 의 우리 cell 단위 reformulation) / §8 Discussion / §9 Limitations (H4 의 dataset confounding caveat + mnli cls90 rerun 결과 + lens 4 의 TMC variance bound 의 한 단락).

target venue: NeurIPS 2027 (deadline 추정 2027 5월) main track, or ICML 2027 (1월).

scenario B: "lens 1 과 lens 2 의 complementary partition"

조건: $\text{corr}(\max_P_{\text{train}}, \text{kta_gap_r10})$ 의 Spearman < 0.5 AND partial r^2 분해에서 두 predictor 가 각각 0.15 이상 기여.

narrative: "label distribution shift 와 kernel-target alignment 는 *complementary mechanism* 의 두 측면이다. lens 1 은 *global* label distribution shift 의 effect 를 capture 하고, lens 2 는 *local* kernel-side spectral concentration 의 effect 를 capture 한다. 두 mechanism 이 합산되어 collapse 의 full picture 를 형성. paper 의 main contribution 은 lens 1, lens 2 의 *quantitative separation* + 각각의 predictive metric (KL, KTA gap) 의 *operational threshold*."

paper 구조: scenario A 와 동일하나 §5 + §6 가 *two complementary mechanism* 으로 재구성. 두 lens 의 partial r^2 + joint variance explained 의 정량적 stacked bar chart 가 main figure.

scenario 결정

round 2 의 `lens_mixed_model.py` 결과 의 두 quantity — $\text{corr}(\max_P_{\text{train}}, \text{kta_gap_r10})$ 와 partial r^2 of $\max_P_{\text{train}}$ in `recovery_sel5` ~ both — 가 결정. 1st-round 의 $r(H2)=+0.71$ 와 $r(H3)=-0.71$ 의 비슷한 *magnitude* 가 scenario A 의 약한 정황 (두 predictor 가 redundant 일 가능성) 이지만, 두 변수의 *cross-setting Spearman* 없이는 확정 불가. paper draft 작성 시작은 round 2 완료 후.

§4. iter_05 의 우선 task (KTA quantity 의 theory bound + cross-domain robustness)

1st-round 결과 + round 2 의 mixed model 결과가 모두 H3/H4 의 mechanism evidence 를 강화하면, iter_05 는 KTA quantity 의 theory bound 의 도출과 vision domain 확장 의 두 줄기로 분기.

iter_05 task A: KTA-based generalization bound 의 도출

핵심 question: cell 단위로 $\text{gap_top_random_balanced} \leq f(\text{kta_train_r10}, \text{kl_val_train}, \text{sel}, \rho)$ 의 explicit upper bound 를 만들 수 있는가. 출발점은 Cortes-Mohri 2012 JMLR 의 centered KTA-based generalization bound $R(f) - \hat{R}(f) \leq O(\sqrt{(\text{complexity}/n) / \text{KTA_centered}})$ 와 Garg 2020 NeurIPS arXiv 2003.07554 의 weighted ERM excess risk 의 $O(\|P_S - P_{\text{val}}\|_{TV}^2)$ 결합. selected subset 의 KTA $\text{KTA}(K_S, \tilde{Y}_S)$ 와 full KTA $\text{KTA}(K_{\text{train}}, \tilde{Y}_{\text{train}})$ 의 차이가 *selection rule* 의 dependence 의 직접 측정.

iter_05 task 분해:

1. $KTA(K_S, \tilde{Y}_S)$ 의 정확한 정의 (selected subset 의 sub-kernel) — `kta_selected.py` script.
2. $KTA(K_{train}) - KTA(K_S) \leq ?$ 의 *explicit* deterministic bound 의 도출 시도. LR top-r selection rule (top- c^2 index) 의 경우 $KTA(K_S) \leq KTA(K_{train}) \cdot (\text{사이즈 ratio} + \text{concentration term})$ 의 형태가 expected.
3. ridge regression 의 generalization error $\|\hat{f}_S - f_\star\|^2 \leq ?$ 의 KTA-side bound derivation. $\rho = 10^{-2}$ 의 explicit 처리.

예상 분량: 한 iteration. 결과는 paper 의 §7 Theory 의 *quantitative bound* 한 proposition.

iter_05 task B: Vision domain 확장 (CIFAR-10 / ImageNet sub-class imbalance)

NLP-only 의 generalization risk — H4 의 $r=0.99$ 가 BERT NTK 의 특수성일 가능성. CIFAR-10 의 sub-class imbalance (예: 10-class 의 majority 70% / minority 5%) 와 ResNet-18 의 NTK spectrum 으로 H2-H4 의 재검증. 이 task 는 새 학습 실험 launch 가 필요 (data_selection_test 의 vision branch 가 있으면 사용, 없으면 new pipeline).

예상 분량: 1-2 iteration (NTK 계산 + sidecar 산출 + lens 1-2 분석).

iter_05 task C: Training dynamics — importance weighting 효과의 epoch 의존성

Liu et al. 2025 arXiv 2505.03617 의 "importance weighting effect fades with training" 관찰의 우리 setup 검증. BERT fine-tune 의 1-epoch vs 3-epoch vs 5-epoch 의 valbal A1 recovery 의 epoch-dependent rate 측정. 만약 fade 가 cell 별로 다른 속도 라면 paper 의 §Limitations 의 한 단락 + iter_06 의 *dynamic mechanism* 분기 ground 가 됨.

예상 분량: 1 iteration (기존 NTK 사용, 학습만 epoch 변경).

iter_05 우선순위 결정

- **Task A (KTA bound 도출):** paper 의 *theory contribution* 의 핵심, 필수.
- **Task B (vision 확장):** paper 의 *generality* 의 핵심, 강추.
- **Task C (training dynamics):** paper 의 *limitation* 의 한 단락 + iter_06 expansion, 권장.

round 2 결과 후 사용자가 1 개를 선택. round 2 결과가 H4 의 mechanism evidence 약화 면 (regime-cross $r < 0.4$ 등) task A 의 우선순위 하향, task B 의 vision 확장으로 mechanism 의 *cross-domain* robustness 먼저 검증.

§5. 종합 — round 2 의 dependency graph

round 2 task 의존성:

1. lens_mixed_model.py (15-20 분, single core)
 - ├ secondary tier (H1-H4 mixed model β + CI)
 - ├ tertiary tier (within-dataset Spearman)
 - ├ partial r^2 분해 (H2, H3, H4)
 - ├ regime-cross (H4 valbal application)
 - ├ predictor redundancy (max_P_train $\leftrightarrow$ kta_gap_r10, etc.)
 - |
 - ├ ─ decision: scenario A or B (paper main story arc)
 - └ ─ decision: H4 mechanism vs confounding
2. mnli_cls90 INV rerun (1 day, single GPU)
 - └ H4 fit robustness 재검증 (n=14 $\rightarrow$ 15)
3. paper draft outline 작성 (round 2 + mnli rerun 완료 후)
 - └ target venue 결정 (NeurIPS 2027 or ICML 2027)
4. iter_05 task 분기 (task A / B / C 의 사용자 선택)

round 2 의 1, 2 가 *parallel* 실행 가능 (mnli rerun 은 GPU, mixed_model 은 CPU). 1 의 결과가 paper draft scenario 결정의 trigger, 2 의 결과가 H4 의 final interpretation 의 robustness 결정. 두 결과가 모두 일관 (mechanism evidence 강화) 이면 paper draft 진입 + iter_05 task A 우선. 결과가 다르면 (H4 의 dataset confounding warning 이 유지) iter_05 task B (vision 확장) 우선으로 mechanism 의 cross-domain robustness 먼저.

§6. 참고

- 1st-round 결과 파일 위치 (모두 state/iteration_04/ 하위):
 - grand_df.csv, grand_meta.csv, lens1_table.csv, lens1_corr.csv, lens1_cell_kl.csv, lens2_table.csv, lens2_corr.csv, ntk_schema.md.
 - figure: lens1_figs/H{1,2}_scatter.png, lens2_figs/H{3,4}_scatter.png.
- critique 의 본 결과 분석: state/iteration_04/critique.md §9.
- iter_03 framework 의 7-quantity / Cond 1-3: state/iteration_03/report.md §3.
- 외부 reference 추가:
 - Liu et al. 2025 arXiv 2505.03617 "Understand the Effect of Importance Weighting in Deep Learning on Dataset Shift" — training-stage dependence of IW effect.
 - Cortes, Mohri, Rostamizadeh 2012 JMLR — KTA-based generalization bound (iter_05 task A 의 출발점).
 - Garg, Wu, Smyl, Lipton 2020 NeurIPS arXiv 2003.07554 — weighted ERM excess risk bound (iter_05 task A 의 lens 1 흡수 framework).