

Iteration 04 — Executive Summary (v2, mnli cls90 INV 완료 반영)

0. 연구 질문과 setup 한 단락

같은 정도의 class imbalance 를 train 측 (valbal: train imbalanced + val balanced) vs val 측 (trainbal: train balanced + val imbalanced) 에 가했을 때, FreeShap (Wang et al. 2024 의 inv approximation) 과 LR (Irfshap workshop 의 top-r eigen approximation) 이 *collapse* 하는 mechanism 은 무엇이며, A1 (label-aware top-r eigen, $s_i = (\lambda_i / (\lambda_i + \rho))^2 \cdot \|u_i^T \tilde{Y}\|^2$ 의 score 로 mode 선택) 이 회복시키는 정확한 *quantity* 는 무엇인가? 왜 trainbal 의 상당 case 에서 A1 도 random selection 한테 패배하는가?

실험은 7 NLP dataset (MR, SST-2, MRPC, QQP, RTE, AG News, MNLI) × valbal/trainbal × imbalance level (balanced + mild 70/30 또는 cls60/55 + extreme 90/10 또는 cls90/85) 의 모든 cell 완성. 마지막 mnli cls90 trainbal extreme 의 FreeShap baseline (INV) 이 2026-06-03 22:18 KST 에 완료되어 7-dataset trainbal 전체 fully done.

1. 용어와 수식 정의

분석에 등장하는 모든 quantity 를 한 곳에 모았다. 이후 가설 표에서 이 정의를 그대로 쓴다.

1.1 확률·label 관련

- **P_train(c)**: train set 의 class c 의 *empirical* 비율. 분포가 아니라 분포의 한 값 (즉 0 과 1 사이 숫자). 모든 c 에 대한 P_train 의 vector 가 분포 자체. 예: SST-2 train 5000 개 중 class 0 이 4500 개, class 1 이 500 개 → $P_{\text{train}}(0) = 0.9$, $P_{\text{train}}(1) = 0.1$.
- **max_c P_train(c)**: train 의 majority class 의 비율. valbal 의 90/10 setting 이면 0.9. *imbalance* 의 깊이 의 직접적 measure.
- **P_val(c)**: 동일하나 val set 위.
- **P_S(y)**: top-Shapley 가 선택한 subset S 의 label 분포. $y = 1$ 의 비율.
- **w(c) = P_val(c) / P_train(c)**: BBSE (아래) 의 importance weight. valbal 의 train 90/10 + val 50/50 이면 $w(\text{maj}) = 0.55$, $w(\text{min}) = 5$. trainbal 의 train 50/50 + val 90/10 이면 $w(\text{maj}) = 1.8$, $w(\text{min}) = 0.2$.

1.2 KL divergence (label shift 의 magnitude)

$$KL(P \parallel Q) = \sum_c P(c) \cdot \log(P(c) / Q(c))$$

두 확률 분포 P , Q 의 비유사도 의 표준 측도. 0 이면 $P = Q$, 클수록 P 와 Q 가 떨어져 있음. *asymmetric* — $KL(P \parallel Q) \neq KL(Q \parallel P)$ 일반적으로.

- **KL(P_val(y) || P_train(y))** (= kl_val_train): val 분포와 train 분포의 label shift 크기. trainbal extreme (val cls90_05_05, train cls33) 이면 KL 약 0.65.
- **KL(P_val(y) || P_S(y))** (= kl_val_S): val 의 *target* 분포와 선택된 subset 의 분포의 KL. small budget 에서 P_S 가 거의 1-class 로 collapse 하면 $KL \rightarrow +\infty$ (또는 매우 큼). 얼마나 잘못 골랐는지 의 proxy.

1.3 Pearson r, Spearman r, p-value, α , Bonferroni

두 변수 ($X = \text{predictor}$, $Y = \text{outcome}$) 의 상관성 측정.

- **Pearson $r \in [-1, +1]$** : 두 변수의 *linear* 상관계수. $r = +1$ 이면 완벽한 양의 선형, -1 이면 완벽한 음의 선형, 0 이면 무상관. r^2 가 분산 설명률.
- **Spearman $r \in [-1, +1]$** : 두 변수의 *rank* 상관계수. linear 가정 없이 monotone 관계만 측정. linear 가정이 깨질 때 (outlier 있을 때) Pearson 보다 robust.
- **p-value**: "no correlation (null hypothesis)" 일 때 관찰된 r 만큼의 r 또는 더 큰 r 이 나올 확률. 작을 수록 우연이 아니라는 strong evidence.
- **α (significance level)**: p-value 의 cutoff. $p < \alpha \rightarrow \text{"reject null"} = \text{"유의미한 상관 있다"}$ 라고 결론. 일반 $\alpha = 0.05$.
- **Bonferroni correction**: K 개 가설을 동시에 검증할 때 false positive 누적을 막기 위해 각 가설의 α 를 α/K 로 조정. iter_04 의 main hypothesis 가 $H1, H2, H3, H4$ 의 4 개이므로 $\alpha = 0.05 / 4 = 0.0125$. 즉 $p < 0.0125$ 일 때만 confirm. α 는 작을수록 더 strict — 즉 더 강한 evidence 요구.
- **95% CI** (Fisher z transform 으로 계산): r 의 95% 신뢰구간. CI 가 0 을 cross 하지 않으면 $r \neq 0$ 이 significant 라는 다른 형태의 표현.

1.4 KTA (Kernel-Target Alignment) — lens 2 의 핵심 quantity

KTA (Cristianini, Shawe-Taylor, Elisseeff, Kandola 2001, NIPS, eq. (1)) 의 정의:

$$\text{KTA}(K, Y) = \langle K, Y Y^T \rangle_F / (\|K\|_F \cdot \|Y Y^T\|_F)$$

- K : $n \times n$ kernel matrix (우리 setting 의 eNTK)
- Y : one-hot label matrix ($n \times C$, $C = \text{class 수}$). $\tilde{Y} = \text{centered (mean-subtracted) version}$.
- $\langle A, B \rangle_F = \sum_{i,j} A_{ij} B_{ij}$: Frobenius inner product
- $\|A\|_F = \sqrt{\langle A, A \rangle_F}$: Frobenius norm

직관: *kernel* 이 *task (label structure)* 와 얼마나 잘 정렬되는지. $\text{KTA} = 1$ 이면 $K \propto Y Y^T$ (즉 kernel 이 label structure 와 완전 일치 — same class 의 sample 쌍에 $K = 1$, different class 쌍에 $K = 0$). $\text{KTA} = 0$ 이면 무관.

- **KTA_full**: 전체 NTK kernel $K = \sum_i \lambda_i u_i u_i^T$ (full eigen 분해) 의 KTA.
- **KTA(r) = KTA_topr**: top- r eigen mode 만 보존한 truncated kernel $K_r = \sum_{i \leq r} \lambda_i u_i u_i^T$ 의 KTA. r 이 작을 때 *alignment* 가 얼마나 보존되는지.
- **kta_train_r10**: train kernel + train $\tilde{Y}$ 에 대한 $\text{KTA}(r=10\%)$. *train spectrum* 의 top 10% mode 가 *train task* 와 얼마나 align 하는지.
- **kta_val_r10**: train kernel 의 top- r eigenvector 를 val 에 Nyström extension (Williams-Seeger 2000, eq. (4) 의 $\sqrt{n}$ factor 포함) 으로 transfer 한 후 val $\tilde{Y}$ 에 대해 계산한 KTA.
- **kta_gap_r10** = $\text{kta_train_r10} - \text{kta_val_r10}$: *train task* $\leftrightarrow$ *val task* 의 *alignment* 격차. trainbal extreme 처럼 train $\tilde{Y}$ 와 val $\tilde{Y}$ 분포가 다를수록 이 gap 이 음수 방향으로 큼.

1.5 BBSE (Black-Box Shift Estimator) — lens 1 의 추정 기법

Lipton, Wang, Smola (2018, ICML), eq. (4)-(5) + Theorem 3. label shift 의 importance weight $w(y) = P_{\text{val}}(y) / P_{\text{train}}(y)$ 를 *labels* 없는 *val* 위에서 추정하는 기법. *black-box classifier* 의 train 위 confusion matrix C 와 val 위 prediction 분포 $\hat{q}_{\text{val}}(\hat{y})$ 만 사용:

$$\hat{w} = C^{-1} \hat{q}_{\text{val}}$$

여기서 $C_{\{ij\}} = P_{\text{train}}(\hat{y} = i \mid y = j)$ (joint 가 아닌 confusion matrix; classifier 가 class j 를 i 로 잘못 분류하는 conditional 비율).

우리 분석에선 oracle P_{train} , P_{val} 을 알고 있어 BBSE 의 추정 자체는 직접 $w = P_{\text{val}} / P_{\text{train}}$ 으로 계산 (estimator 의 fit 만 baseline classifier = "always predict train majority" 로 sanity check 위해 monitor).

1.6 Outcome (acc gap) 들

- **balanced acc** = per-class recall 의 평균 = $(1/C) \sum_c \text{recall}_c$. label shift 에 *invariant* — val 의 class 비율이 바뀌어도 (per-class recall 자체는 안 바뀌면) balanced acc 안 바뀜.
- **gap_top_random_balanced**: $\text{balanced_acc}(\text{top-Shapley selection}) - \text{balanced_acc}(\text{random selection})$. > 0 이면 top-Shapley 가 random 보다 나음.
- **recovery_sel5**: $\text{balanced_acc}(A1, \text{sel}=5\%) - \text{balanced_acc}(\text{LR}, \text{sel}=5\%)$. A1 이 LR 대비 얼마나 회복했나. $> 0 = A1$ better.
- **LR_loss_vs_random_balanced_sel5**: $\text{balanced_acc}(\text{random}, \text{sel}=5\%) - \text{balanced_acc}(\text{LR}, \text{sel}=5\%)$. LR 이 random 보다 얼마나 못한지. $> 0 = \text{LR worse than random}$.

2. 5 가설의 결과 표 (mnli cls90 INV 포함)

각 가설의 predictor (X) 와 outcome (Y) 정의:

- **H1**: $X = \text{kl_val_S}$ (선택된 subset 의 label 분포와 val 분포의 KL), $Y = \text{gap_top_random_balanced}$ (top-Shapley 의 balanced acc – random 의 balanced acc; sel $\in \{1,2,3,5\}$ % 평균; $r=10\%$; A1 method)
- **H2**: $X = \text{max_c } P_{\text{train}}(c)$ (train majority class 의 비율), $Y = A1 - \text{LR balanced acc gap}$ (sel=5%, $r=10\%$)
- **H3**: $X = \text{kta_gap_r10}$ (train $\tilde{Y}$ 와 val $\tilde{Y}$ 의 alignment 격차), $Y = \text{recovery_sel5}$ (= H2 의 Y 와 동일)
- **H4**: $X = \text{kta_train_r10}$ (train kernel + train $\tilde{Y}$ 의 top- $r=10\%$ KTA), $Y = \text{LR_loss_vs_random_balanced_sel5}$ (random 의 balanced acc – LR 의 balanced acc; sel=5%; $r=10\%$)
- **H4b**: $X = \text{kta_gap_r10}$ (= H3 의 X), $Y = \text{H4 의 Y}$ (trainbal regime 에서의 gap 효과 점검)
- **H5**: $X = \text{d_eff_ratio_r10}$ (effective dimension 의 $r=10\%$ truncate ratio), $Y = \text{recovery_sel5}$

H	regime	n	r (Pearson)	p (Bonf. $\alpha=0.0125$)	결정
H1	trainbal	14	-0.001	0.997	reject
H2	valbal	21	+0.71	3.2×10^{-4}	confirm
H3	valbal	21	-0.71	3.5×10^{-4}	confirm
H4	trainbal	14	+0.99	7.6×10^{-11}	confirm ★ (dataset confounding 의심)
H4b	trainbal	14	-0.22	0.46	partial
H5	valbal	21	+0.14	0.54	reject

mixed model β (dataset random effect 흡수 후의 effect) 가 산출된 경우:

- H1: mixed $\beta = -0.0005$ [95% CI $-0.0033, 0.0023$] — CI 가 0 cross $\rightarrow$ 효과 없음, primary reject 와 일치
- H2: mixed $\beta = +0.255$ [95% CI $0.188, 0.322$] — CI 가 0 cross 안 함 $\rightarrow$ dataset 흡수 후에도 effect 살아남음, primary confirm 강화
- H3, H4, H4b, H5: lens2 분석에서 mixed β 산출 누락 (NaN) — round 2 에서 보강 필요

stratified (imbalance level 별):

H	level	n	r	p	결정
H1	mild	14	-0.001	0.997	reject
H2	mild	14	+0.48	0.084	partial (p > 0.0125)
H2	extreme	7	+0.80	0.030	partial (n 작아 CI wide)
H3	mild	14	-0.68	0.007	confirm
H3	extreme	7	+0.62	0.138	partial (부호 반대)
H4	mild	14	+0.99	7.6×10^{-11}	confirm (= main, trainbal mild + extreme 가 모두 mild 로 분류된 경우; 별도 partition 안 됨)

stratified (imbalance level 별):

H	level	n	r	p	결정
H1	mild	14	-0.001	0.997	reject
H2	mild	14	0.48	0.084	partial (p > 0.0125 — strict cutoff 못 넘김)
H2	extreme	7	0.80	0.030	partial (n 작아 CI wide)
H3	mild	14	-0.68	0.007	confirm
H3	extreme	7	+0.62	0.138	partial (부호 반대)

mild vs extreme 의 stratification 이 균일하지 않음 — H3 의 부호가 mild 에서 음, extreme 에서 양으로 뒤집힘. 이 inversion 은 *small n* (7) 의 *chance* 일 수도 있고 진짜 regime split 일 수도 — round 2 의 mixed model 로 점검 필요.

3. 가설별 깊이 해석 (왜 됐는지/안 됐는지)

H1 (label shift KL $\rightarrow$ trainbal random-loss): reject 이나 단변량 reject 일 뿐

가설: trainbal regime 에서 top-Shapley 가 random 한테 지는 cell 은 *label shift* 가 큰 cell 일 것이다 — 즉 train 과 val 분포가 떨어진 setting 일수록 잘못된 sample 을 고른다.

결과: $r = -0.001$, 사실상 무상관. 왜?

`lens1_cell_kl.csv` 의 small-sel cell 을 보면 `kl_val_s` 가 19.34 또는 11.25 의 *plateau* 에 몰린다. 즉 small sel% (1, 2%) 에서 top-Shapley 가 거의 100% *majority class* 로 collapse 해 P_S 가 한 점에 모이고, 이로 인해 between-setting 분산이 outcome 분산보다 훨씬 작아져 correlation 추정 자체가 무력화 된다. 단변량으로는 신호 부재라는 결론이지만, label shift 가 무의미한 게 아니라, lens 2 의 KTA 같은

spectral quantity 와 결합한 *interaction* 으로만 작동할 가능성이 큼 (round 2 에서 OLS outcome ~ $kl_val_S \times kta_train_r10$ 으로 점검 예정).

H2 (train majority → A1 recovery): confirm

가설: valbal 에서 train imbalance 가 깊을수록 ($\max_c P_{train}(c)$ 클수록) LR 은 더 큰 collapse, A1 의 회복 폭도 크다.

결과: $r = 0.71$, $p = 3.2 \times 10^{-4}$, mixed $\beta = 0.255$ [0.188, 0.322]. mixed model 의 CI 가 0 을 cross 하지 않음 → dataset 효과 흡수 후에도 진짜 효과로 남음. **label-side mechanism 의 strong evidence.**

해석: A1 의 score $s_i = (\lambda_i / (\lambda_i + \rho))^2 \cdot \|u_i T \tilde{Y}\|^2$ 의 $\|u_i T \tilde{Y}\|^2$ 부분이 minority class 의 mode 를 명시적으로 골라낸다. train 이 imbalanced 일수록 minority mode 가 LR (λ 기반 선택) 에서 누락되는데, A1 가 이를 회복한다.

H3 (train-val alignment gap → A1 recovery): confirm

가설: train $\tilde{Y}$ 와 val $\tilde{Y}$ 의 alignment 격차 (kta_gap_r10) 가 클수록 LR 은 train task 에 specialize 되어 val 에서 collapse, A1 은 *train $\tilde{Y}$* 를 직접 score 에 쓰므로 (val $\tilde{Y}$ 는 unknown) 동일한 alignment gap 에서도 회복 가능.

결과: $r = -0.71$, $p = 3.5 \times 10^{-4}$ (음의 부호는 *gap* 이 음수 방향으로 클수록 *recovery* 가 양수 라는 의미 — $gap = \text{train alignment} - \text{val alignment}$ 이므로 train spectrum 이 val task 와 덜 정렬될수록 LR 더 collapse). **spectral-side mechanism 의 strong evidence.**

H4 (top-r KTA on train → trainbal LR loss): confirm 이나 dataset confounding 의심

가설: trainbal 에서 LR 이 random 한테 지는 cell 은 train kernel 의 top-r KTA 가 큰 cell 이다 (train task 위에서 spectrum top 이 잘 정렬돼 있지만 그게 val task 에 안 맞음).

결과: $r = 0.99$, $p = 7.6 \times 10^{-11}$ — 너무 *sharp*. Spearman 만 보면 $0.85 < \text{Pearson } 0.99$ 라 *outlier-driven linear fit* 의 가능성. 결정적으로 trainbal 의 train 이 모든 setting 에서 balanced 고정 (cls33_33_33, cls25_25_25 등) 이라 kta_train_r10 가 *dataset* 마다 단일 값 으로 degenerate — 14 setting 에 unique 값이 7 개 (= 7 dataset). 즉 fit 이 $kta_train_r10 \rightarrow LR_loss$ 가 아니라 *dataset identity* → LR_loss 의 흡수일 가능성. mixed model 의 β (dataset random effect 흡수 후 effect) 가 plan 의 secondary tier 였으나 lens2 의 산출에 NaN — round 2 에서 statsmodels MixedLM 으로 직접 측정 필요.

이 의문 해소 후 에야 H4 가 mechanism evidence 인지 dataset artifact 인지 확정.

H5 (d_eff_ratio → A1 recovery): reject — lens 3 의 inherent 한계

$d_eff(\rho) = \sum_i \lambda_i / (\lambda_i + \rho)$ 의 r-truncated version 의 ratio 가 모든 setting 에서 거의 0.100 ($d_eff_full \approx 5000$, ratio = $500 / 5000 = 0.1$). 이는 NTK spectrum 의 단조감소 특성에 따른 *inherent* 결과이지 setting 사이 변별력이 없는 것. lens 3 (d_eff) 는 본 분석에선 활용 불가 — plan §4 의 *brief* 결정이 옳았음.

4. iter_03 framework 와의 연결 (확장)

iter_03 의 7 quantity (LC_LR, $PR(c^2)$, Spearman(λ , c^2), overlap_LR_A1, train_majority, LR_predict_majority_frac, C) 가 iter_04 의 lens 에 어떻게 mapping 되는지 — *quantity* 정의 도 함께.

iter_03 quantity	정의	iter_04 의 위치	검증 상태
LC_LR(r)	LR 의 selected sample 들의 <i>learning curve</i> 의 <i>r-truncation</i> 시점에서의 <i>confidence</i> . iter_03 §1 에서 "small sel 에서 LR 의 majority recall" 의 proxy 로 사용.	lens 2 의 LC_train(r), LC_val(r)	round 2 에서 $r \in \{5,10,15,20\}$ 일관성 측정
PR(c^2)	participation ratio of c^2 values: $PR(x) = (\sum x)^2 / \sum x^2$. iter_03 의 Cond 2 cause-side mechanism — small budget 에서 어느 mode 가 dominant 한지 측정	lens 2 의 pr_c2_train + KTA(r)/KTA_full ratio	H3, H4 가 KTA quantity 의 cause-side spectral 정량화로 지지. complementary 인지 redundant 인지는 round 2 에서
train_majority	max_c P_train(c). Cond 2 verify-side	lens 1 의 max_c P_train(c)	H2 가 <i>label-side</i> 와 <i>spectral-side</i> (H3) 분리 가능성 보여줌
LR_predict_majority_frac	LR 이 val 에서 majority class 로 예측한 비율. Cond 2 의 effect-side trigger	lens 1 의 BBSE-weighted risk	round 2 에서 측정
C	class 수. Cond 3 의 SNR axis	lens 1 의 KL + $\sqrt{(C-1)}$ factor	mapping 약화 (next_directions 로 이관) — C 와 KL 은 independent mechanism

핵심 mapping: iter_03 의 Cond 2 ($PR(c^2)$ cause-side mechanism) 은 iter_04 의 lens 2 KTA quantity 의 spectral 정량화로 강하게 지지된다 (H3, H4 confirm). 단 plan §6 의 "동치" 주장은 round 2 의 $PR(c^2) \leftrightarrow KTA(r)/KTA_{full}$ 의 *redundancy* 측정 결과에 따라 *complementary partition* 으로 약화될 수 있음.

5. 핵심 결론 3 개

- Spectral KTA gap (lens 2) 가 가장 sharp 한 single predictor** — valbal 에션 H3 ($r = -0.71$) 이 A1 recovery 의 약 절반 분산 설명, trainbal 에션 H4 ($r = 0.99$) 이 LR collapse 의 거의 모든 분산 설명. 단 H4 의 dataset confounding 의문 해소 필요.
- Label shift (lens 1) 는 단독으로 insufficient** — KL 단변량으로는 trainbal random-loss 설명 못함 (H1 reject). lens 2 와 *interaction* 으로만 작동할 가능성.
- A1 의 recovery 는 train-side imbalance 와 cross-Ŷ alignment 두 축 모두에서 measurable** — paper main story 는 "A1 = label-aware mode selection 이 imbalance + small budget regime 에서 LR collapse 의 *spectral-side* 회복" 으로 잡힘.

6. Round 2 의 우선 task

#	task	시간	무엇을 점검
1	experiments/ lens_mixed_model.py 신설	15-20 분, CPU	(i) H4 의 mixed β + within-dataset Spearman 으로 dataset confounding 점검, (ii) $\text{outcome} \sim \text{kl_val_S} \times \text{kta_train_r10}$ 의 interaction 향으로 H1 의 moderator 효과 검증, (iii) $\text{Spearman}(\text{max_P_train}, \text{kta_gap_r10})$ 의 H2-H3 redundancy 측정, (iv) H4 를 valbal 21 setting 에 regime-cross 적용 (mechanism generality), (v) (Q3) "trainbal random-loss 절반 case" 의 operational rate ($\text{gap} < -0.02$ cell 비율) 계산
2	paper main story arc 결정	round 2 후	scenario A ("lens 2 가 lens 1 함수") vs scenario B ("complementary partition"). trigger: $\text{Spearman}(\text{max_P_train}, \text{kta_gap_r10}) \geq 0.7 \rightarrow A, < 0.5 \rightarrow B$
3	iter_05 의 분기 (사용자 선택)	—	(Task A) KTA-based generalization bound 도출 (paper §Theory), (Task B) vision domain 확장, (Task C) training dynamics 의 epoch dependence

7. 산출 file

- 분석 데이터: state/iteration_04/grand_df.csv (79,800 cells, mnli cls90 INV 포함), lens1_table.csv, lens2_table.csv, eig_cache/ (52 npz)
- 통계 결과: lens1_corr.csv, lens2_corr.csv, lens1_cell_kl.csv
- 그림: lens1_figs/H{1,2}_scatter.png, lens2_figs/H{3,4}_scatter.png
- 문서: plan.md (7300 단어 v2), critique.md (8500 단어), next_directions.md (1700 단어), critique_priorart.md (보존)
- 스크립트: experiments/build_grand_df.py, lens1_label_shift.py, lens2_kta_spectral.py
- 전체 archive: reports/iter_04.pdf (45 pages)
- 데이터 PDF: reports/lrfshap_vs_a1_trainbal.pdf (43 pages, 18 settings, 7 dataset trainbal fully done), reports/lrfshap_vs_a1_valbal.pdf (27 pages, 21 settings)