

Shapley Value 비교 리포트: inv vs eigen / nystrom

원본(FreeShap, inv = full eNTK)으로 구한 점별 Shapley 값을 기준으로, 근사 방법인 eigen과 nystrom이 같은 데이터 포인트에서 값을 얼마나 다르게 추정하는지 비교한다. (랭킹이 아니라 값 자체의 차이)

실험 설정

- 데이터셋 7개: sst2, mnli, ag_news, mr, qqp, rte, mrpc · approx rank: 1%, 5%, 20%
- eigen $\lambda = 1e-2$ / nystrom $\lambda = 1e-2 \cdots 1e-6$ (5종) / 공통 seed=2024, tmc=500
- 점별 Shapley 값 = dv_result[:,1,:].sum(axis=1) (검증셋 accuracy 기여의 합)
- 정렬: 같은 seed라 모든 방법의 sampled_idx가 동일 → 같은 위치 = 같은 데이터 포인트 (로드 시 일치 확인)

핵심 결론


- ① eigen은 inv 값에 충실하다 — 상관 0.56~0.93, 점별 평균오차 0.06~0.18, 폭발 없음.
- ② nystrom은 값이 폭발한다 — 특히 rank 5% · 작은 λ 에서 Shapley 값이 $\pm 10 \sim 30$ 까지 튀고(정상 $\sim \pm 1$), inv와의 상관이 거의 0(≈ 0.03), 표준편차가 inv의 8~40배.
- ③ 원인은 앞서 분석한 $m \approx d$ 수치 불안정성 — rank 5%(=차원 $d \approx 250$)에서 TMC coalition이 $m \approx d$ 를 지날 때 feature 역행렬이 폭발 → marginal 기여 폭발. λ 가 작을수록(정규화 약할수록) 심함.
- ④ 주의: 이건 "값"의 불안정이지 "랭킹"이 아니다. 데이터 선택(랭킹 기반)은 멀쩡해 보여도, Shapley 값을 직접 쓰는 분석에는 nystrom(특히 mid-rank · 작은 λ)이 부적합하다.

A. 데이터 선택 정확도 (랭킹 기반)

각 방법의 Shapley 랭킹으로 상위 k% 데이터를 고른 뒤 full eNTK(inv)로 정확도를 측정한 것. x=선택 비율(1~100%), y=검증 정확도. eigen $\lambda = 1e-2 + \text{nystrom } 5\lambda$. 곡선이 위일수록 그 랭킹이 더 좋은 데이터를 골랐다는 뜻.

핵심 — 대부분의 칸에서 곡선들이 비슷하게 겹친다 = 랭킹 기반 선택 정확도는 방법 간 큰 차이가 없다. 뒤(①②③)에서 값이 폭발했던 칸(mr · qqp rank 5%)에서도 이 정확도 곡선은 멀쩡하다 → 값은 못 믿어도 랭킹(=상대 순서)은 대체로 살아남는다. 그래서 값 비교를 따로 봐야 한다.

예시 — ag_news rank 20%에서는 eigen(검정)이 nystrom보다 대체로 위 = 고rank에선 eigen 우세. 방법 간 차이는 주로 저선택 구간(그래프 좌측)에서 드러난다.



선택 비율별 정확도 (full eNTK 평가) — eigen $\lambda = 1e-2 + \text{nystrom } 5\lambda$


① 충실도 히트맵 (correlation & mean| Δ |)

한 칸 = (데이터셋, rank) $\times$ 방법. 왼쪽 = inv와의 상관(1=거의 동일, 0=무관), 오른쪽 = 점별 평균 절대오차 mean|approx - inv|. **초록일수록 inv와 가깝다**(왼쪽은 1에 가까움, 오른쪽은 0에 가까움). 빨강은 멀다.

맨 왼쪽 열(eigen)이 전반적으로 초록인 반면, 오른쪽으로(λ 가 작아질수록) · 특히 rank 5% 행에서 새빨강게 변한다 = nystrom 값 폭발.

예시 — ag_news rank 5% 행을 보면: eigen corr=0.90(진초록)인데, 같은 행 nys $\lambda=1e-6$ 은 corr=0.03(새빨강). 윈→오로 갈수록 빨개진다. 반대로 rte 행들은 nystrom도 비교적 초록 = 이 데이터셋은 폭발이 없다.

Shapley VALUE fidelity to inv (full eNTK): eigen stays faithful, nystrom explodes at mid-rank / small λ



correlation(좌) · mean| Δ | (우) 히트맵 — 초록=inv와 가까움


② 평균 · 최대 오차 막대 (log 스케일)

각 칸 = (데이터셋, rank)의 6개 방법. 막대 높이 = 평균오차 $\text{mean}|\Delta|$, 막대 위 가로 tick = 최대오차 $\text{max}|\Delta|$. y축은 log 스케일이고, **빨간 점선** = 정상 Shapley 값 스케일 (≈ 1). 막대가 빨간선을 넘으면 사실상 폭발이다.

eigen(검정) 막대는 어디서나 빨간선 한참 아래 = 평균으로도 최댓값으로도 inv에 가깝다. nystrom 막대는 rank 5%(가운데 열)에서 빨간선 위로 치솟는다.

예시 — mr rank 5%: eigen은 평균 0.09 · 최대 0.72(빨간선 아래)인데, nys $\lambda = 1e-2$ 는 평균 2.59 · 최대 12.96(빨간선 위). 즉 평균은 ~29배, 최대는 ~18배 eigen이 더 작다 = inv에 더 비슷하다. 다만 rte rank 5%는 nystrom도 빨간선 아래(안정)라, 폭발이 데이터셋 · rank에 따라 갈린다.

Per-point [Shapley value — inv]: bar=mean, tick=max (log y; red line ~ normal sv scale)




막대=mean $|\Delta|$, tick=max $|\Delta|$ (log y; 빨간선 $\approx$ 정상 sv 스케일)

③ 점별 오차 분포

Shapley 값 자체가 아니라 점별 오차 = (approx 값 - inv 값)의 분포(히스토그램)다. x =오차(0이면 inv와 일치), 검정=eigen. $|\text{오차}| > 1$ 인 점은 ± 1 로 클리핑해 양끝에 쌓이게 했다(각 칸 좌상단에 클리핑된 비율 표시).

0에 좁고 뾰족할수록 inv에 충실하다. eigen은 어디서나 0 중심의 뾰족한 종 모양. nystrom은 안정 칸에선 조금 더 퍼진 종, 폭발 칸에선 0 근처가 비고 양끝(± 1)에 스파이크가 생긴다.

예시 - qqp rank 5%: eigen은 0 중심의 뾰족한 종이지만, nystrom은 대부분의 점이 ± 1 로 클리핑돼 양끝에 몰린다(값이 inv와 완전히 어긋남). 반대로 sst2 rank 1%는 eigen · nystrom 모두 0 근처 종 모양 = 둘 다 안정적.




④ 순위(rank) 보존도 — Spearman & top-5% 겹침

①②③은 값의 유사도였다. 이 페이지는 순위(순서)가 inv와 같은지를 직접 본다. 왼쪽 = Spearman 순위상관(1=같은 순서, ~0=무관), 오른쪽 = inv가 고른 상위 5% 데이터를 얼마나 똑같이 고르나(top - 5% 집합 겹침; 무작위면 ~0.05). **초록일수록 순위를 잘 보존**.

핵심 — Spearman이 ①의 Pearson을 거의 그대로 따라간다. 즉 값이 터진 칸은 순위도 같이 무너진다(순위상관 ≈ 0 , top - 5% 겹침이 무작위 수준 ~ 0.05). eigen은 값뿐 아니라 **순위도 잘 보존**한다.

예시 — mr rank 5%: eigen은 Spearman **0.76** · top - 5% 겹침 **0.59**인데, nys $\lambda = 1e-2$ 는 Spearman **0.04** · top - 5% 겹침 **0.06**(= 거의 무작위). 즉 폭발 칸의 nystrom 순위는 inv와 사실상 무관하다.

Shapley RANKING preservation vs inv: eigen preserves order; nystrom order collapses where values explode



Spearman 순위상관(좌) · top - 5% 겹침(우) — 초록=순위를 잘 보존

정리 & 시사점

- **eigen**은 Shapley 값과 순위 둘 다 inv에 충실 → 값 기반 · 순위 기반 분석 모두 안전.
- **nystrom**은 mid - rank · 작은 λ 에서 값이 폭발하고 순위(④)도 inv와 무관해진다. 데이터 선택 정확도(A)가 그래도 괜찮아 보인 건 무작위에 가까운 선택도 정확도가 그럭저럭 나오기 때문이지 순위가 맞아서가 아니다.
- nystrom을 꼭 쓴다면: 큰 λ ($\geq 1e-2$)를 쓰고, rank를 $m \approx d$ 충돌 구간(여기선 5% $\approx d250$ 부근)을 피하도록 선택. 그래도 mr · qqp처럼 $\lambda = 1e-2$ 에서도 터지는 경우가 있으니, 값 정밀 비교에는 eigen 권장.
- 같은 경향이 데이터셋 전반(7개)에서 일관되게 나타난다. 예외적으로 rte(가장 작은 데이터셋, d가 작음)는 nystrom도 비교적 안정적이다.

※ 그림은 모두 seed=2024, tmc=500 기준. 표/수치 원본은 분석 스크립트로 언제든지 재생성 가능.